

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií
FIIT-XXXX-XXXX

Bc. Zoltán Csengődy

IDENTIFIKÁCIA BEZPEČNOSTNÝCH RIZÍK A ANALÝZA DÁT Z PROSTREDIA
POČÍTAČOVÝCH SIETÍ

Diplomová práca

Študijný program:	Inteligentné softvérové systémy
Študijný odbor:	18. Informatika
Miesto vypracovania:	Ústav počítačového inžinierstva a aplikovanej informatiky
Vedúci práce:	Ing. Rudolf Grežo

december 2019

Zadanie diplomovej práce

Meno študenta: **Bc. Zoltán Csengődy**

Študijný program: Intelligentné softvérové systémy

Študijný odbor: Softvérové inžinierstvo – hlavný študijný odbor
Umelá inteligencia – vedľajší študijný odbor

Názov práce: **Identifikácia bezpečnostných rizík a analýza dát z prostredia počítačových sietí**

Samostatnou výskumnou a vývojovou činnosťou v rámci predmetov Diplomový projekt I, II, III vypracujte diplomovú prácu na tému, vyjadrenú vyššie uvedeným názvom tak, aby ste dosiahli tieto ciele:

Všeobecný cieľ:

Vypracovaním diplomovej práce preukážte, ako ste si osvojili metódy a postupy riešenia relatívne rozsiahlych projektov, schopnosť samostatne a tvorivo riešiť zložité úlohy aj výskumného charakteru v súlade so súčasnými metódami a postupmi študovaného odboru využívanými v príslušnej oblasti a schopnosť samostatne, tvorivo a kriticky pristupovať k analýze možných riešení a k tvorbe modelov.

Špecifický cieľ:

Vytvorte riešenie zodpovedajúce návrhu textu zadania, ktorý je prílohou tohto zadania. Návrh bližšie opisuje tému vyjadrenú názvom. Tento opis je záväzný, má však rámcový charakter, aby vznikol dostatočný priestor pre Vašu tvorivosť.

Riadte sa pokynmi Vášho vedúceho.

Pokiaľ v priebehu riešenia, opierajúc sa o hlbšie poznanie súčasného stavu v príslušnej oblasti, alebo o priebežné výsledky Vášho riešenia, alebo o iné závažné skutočnosti, dospejete spoločne s Vaším vedúcim k presvedčeniu, že niečo v texte zadania a/alebo v názve by sa malo zmeniť, navrhnete zmenu. Zmena je spravidla možná len pri dosiahnutí kontrolného bodu.

Miesto vypracovania: Ústav počítačového inžinierstva a aplikovanej informatiky, FIIT STU Bratislava

Vedúci práce: **Ing. Rudolf Grežo**

Termíny odovzdania:

Podľa harmonogramu štúdia platného pre semester, v ktorom máte príslušný predmet (Diplomový projekt I, II, III) absolvovať podľa Vášho študijného plánu

Predmety odovzdania:

V každom predmete dokument podľa pokynov na www.fiit.stuba.sk v časti:
home > Informácie o > štúdiu > harmonogram štúdia > diplomový projekt.

V Bratislave dňa 11. 2. 2019

SLOVENSKÁ TECHNICKÁ UNIVERZITA
V BRATISLAVE
Fakulta informatiky a informačných technológií
Ilkovičova 2, 842 16 Bratislava 4

1

prof. Ing. Pavol Návrat, PhD.
riaditeľ Ústavu informatiky, informačných systémov
a softvérového inžinierstva

Návrh zadania diplomovej práce

Finálna verzia do diplomovej práce¹

Študent:

Meno, priezvisko, tituly: Zoltán Csengődy, Bc.
Študijný program: Inteligentné softvérové systémy
Kontakt: csengody4@gmail.com

Výskumník:

Meno, priezvisko, tituly: Rudolf Grežo, Ing.

Projekt:

Názov: Identifikácia bezpečnostných rizík a analýza dát z prostredia počítačových sietí
Názov v angličtine: Data analysis and security risk identification in computer networks
Miesto vypracovania: Ústav počítačového inžinierstva a aplikovanej informatiky, FIIT STU
Oblasť problematiky: počítačové siete, analýza dát, bezpečnosť

Text návrhu zadania²

Počítačové siete nás sprevádzajú každodenným životom, pričom jedným z aspektov pri práci s nimi je zvýšenie spoľahlivosti a bezpečnosti siete. Spoľahlivosť a bezpečnosť siete sú kľúčové pre poskytovanie rôznych služieb siete, ako napríklad prenos informácií a zdieľanie prostriedkov. Rozvoj v oblasti sietí je veľmi rýchly a tým pádom sa môžu stať zraniteľnými voči novým druhom útokov. Preto je potrebné venovať sa zabezpečeniu siete a hľadaniu nových spôsobov detekcie sieťových útokov.

Analyzujte súčasný stav problematiky, typy útokov a metódy použiteľné pri analýze dát z počítačových sietí. Vzhľadom na identifikáciu bezpečnostných rizík a útočnej premávky navrhňte modifikáciu existujúcich algoritmov alebo metód so zameraním na spracovanie tohto typu dát. Zamerajte sa najmä na voľne dostupné dátové množiny. Pred samotným identifikovaním bezpečnostných rizík a útočnej premávky analyzujte a spracujte rozsiahle množiny dát.

Vami navrhnutý algoritmus alebo metódu implementujte vo forme softvérového nástroja. S ohľadom na jednoduchosť, modulárnosť, rozšíriteľnosť a použiteľnosť riešenia sa snažte využiť existujúce softvérové moduly. Výsledné riešenie overte na množine existujúcich testovacích dát a ukážte jeho prínos voči podobným riešeniam.

¹ Vytlačiť obojstranne na jeden list papiera

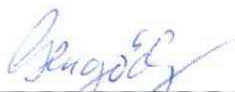
² 150-200 slov (1200-1700 znakov), ktoré opisujú výskumný problém v kontexte súčasného stavu vrátane motivácie a smerov riešenia

Literatúra³


- LIU, Gao, Zheng YAN a Witold PEDRYCZ. Data collection for attack detection and security measurement in Mobile Ad Hoc Networks: A survey. Journal of Network and Computer Applications [online]. 2018, 105, s. 105-122. DOI: 10.1016/j.jnca.2018.01.004.
- ZAMAN, Marzia a Chung-Horng LUNG. Evaluation of machine learning techniques for network intrusion detection. In: NOMS 2018 - 2018 IEEE/IFIP Network Operations and Management Symposium [online]. 2018, s. 1-5. DOI: 10.1109/NOMS.2018.8406212.

Vyššie je uvedený návrh diplomového projektu, ktorý vypracoval(a) Bc. Zoltán Csengődy, konzultoval(a) a osvojil(a) si ho Ing. Rudolf Grežo a súhlasí, že bude takýto projekt viesť v prípade, že bude pridelený tomuto študentovi.

V Bratislave dňa 28.1.2019



Podpis študenta

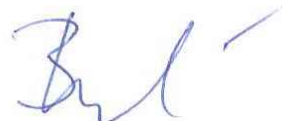


Podpis výskumníka

Vyjadrenie garanta predmetov Diplomový projekt I, II, III

Návrh zadania schválený: áno / nie⁴

Dňa: 11. 2. 2019



Podpis garanta predmetov

³ 2 vedecké zdroje, každý v samostatnej rubrike a s údajmi zodpovedajúcimi bibliografickým odkazom podľa normy STN ISO 690, ktoré sa viažu k téme zadania a preukazujú výskumnú povahu problému a jeho aktuálnosť (uvedte všetky potrebné údaje na identifikáciu zdroja, pričom uprednostnite vedecké príspevky v časopisoch a medzinárodných konferenciách)

⁴ Nehodiace sa prečiarknite

Čestne vyhlasujem, že som túto prácu vypracoval samostatne, na základe konzultácií a s použitím uvedenej literatúry.

V Bratislave, 11.12.2019

Bc. Zoltán Csengődy

Anotácia

Slovenská technická univerzita v Bratislave

FAKULTA INFORMATIKY A INFORMAČNÝCH TECHNOLOGIÍ

Študijný program: Inteligentné softvérové systémy

Autor: Bc. Zoltán Csengődy

Diplomová práca: Identifikácia bezpečnostných rizík a analýza dát z prostredia počítačových sietí

Vedúci diplomovej práce: Ing. Rudolf Grežo

december 2019

Počítačové siete nás sprevádzajú každodenným životom, pričom jedným z aspektov pri práci s nimi je zvýšenie spoľahlivosti a bezpečnosti siete. S rozvojom tejto technologickej oblasti prichádzajú nové spôsoby a typy útokov, voči ktorým sa treba chrániť. Táto práca je venovaná výskumu v oblasti odhalenia počítačových útokov metódami strojového učenia. Cieľom tejto diplomovej práce je vytvorenie programového modulu, ktorý vhodným spôsobom dokumentuje vybrané algoritmy strojového učenia. Hlavnou motiváciou je vytvorenie jednotnej analýzy vplyvov rôznych nastavení klasifikačných algoritmov a rôznych spôsobov predspracovania vybraných dátových množín na výsledky odhalenia sieťových útokov. Súčasťou tejto práce je vlastný návrh riešenia, ktorý vyplýva z faktu, že hlavným nedostatkom použitia algoritmov strojového učenia je nedostatočná dokumentácia použitia, tvorba architektúry a nastavenia parametrov. Dnešný spôsob použitia týchto metód spočíva predovšetkým v skúšaní a optimalizácii najlepšieho riešenia pre daný model. Na základe rôznych nastavení a vstupov do metód dokážeme optimalizovať klasifikáciu a tým pádom pri vhodných nastaveniach dosahovať lepšie výsledky hodnotenia modelu. V tejto práci sa venujeme hľadaniu anomálií v sieťovej premávke a metódam, ktoré sú určené na ich odhaľovanie. Súčasťou práce je taktiež vhodné predspracovanie dát vybranej dátovej množiny a odhalenie závislostí medzi jeho atribútmi, ktoré majú značný vplyv na odhaľovanie útokov. Výstupom tejto práce je programový modul na predspracovanie dátovej množiny a programový modul strojového učenia. Na základe výsledkov z programového modulu porovnáme výhody a nevýhody použitých metód strojového učenia a výsledky interpretujeme vhodným spôsobom.

Annotation

Slovak University of Technology in Bratislava

FACULTY OF INFORMATICS AND INFORMATION TECHNOLOGIES

Degree course: Intelligent software systems

Author: Bc. Zoltán Csengődy

Master's thesis: Data analysis and security risk identification in computer networks

Supervisor: Ing. Rudolf Grežo

2019, December

Computer networks accompany us with everyday life, and one aspect of working with them is to increase network reliability and security. With the development of this technological area, new ways and types of attacks are coming, against which we must protect ourselves. This work is devoted to research in the field of detection of computer attacks by machine learning methods. The aim of this master thesis is to create a program module, which in an appropriate way documents the selected machine learning algorithms. The main motivation is to create a unified analysis of the effects of the different settings of the classification algorithms and the different methods of pre-processing the selected datasets to the results of network attack detection. Part of this work is a custom design solution, which stems from the fact that the main drawback of using machine learning algorithms is insufficient documentation of the use, creation of architecture and parameter settings. Today's use of these methods lies primarily in testing and optimizing the best solution for a given model. Based on the various settings and inputs to the methods we can optimize the classification and thus achieve better model evaluation results with appropriate settings. In this work, we look for anomalies in network traffic and methods intended to detect them. Part of the work is also a suitable pre-processing of the selected dataset and revealing the dependencies between its attributes, which have a significant impact on the detection of attacks. The outcome of this work is a program module for dataset preprocessing and a machine learning program module. Based on the results from the program module, we compare the advantages and disadvantages of used machine learning methods and interpret the results in an appropriate way.

Obsah

1. Úvod.....	1
2. Analýza problematiky.....	3
2.1. Typy systémov na detekciu sieťových útokov.....	3
2.1.1. Anomálne založené detekčné systémy	5
2.1.2. Charakteristiky IDS	8
2.2. Architektúra IDS.....	10
2.3. Existujúce nástroje.....	11
2.4. Spôsob vyhodnocovania IDS	12
2.5. Sieťové útoky	17
2.5.1. Detekcia anomálií	17
2.5.2. Detekcia zneužitia.....	17
2.5.3. Monitorovanie cieľa	18
2.5.4. Špionáž	18
2.5.5. Typy sieťových útokov	18
2.5.6. Odhalenie sieťových útokov	20
2.6. Strojové učenie.....	22
2.6.1. Klasifikačné algoritmy.....	23
2.6.2. Neurónová sieť	26
2.7. Dátové množiny	29
2.7.1. NSL-KDD.....	29
2.7.2. UNSW-NB15.....	31
2.7.3. ISCX.....	33
2.7.4. Predspracovanie dát.....	35
2.8. Zhodnotenie analýzy	38
3. Špecifikácia požiadaviek.....	39
3.1. Funkcionálne požiadavky	39
3.2. Nefunkcionálne požiadavky.....	40
3.3. Prípady použitia	41
3.3.1. Scenáre prípadov použitia.....	42
4. Návrh riešenia	47
4.1. Vývojové prostredie	48
4.2. Programový modul predspracovania dátovej množiny	48
4.3. Opis činností programového modulu predspracovania dátovej množiny	52

4.4.	Programový modul strojového učenia.....	53
4.5.	Opis činností programového modulu strojového učenia	55
5.	Implementácia	57
5.1.	Nastavenie vývojového prostredia	57
5.2.	Prototyp programového modulu predspracovania dátovej množiny.....	57
5.2.1.	Načítanie dátovej množiny	58
5.2.2.	Analýza dátovej množiny	58
5.2.3.	Čistenie dát	58
5.2.4.	Doplnenie chýbajúcich hodnôt	59
5.2.5.	Spracovanie kategorických atribútov	60
5.2.6.	Obohacovanie dát	60
5.2.7.	Štandardizácia.....	61
5.2.8.	Vzorkovanie.....	61
5.2.9.	Uloženie súborov	61
5.3.	Prototyp programového modulu strojového učenia.....	62
5.3.1.	Načítanie, zjednotenie a transformácia predspracovanej dátovej množiny.....	62
5.3.2.	Trénovanie a vyhodnotenie modelu strojového učenia	63
5.3.3.	Uloženie súborov	64
6.	Overenie riešenia.....	65
6.1.	Experimentálne overenie riešenia	66
7.	Zhodnotenie	71
	Bibliografia	73
	Príloha A: Plán práce	A-1
	Príloha B: Technická dokumentácia	B-1
	Príloha C: Obsah elektronického média.....	C-1

Zoznam obrázkov

Obrázok 1 – Všeobecná architektúra IDS [38]	3
Obrázok 2 – Architektúra HIDS [38].....	4
Obrázok 3 – Architektúra NIDS [38].....	4
Obrázok 4 – Bodová, kontextová a kolektívna anomália [8].....	6
Obrázok 5 – Funkcionality IDS [54].....	10
Obrázok 6 – Confusion matrix [7]	14
Obrázok 7 – ROC krivka [43].....	15
Obrázok 8 – Návrh platformy na odhalenie sieťových útokov [27]	21
Obrázok 9 – Prostredie odhalenia útoku [27]	21
Obrázok 10 – Štruktúra modulu na detekciu sieťových útokov [27].....	22
Obrázok 11 – Neurón [39]	26
Obrázok 12 – Feed-forward neurónová sieť [18]	27
Obrázok 13 – Model neurónovej siete pre IDS [39].....	28
Obrázok 14 – Proces klasifikácie sieťových útokov [39]	28
Obrázok 15 – Diagram prípadov použitia.....	41
Obrázok 16 – Diagram aktivít programového modulu predspracovania dátovej množiny	52
Obrázok 17 – Diagram aktivít programového modulu strojového učenia.....	55
Obrázok 18 – ROC krivka najlepšieho modelu náhodného lesa	68
Obrázok 19 – ROC krivka SGD klasifikátora	68
Obrázok 20 – ROC krivka rozhodovacieho stromu.....	69
Obrázok 21 – ROC krivka náhodného lesa.....	69

Zoznam tabuliek

Tabuľka 1 – Typy IDS [29]	5
Tabuľka 2 – Útoky v testovacom súbore dát NSL-KDD [37]	30
Tabuľka 3 – Tabuľka výsledkov experimentu v nástroji WEKA [10]	31
Tabuľka 4 – Tabuľka výsledkov pre sieťovú forenznú schému [31].....	33
Tabuľka 5 – Tabuľka presností klasifikačných algoritmov pre ISCX IDS 2012 [48].....	35
Tabuľka 6 – Scenár prípadu použitia spracuj vybranú dátovú množinu	42
Tabuľka 7 – Scenár prípadu použitia aplikuj metódu strojového učenia na množinu dát.....	43
Tabuľka 8 – Scenár prípadu použitia vyber dátovú množinu	44
Tabuľka 9 – Scenár prípadu použitia vyber metódu spracovania dátovej množiny	44
Tabuľka 10 – Scenár prípadu použitia vyber metódu strojového učenia.....	45
Tabuľka 11 – Výsledky experimentálnych testov - správnosť	66
Tabuľka 12 – Výsledky experimentálnych testov - F1-skóre	67
Tabuľka A.13 – Plán práce k DP I	A-1
Tabuľka A.14 – Plán práce k DP II.....	A-1
Tabuľka A.15 – Plán práce k DP III	A-2

1. Úvod

S rozvojom internetových technológií počítačové siete postupne menia životy ľudí a čoraz viac uľahčujú prácu a spôsob práce ľudí. Rozvoj tejto oblasti je veľmi rýchly a tým pádom je aj čoraz zraniteľnejší voči počítačovým útokom. S rozvojom tejto technologickej oblasti prichádzajú nové spôsoby a typy útokov.

Nebezpečenstvo počítačového útoku a jeho zabránenie je dôležitým aspektom, ktorý sa výskumníci v tejto oblasti snažia vyriešiť. Keďže počítačová sieť môže byť otvorená (voľne dostupná) a medzinárodne zdieľaná, tak údaje, ktoré sú v nej prenášané nie sú v bezpečí. Preto je potrebné zaviesť technické opatrenia na zabezpečenie ochrany údajov v sieťovom prostredí.

Zhromažďovanie údajov v počítačovej sieti môže výrazne pomôcť pri detekcii sieťových útokov a pomáhať pri správe siete. Vďaka monitorovaniu, testovaniu, kontrole a vyhodnocovaniu v reálnom čase sú správcovia siete schopní získať informácie o výkonnosti sieťového systému, vyhodnotiť kvalitu služieb (QoS) a zistiť poruchu siete. Vďaka napredujúcej technológii 5G a podpore technológie Internet vecí (IoT), sa veľkoplošné a vysokorýchlostné siete sa stávajú súčasťou výskumu a vývoja s cieľom účinne zhromažďovať a analyzovať údaje o sieti.

Danú problematiku je potrebné riešiť z dôvodu predchádzania škodlivým útokom prostredníctvom predikcie na základe analýze dát. V rámci riešenia tejto problematiky je dôležité navrhnúť, vytvoriť a implementovať bezpečnostné metódy na zabránenie takýchto útokov. Definícia pojmu sieťová bezpečnosť je podľa autorov Xia a Wang [60] nasledovná: „Pomocou zachytávania a integrácie všetkých druhov informácií, ktoré odrážajú bezpečnostný stav, možno predpovedať trend bezpečnosti siete“ (Xia Wei-Wei a Wang Hai-Feng, 2010, str. 616). Predčasné odhalenie škodlivej činnosti zabezpečí lepšiu ochranu siete od budúcich trendov v tejto oblasti, ktoré prinášajú nové, komplexné a sofistikovanejšie útoky. Taktiež zabezpečuje vybudovanie nákladovo efektívnej stratégie v prípade nového útoku.

Prvá časť tejto práce je venovaná analýze dát z prostredia počítačových sietí. Vzhľadom na identifikáciu bezpečnostných rizík a útočnej premávky je potrebné analyzovať existujúce algoritmy a procesy zamerané na spracovanie dát tohoto typu. Naším cieľom je analýza súčasného stavu problematiky a metód použiteľných pri analýze dát z prostredia počítačových sietí. V tejto práci sa venujeme analýze systémom na detekciu sieťového narušenia - IDS, ich architektúre a spôsobu vyhodnocovania. Taktiež sa venujeme sieťovým útokom, opisujeme typy sieťových útokov a priblížime si spôsob ich odhalenia. Bližšie opisujeme strojové učenie a jednotlivé algoritmy strojového učenia. Zvlášť v rámci kapitoly 2.6 Strojové učenie sa venujeme neurónovým sieťam. V našej práci sme pri výbere zohľadňovali kritériá, ktoré sú kladené na dnešné moderné metódy dolovania v dátach. To nás priviedlo k umelej inteligencii - neurónovým sieťam. Tie poskytujú v

dnešnej dobe veľmi intuitívne a moderné riešenia. Táto metóda klasifikácie je jedna z najpresnejších. Klasifikačná metóda ako náhodný les (Random Forest) má tiež veľký potenciál. Na záver analýzy sa venujeme vybraným dátovým množinám, kde uvádzame výsledky experimentov iných autorov pre budúce porovnanie s výsledkami našej práce a metódy predspracovania týchto dátových množín.

V druhej časti tejto práce sa venujeme návrhu vlastného riešenia. Navrhujeme dva programové moduly. Prvý programový modul je určený na spracovanie rozsiahlych dátových množín a druhý programový modul je určený na aplikovanie metód strojového učenia na vybranej predspracovanej dátovej množine. Taktiež navrhujeme prostredie v ktorom sa budú programové moduly vyvíjať. Určíme funkcionálne a nefunkcionálne požiadavky, ktoré majú programové moduly spĺňať. Nakoniec na základe návrhu implementujeme prototypy programových modulov. Postup implementácie jednotlivých častí programových modulov taktiež detailnejšie opíšeme. V poslednej časti tejto práce overíme navrhnuté riešenie. Riešenie overíme na základe miery splnenia funkcionálnych požiadaviek. Na záver vykonáme experimentálne testy a na základe výsledkov vyhodnotíme úspešnosť klasifikácie vybraných metód strojového učenia. Výsledky interpretujeme vo forme tabuliek a grafov.

Táto práca má dostatočne priblížiť, vysvetliť jednotlivé pojmy a súvislosti medzi nimi a uviesť čitateľa do danej problematiky.

2. Analýza problematiky

V tejto kapitole sa budeme venovať analýze systémov na detekciu sieťových útokov (Intrusion Detection System - IDS) a priblížime jednotlivé prístupy detekcií sieťových útokov.


2.1. Typy systémov na detekciu sieťových útokov

Na základe predpokladu, že správanie sa útočníka na sieti je odlišné od bežného správania sa používateľa môžeme takúto sieťovú premávku identifikovať ako útočnú. Prostredníctvom skúmania anomálií v sieti je možné detegovať známe, ale aj neznáme typy útokov. Anomáliám sa venujeme v kapitole 2.1.1 Anomálne založené detekčné systémy.

Systémy na detekciu sieťových útokov sú implementované ako druhá obranná línia popri autentifikácii používateľa a ďalších bezpečnostných mechanizmov. IDS je softvér, hardvér alebo ich kombinácia, ktorý monitoruje počítačovú sieť pre odhalenie škodlivých aktivít alebo narušení siete. Narušenie siete je akt odhalenia nepriateľského používateľa (útočníka), ktorý sa pokúša získať neoprávnený prístup do siete alebo sa snaží narušiť služby a odmietnuť služby legitímnym používateľom. Pri odhalení narušenia siete, IDS systémy vytvárajú správy pre správcov bezpečnosti siete, ktorí sa rozhodnú o ďalších postupoch zaobchádzania sa s narušením. Tieto systémy môžu byť nasadené priamo u používateľa siete alebo priamo integrované v sieti na analýzu sieťovej premávky.


Bhattacharyya a Kalita [8] vo svojej knihe uvádzajú nasledujúce metódy detekcie anomálií v počítačovej sieti:

- **Intrusion Detection System (IDS)** – Systémy detekcie narušenia je nasadzovaný ako druhá obranná línia spolu s ďalšími preventívnymi bezpečnostnými mechanizmami, ako je autentifikácia používateľov a kontrola prístupu. Tento systém detekcie narušenia je založený na tom, že správanie útočníka je výrazne odlišné od správania bežného používateľa. Na nasledujúcom obrázku môžete vidieť všeobecnú architektúru IDS.



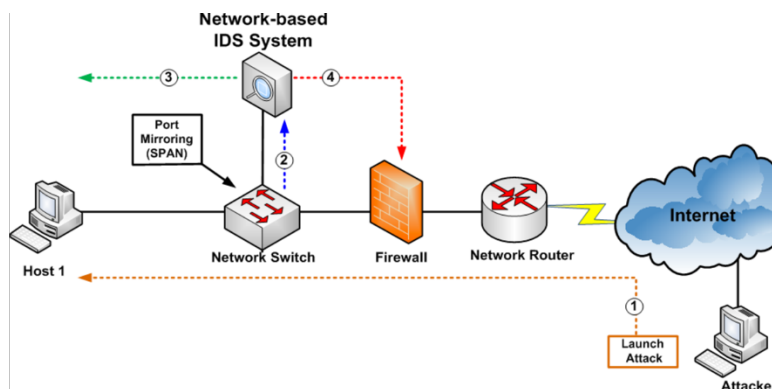
Obrázok 1 – Všeobecná architektúra IDS [38]

- **Host-based IDS (HIDS)** – Systém monitoruje vnútro výpočtového systému a sleduje, či niekto neobišiel bezpečnostnú politiku z vnútra (interne) alebo z vonka (externe). Podľa Jajish [23] HIDS je softvérová aplikácia (agent) nainštalovaný na pracovných staniciach, ktoré sa majú monitorovať. Agenti monitorujú operačný systém a zapisujú údaje do protokolových súborov a/alebo spúšťajú poplach. Tento typ systému môže monitorovať iba jednotlivé pracovné stanice na ktorých sú agenti nainštalovaní, nemôže monitorovať celú sieť. HIDS môže zistiť internú aktivitu, ako napríklad program, ktorý prístupuje k zdrojom a pokúša sa k neoprávnenému prístupu.



Obrázok 2 – Architektúra HIDS [38]

- **Network-based IDS (NIDS)** – Keďže sieť je prepojená väčšinou s internetom pre komunikáciu so zvyškom sveta, tak NIDS číta všetky prichádzajúce pakety alebo toky a snaží sa nájsť podozrivé vzory. Podľa [23] Zvyčajne sa skladajú zo sieťového zariadenia s kartou sieťového rozhrania (NIC) pracujúci v promiskuitnom režime. V prípade ak je paket prepojený s podpisom útočníka, tak je generované upozornenie alebo je paket zaznamenaný do databázy.



Obrázok 3 – Architektúra NIDS [38]

Autori Liu, Yan a Pedrycz [29] vo svojej práci IDS ďalej rozdeľujú do päť typov (viď. tabuľku č. 1):

- Anomaly-Based Intrusion Detection System (ABIDS)
- Knowledge-Based Intrusion Detection System (KBIDS)
- Specification-Based Intrusion Detection System
- Hybrid Intrusion Detection System (HIDS)
- Other Intrusion Detection System (OIDS)

Tabuľka 1 – Typy IDS [29]

IDS	Popis
ABIDS	Odvodzuje model (profil) podľa prijateľných činností a správania a generuje poplach, ak sa monitorované činnosti alebo správanie sa výrazne odlišuje od tohto profilu.
KBIDS	Zachováva vzory konkrétnych útokov a spustí poplach ak sa pozorované udalosti zhodujú so vzormi.
SBIDS	Vyberá špecifikácie, ktoré definujú správne operácie siete s určitými obmedzeniami a identifikuje narušenie ak sa monitorované operácie odlišujú od špecifikácie.
HIDS	Je kombináciou ABIDS, KBIDS a SBIDS.
OIDS	Nepatrí do vyššie uvedených typov IDS.

2.1.1. Anomálne založené detekčné systémy

Anomálie v sieťach sa môžu vyskytnúť z viacerých dôvodov, napríklad z dôvodu prevádzky siete či z dôvodu škodlivej činnosti. Na základe takýchto výkyvov v sieti dokážeme relatívne ľahko identifikovať činnosť, ktorá je odlišná od bežnej činnosti siete a určiť, či je táto činnosť škodlivá alebo nie. Bhattacharyya a Kalita [8] vo svojej knihe tvrdia, že anomálie v sieti sú detekovateľné prostredníctvom strojového učenia, ktoré odhaľuje dve hlavné oblasti/kategórie vplyvu anomálií na počítačovú sieť. Anomálie podľa [8] môžu ovplyvňovať výkonnosť a bezpečnosť siete.


Naším hlavným cieľom je venovanie sa anomáliám spôsobujúce bezpečnostné riziká v sieti, a to konkrétne anomáliám spôsobené škodlivými aktivitami. Škodlivé činnosti v sieti môžu mať rôzne typy, ako sú bodové anomálie, kontextové anomálie či kolektívne anomálie.

Nasledujúci zoznam stručne opisuje predchádzajúce tri typy škodlivých činností:

- **„Bodová anomália:** Bodové anomálie sú prípady, ktoré sú mimoriadne alebo nezvyčajné vzhľadom na ostatné údaje. Napríklad mimoriadne výdavky na výpise kreditnej karty v

porovnaní s predchádzajúcimi transakciami. Na obrázku č. 4 môžete vidieť, že objekt *O1* je izolovaný od inej skupiny objektov *C1*, *C2* a *C3*. Objekt *O1* je bodová anomália.

- **Kontextová anomália:** V danom kontexte (napr. v rámci daného rozsahu), ak je inštancia anomálna alebo výnimočná. Na obrázku č. 4 môžete vidieť, že objekt *O2* je izolovaný v kontexte skupiny objektov *C2*. Objekt *O2* je kontextová anomália.
- **Kolektívna anomália:** Ak sa zistí s ohľadom na dané normálne správanie, že skupina prípadov sa odchyli anomálne, celá skupina anomálnych prípadov sa označí ako kolektívna anomália. Na obrázku č. 4 je skupina *C3* odlišná od skupín *C1* a *C2* z hľadiska počtu prípadov a kompaktnosti, a preto môže byť *C3* označená ako kolektívna anomália.“ (Dhruba Kumar Bhattacharyya a Jugal Kumar Kalita [8], 2014, str. 46)



Obrázok 4 – Bodová, kontextová a kolektívna anomália [8]

Podľa [8], účel anomálne založených detekčných systémov je analýza, porozumenie, charakteristika sieťovej premávky, a zároveň identifikácia a klasifikácia abnormálnej premávky. Anomálne klasifikačné metódy existujú v štyroch kategóriách:

- **Dohliadaná anomálna detekcia** – Technika trénovania potrebuje trénovaciu dátovú množinu, ktorá má označenú normálnu a anomálnu sieťovú premávku. V prípade dát, ktoré sa nepodarilo zaklasifikovať (označiť) sú porovnané voči modelu už klasifikovaných tried a na základe výsledku sú zaradené do príslušnej triedy. Nevýhodou tejto techniky je, že anomálne dáta sú málo porovnávané voči normálnym triedam. Ďalej, je náročné presne a reprezentatívne klasifikovať anomálnu sieťovú premávku.
- **Čiastočne dohliadaná anomálna detekcia** – Technika, pri ktorej trénovacia dátová množina má označenú iba normálnu sieťovú premávku. Anomálna triedy nemajú označenie a tak využitie tejto techniky je viac aplikovateľná.

- **Nedohliadaná anomálna detekcia** – Technika nepoužíva trénovaciu dátovú množinu a tým pádom je dosiahnutie presnej detekcie anomálnej sieťovej premávky náročné. Väčšinou pri tejto technike sa vychádza z predpokladu, že normálna sieťová premávka je vo väčšej miere zastúpená v testovacej dátovej množine ako anomálna.
- **Hybridná anomálna detekcia** – Technika kombinujúca dohliadanú a nedohliadanú metódu detekcie. Táto technika má výhodu v tom, že vďaka dohliadanej technike má vysokú mieru odhalenia útokov a nízku mieru falošných poplachov. Na druhej strane, v prípade nedohliadanej techniky má výhodu v odhalení neznámych útokov. Preto hybridná technika detekcie sieťových útokov je schopná identifikovať známe, ale aj neznáme sieťové útoky.

Podľa Samrina a Vasumathi [38] anomálne založené detekčné systémy majú nasledovné výhody:

- Na identifikáciu nových útokov sa nevyžaduje aktualizácia databázy.
- Po nainštalovaní softvéru je potrebná údržba.
- Súbežne sleduje správanie sa siete a vytvára profily sieťových aktivít.
- Najefektívnejšie identifikuje hrozby vo väčšom systéme.

a nevýhody:

- Abnormálne správanie sa siete v normálnej premávke neodošle upozornenie správcovi.
- Veľa falošných poplachov.

Ďalšími stratégiami odhalenia sieťových útokov sú detekčné systémy založené na podpisoch (*Signature-based IDS*) podľa Warzyński a Kołaczek [57] a systémy na rozpoznanie zneužitia (*Misuse IDS*) podľa Saxena a spol. [41]. Detekčné systémy založené na podpisoch sú založené na podpisoch známych útokov a pravidiel definovaných administrátorom. Takéto systémy môžu klasifikovať známe útoky porovnaním pozorovanej aktivity s uloženými vzormi, ale nemôžu identifikovať nové útoky. V prípade systémov na rozpoznanie zneužitia je najprv definované abnormálne správanie systému a potom všetky ostatné správania sú definované ako normálne. Je v rozpore s prístupom na detekciu anomálií, ktorý využíva opačný postup. Pri detekcii zneužitia je všetko neznáme, normálne správanie sa.

2.1.2. Charakteristiky IDS

Spôsob reakcie IDS systémov na sieťové útoky môže byť dvojaká podľa Ahmed a spol. [1]: *pasívna* a *aktívna* reakcia. V prípade pasívnych detekčných systémov, systém pri odhalení sieťového útoku priamo nereaguje na útok, ale nechá rozhodnutie na iný systém. V prípade aktívneho detekčného systému, systém pri odhalení útoku priamo reaguje na útok napríklad zablokovaním sieťovej premávky pre detegovaného sieťového útočníka.

Jedným z najdôležitejších cieľov NIDS je odhalenie útočnej premávky v reálnom čase. V prípade aktívnych IDS je táto skutočnosť možná, pretože priamo reagujú v momente detekcie útoku. Žiaľ takéto systémy trpia vysokou mierou falošných poplachov, z čoho vyplývajú nasledovné nedostatky IDS [38]:

- **False positive:** Predpoveď falošných útokov. Ak je táto miera vysoká, potom normálny útok sa predpovedá ako útok.
- **False negative:** Vysoká miera falošne negatívnych hodnôt spôsobuje problém tak, že keď sa vyskytne narušenie siete, IDS nevytvorí žiadne upozornenie.
- **True positive:** Vyskytne sa vtedy, keď dôjde ku skutočnému útoku a IDS naň odpovie vyvolaním poplachu.
- **True negative:** Keď nenastane žiadny útok a IDS nevyvolá poplach.

Poplach [8] – Výstraha generovaná systémom NIDS, ktorá dostatočne a zmysluplne identifikuje dôvod, ktorý spôsobil udalosť poplachu a zdroj/cieľ útoku. Mal by pomáhať správcovi systému alebo analytikovi pri určovaní vhodnej reakcie na konkrétne upozornenie.

Bhattacharyya a Kalita [8] vo svojej knihe zadefinoval nasledujúce otvorené výzvy čakajúce na vyriešenie:

- **Obmedzenie výkonnosti pri práci v reálnom čase** – Vyvinutý NIDS by mal v ideálnom prípade v reálnom čase zachytiť a skontrolovať každý jeden paket podľa aktuálneho sieťového scenára pre vhodnú analýzu a presnú detekciu anomálie.
- **Zníženie falošného poplachu** – NIDS alebo iná metóda detekcie by sa mala vyhnúť vysokej miere hlásenia falošných útokov.
- **Redukcia dimenzie** – Vyvinúť vhodnú metódu na výber optimálneho súboru parametrov na detekciu anomálií bez znižovania výkonnosti detekcie.

- **Zvýšenie výpočtovej sily** – Na zvládnutie sofistikovanejších a komplexnejších vrstvených útokov sú mechanizmy na ochranu siete postavené na existujúcom systéme s pridruženými výpočtovými modulmi, ktoré v prípade rapídneho vývoja vysokorýchlostného internetu sú kontraproduktívne a môžu spôsobovať uviaznutia či zníženie výpočtovej sily.
- **Generický systém** – Platformovo nezávislý systém či metóda.
- **Spracovanie sofistikovaných anomálií** – Aktualizovanie NIDS alebo iných detekčných metód na aktuálne anomálie, ktoré sa vyskytli v lokálnej sieti alebo na internete.

Garg a Maheshwari [16] ďalej uvádzajú:


- **Špecifickosť**: Po identifikácii útoku musia byť k dispozícii dostatočné podrobné informácie, aby sa dosiahla lepšia reakcia.
- **Škálovateľnosť**: Možnosť aplikovať na veľké a malé siete.
- **A priori informácie**: Táto vlastnosť potrebuje vopred informácie týkajúce sa potenciálnych útočníkov a ich stratégií.

Bhattacharyya a Kalita ďalej spomínajú otvorené výzvy v súvislosti so spracovaním útokov ako: prispôsobovanie sa novým útokom, detekcia a spracovanie veľkých útokov, odhalenie útokov útočiace na sieťovú infraštruktúru, ovládanie, resp. odolávanie útokom s vysokou mierou frekvencie a identifikovanie nových, vynaliezavých útokov.

Autori Bhattacharyya, Kalita a Liu a spol. [29] sa však zhodnú na rovnakom názore/závere, že nedostatok spoľahlivých a kvalitatívnych údajov je veľkou prekážkou v presnosti klasifikácie útoku. Väčšina dátových množín je neúplná, keďže množstvo systémov založených na anomáliách bolo testované na množine vytvorených údajov a tým pádom hodnotenie systému je obmedzené kvalitou údajov. Taktiež sa znižuje efektívnosť zhromažďovania údajov súvisiacich s bezpečnosťou v dôsledku duplicity údajov a veľkosti ich množstva. Dátovým množinám sa venujeme v kapitole 2.7 Dátové množiny.

2.2. Architektúra IDS

Tiwari a spol. [54] vo svojom článku opisujú štyri základné moduly, z ktorých sa skladá vnútorná štruktúra každého IDS. Tieto moduly sú nasledovné: kolekcia dát, výber vhodných atribútov, analýza, akcia (viď. obrázok č. 5).



Obrázok 5 – Funkcionality IDS [54]

1. **Kolekcia dát** – Modul pre vstupné dáta pre IDS. Dáta sú zbierané a ukladané do súboru pre ďalšiu analýzu.
2. **Výber atribútov** – Modul pre výber vhodných ohodnotených atribútov z dátovej množiny.
3. **Analýza** – Modul, ktorý pre pravidlami riadené IDS systémy analyzuje dáta a v prípade prichádzajúceho sieťového toku dát sú dáta porovnávané voči vzorom a podpisom. V prípade anomálnych IDS systémov je analyzované správanie sa siete a následne je aplikovaný matematický model.
4. **Akcia** – Modul definujúci reakciu na útok. Reakcia môže byť informatívna pre systémového/sieťového administrátora alebo aj samotný IDS systém (aktívny) môže rozhodnúť o akcii (napríklad zahodenie paketov).

[54] uvádzajú tri základné komponenty IDS: senzor, backend, frontend. Túto skutočnosť potvrdzuje aj práca autora Schaelicke a spol. [42], ktorí tvrdia, že senzor je častokrát implementovaný ako univerzálny počítačový systém so softvérom na detekciu narušenia siete. Samostatný systém môže byť hostiteľom databázy alebo podobného softvéru na zabezpečenie dlhodobého ukladania dát pre ďalšiu možnosť analýzy.

1. **Senzor** – Hlavnou funkciou tohto modulu je detekcia a report. Obsahuje rozhranie pre kolekciu dát a rozhranie pre sieťový manažment. Priebeh funkcionality senzora je nasledovný: senzor počúva na sieťovom rozhraní a ukladá zachytené dáta do buffer pamäte. Následne nástroj na detekciu analyzuje pozbierané dáta a spustí sa analýza sieťových protokolov. V tomto komponente prebieha aj detekcia podpisov a anomálií.

2. **Backend** – Predstavuje hlavnú funkcionálnu IDS. Každá senzorom zachytená udalosť je ukladaná do databázy a následne vyhodnocovaná, že aká akcia sa podnikne systémom.
3. **Frontend** – Modul predstavuje používateľské rozhranie a tzv. *Command & Control*. Údaje, udalosti a log zápisy z backend-u sa zobrazia v tomto komponente, kde používateľ ich môže manažovať.

2.3. Existujúce nástroje

Bhattacharyya a Kalita [8] vo svojej knihe opísali veľké množstvo (20) nástrojov na detekciu útokov alebo narušenia, ktoré identifikujú známe aj neznáme útoky pomocou štatistických metód, dolovania v dátach alebo softvérových prístupov. V nasledujúcom zozname opíšeme niektoré vybrané nástroje.

1. **Bro** – Voľne dostupný nástroj pre platformu Linux, ktorý pasívne monitoruje sieťovú prevádzku a snaží sa identifikovať narušenia siete v reálnom čase. Je schopný identifikovať útoky založené na podpisoch, útoky orientované na udalosti a niektoré nezvyčajné útoky. Umožňuje tiež sledovanie správania, viacvrstvovú analýzu, presadzovanie politík a činnosti pri registrácii paketov.
2. **Snort** – IDS je založený na ľahkých podpisoch, ktorý kontroluje návštevnosť protokolu TCP/IP s cieľom identifikovať narušenia siete na základe pravidiel funkcií a zhody obsahu.
3. **HIDE** – Hierarchický systém založený na anomáliách, vyvinutý pomocou štatistického modelovania a neurónových sietí. Skladá sa z niekoľkých úrovní, kde každá vrstva obsahuje niekoľko detektorov narušenia (*Intrusion Detection Agents* - IDA), ktoré sú IDS komponentmi, ktoré monitorujú činnosti hostiteľa alebo siete.
4. **CAD** – Používa dátovú štruktúru - stromy (*Change Aggregation Trees* - CAT) na detekciu distribuovaných záplavových útokov (DDoS) na úrovni toku. Hlavným cieľom je odhaliť náhle zmeny prevádzky vo viacerých sieťových doménach.
5. **MINDS** – Populárny nástroj založený na metódach dolovania v dátach. Využíva Netflow v. 5 na zbieranie dát zo sieťovej premávky pomocou nástrojov na odchyťovanie toku v sieti. Pred vyhodnotením anomálnej premávky sa tieto dáta prečistia od nezaujímavých dát, resp. vzorov sieťovej premávky. Systém na detekciu anomálií využíva outlier algoritmus, ktorý priradí jednotlivým sieťovým spojeniam anomálnu hodnotu, na základe ktorej sa vyhodnocuje podozrivá sieťová premávka.
6. **N@G** – Hybridný IDS s podporou odhaľovania útokov na strane klienta (host-based) a siete (network-based). Analyzuje premávku v reálnom čase na základe štatistických

technik na strane klienta. Zastrešuje kontrolu používateľského rozhrania a manažmentu dát. Podporuje ochranu Layerd Service Provider (LSP) Domain Name Server (DNS) a dokáže dynamicky aplikovať Access Control List (ACL) pre blokovanie sieťovej premávky, resp. útoku.

Po analýze existujúcich nástrojov na bezpečnosť sietí autori knihy [8] prišli k záveru, že:

- Väčšina existujúcich NIDS je závislý od viacerých vstupných parametrov používateľa a ich výkon je veľmi citlivý na tieto parametre.
- Takmer všetky NIDS na báze anomálií pracujú takmer v reálnom čase alebo offline. Navyše väčšina trpí veľkým počtom falošných poplachov.

Autori knihy [8] identifikovali nasledujúce nedostatky v existujúcich riešeniach vhodné na ďalší výskum:

- Vyvinúť detekčný systém útokov v reálnom čase pre útoky s nízkou a vysokou frekvenciou DDoS (Distributed Denial of Service) útokov bez ovplyvnenia používateľov alebo bežných služieb.
- Vyvinúť NIDS založený na detekcii útokov pomocou anomálií, ktorého schopnosť detegovať útoky závisí od minimálneho počtu užívateľských parametrov a je schopný zaobchádzať so známymi aj neznámymi útokmi v reálnom čase s minimálnym počtom falošných poplachov.

2.4. Spôsob vyhodnocovania IDS

Hodnotenie je dôležité pre pochopenie kvality použitého modelu alebo techniky. Na základe získaných hodnôt môžeme ladiť použitie parametrov v iteratívnom procese učenia sa, pre výber najpriateľnejšieho modelu alebo techniky z daného súboru modelov alebo techník. Preto existuje niekoľko kritérií na hodnotenie modelov a techník.

Podľa Schaelicke a spol. [42] výkon systému detekcie narušenia siete je charakterizovaný pravdepodobnosťou, že útok je detegovaný v kombinácii s počtom falošných upozornení. Rovnako dôležitá je však schopnosť systému spracovať prevádzku pri maximálnej rýchlosti, ktorú ponúka sieť s minimálnou stratou paketov. Významná strata paketov môže zanechať množstvo nezistených útokov a zhoršiť celkovú efektívnosť systému.

Autorka Bhardwaj [7] vo svojom diele uvádza, že pri klasifikačných problémoch je prirodzené merať výkon klasifikátora z hľadiska chybovosti. Klasifikátor predpovedá triedu každej inštancie ak je správne, počíta sa ako úspech, ak nie, tak ide o chybu. Miera chybovosti je len podiel chýb

vykonaných v celom súbore inštancií a meria celkový výkon klasifikátora. Najznámejšie metódy vyhodnotenia výkonnosti klasifikátora sú nasledovné:

- **Cross-validation** – Rozdelenie dátovej množiny na menšie celky (k podmnožín) pre odhad rizika každého algoritmu. Časť údajov (trénovacia vzorka) sa používa na tréning každého algoritmu a zostávajúca časť (validačná vzorka) sa používa na analýzu. To znamená, že jedna podmnožina k sa použije na testovanie a ostatné $k-1$ podmnožín na tréning. Tento postup sa opakuje pokiaľ sa nepoužije každá podmnožina k na test. Nakoniec sa výsledky testov skombinujú do výsledného odhadu a vyberie sa algoritmus s najmenším odhadovaným rizikom.
- **Holdout metóda** – Najjednoduchší druh krížovej validácie. Dátový súbor je rozdelený do dvoch skupín (trénovacia a validačná vzorka). Klasifikátor predpovedá výstupné hodnoty pre dáta v testovacej sade. Chybovosť klasifikátora sa spriemeruje v absolútnej hodnote a používa sa na vyhodnotenie modelu. Hodnotenie môže do značnej miery závisieť od toho, ktoré dáta skončia v trénovacom súbore a ktoré skončia v testovacom súbore dát. Preto výsledok vyhodnotenia môže mať vysokú mieru variability.
- **Random sub-sampling** – Táto metóda vychádza z predchádzajúcej metódy, ktorá sa môže opakovať niekoľko krát kvôli zlepšeniu odhadu výkonnosti klasifikátora. Nevýhodou tejto metódy je, že nemá žiadnu kontrolu nad tým koľkokrát sa každý záznam použije na testovanie a tréning.
- **K-fold cross-validation** – Metóda na vylepšenie Holdout metódy. Dátový súbor je rozdelený do k podmnožín a metóda holdout sa opakuje k -krát. Zakaždým, keď sa jedna z k podmnožín použije ako sada testov, tak ostatné podmnožiny $k-1$ sa zostavia tak, aby vytvorili tréningovú množinu. Potom sa vypočíta priemerná chyba vo všetkých pokusoch k . Nevýhodou tejto metódy je, že tréningový algoritmus musí byť opakovaný k -krát.
- **Leave-one-out** – K -násobná krížová validácia, pričom k sa rovná n , kde n je počet inštancií v dátovej množine. Testuje sa vždy iba na jednom zázname a ostatné slúžia ako trénovacia vzorka. Týmto spôsobom sa zabezpečuje tréning na najväčšej možnej vzorke dát. Výpočet priemernej chybovosti sa použije na vyhodnotenie modelu.
- **Bootstrap** – Záznam, ktorý sa vybral na tréning sa vloží naspäť do pôvodného súboru záznamov, tým pádom môže byť s rovnakou pravdepodobnosťou znovu vybraný.
- **Confusion matrix** – Binárny klasifikačný model klasifikuje každú inštanciu do jednej z dvoch tried: správna a chybová trieda. Z toho vyplývajú štyri možné klasifikácie pre každý prípad: skutočný pozitívny (*true positive* - TP), skutočný negatívny (*true negative* - TN), falošný pozitívny (*false positive* - FP) alebo falošný negatívny (*false negative* - FN). Tieto

štyri klasifikácie znázorňuje kontingenčná tabuľka, reps. Confusion matrix. (vid'. obrázok č. 6).

		Actual Values	
		Positive (1)	Negative (0)
Predicted Values	Positive (1)	TP	FP
	Negative (0)	FN	TN

Obrázok 6 – Confusion matrix [7]

Vysvetlenie klasifikácií:

- **TP** – Predpovedáme triedu 1, zatiaľ čo skutočná trieda je 1. To znamená, že správne predpovedáme, že trieda je pozitívna.
- **FP** – Predpovedáme triedu 1, zatiaľ čo skutočná trieda je 0. To znamená, že nesprávne predpovedáme, že trieda je pozitívna.
- **FN** – Predpovedáme triedu 0, zatiaľ čo skutočná trieda je 1. To znamená, že nesprávne predpovedáme, že trieda je negatívna.
- **TN** – Predpovedáme triedu 0, zatiaľ čo skutočná trieda je 0. To znamená, že správne predpovedáme, že trieda je negatívna.

Z matice môže odvodiť rad ďalších výkonnostných metrík modelu:

- **Presnosť** (precision) – je pomer správne predpovedaných pozitívnych pozorovaní k celkovým predpokladaným pozitívnym pozorovaniam a počíta sa nasledovne:

$$\text{Presnosť} = \frac{TP}{TP + FP}$$

- **Odvolanie** (recall) – je pomer správne predpovedaných pozitívnych pozorovaní ku všetkým pozorovaniam v skutočnej triede a počíta sa nasledovne:

$$\text{Odvolanie} = \frac{TP}{TP + FN}$$

- **F1-skóre** (F1-score) – je vážený priemer presnosti a spätného volania. Toto skóre berie do úvahy falošne pozitívny aj falošný negatív a počíta sa nasledovne:

$$F1 - \text{skóre} = \frac{2 * (\text{Odvolanie} * \text{Presnosť})}{\text{Odvolanie} + \text{Presnosť}}$$

- **Správnosť** (accuracy) – predstavuje pomer správneho predpovedaného pozorovania k celkovým pozorovaniam a počíta sa nasledovne:


$$\text{Správnosť} = \frac{TP + TN}{TP + FP + FN + TN}$$

Receiver Operating Curves (ROC) intuitívnejším a robustnejším spôsobom vizuálne sprostredkúva rovnaké informácie ako confusion matrix. ROC je dvojrozmerný graf, ktorý vizuálne zobrazuje výkonnostný a výkonový kompromis klasifikačného modelu. Pre skonštruovanie ROC krivky je potrebné zaviesť dve nové výkonnostné metriky: skutočná pozitívna miera (*True positive rate* - TPR), ktorej vzorec je rovnaký ako pre *odvolanie* a falošná pozitívna miera (*False positive rate* - FPR).

Táto metrika zodpovedá podielu negatívnych pozorovaní, ktoré sa mylne považujú za pozitívne vzhľadom na všetky negatívne pozorovania. Vzorec pre falošnú pozitívnu mieru je nasledovný:

$$\text{Falošná pozitívna miera} = \frac{FP}{FP + TN}$$

Grafy ROC sú konštruované vykreslením skutočnej pozitívnej miery proti falošne pozitívnej miere (viď. obrázok č. 7).



Obrázok 7 – ROC krivka [43]

Autori Zaman a Lung [61] vo svojej práci vyhodnotili výkonnosť siedmich techník strojového učenia na dátovej množine Kyoto 2006+ a zistili, že ROC je vhodnejšia na vyhodnotenie techník ako metriky presnosť, odvolanie a správnosť. Mieru presnosti modelu môžeme odvodiť zo zakrivenia ROC krivky. Čím je ROC krivka bližšie k ľavému hornému rohu, tým je vyššia celková presnosť modelu.

Podľa Bhardwaj [7] na výber zaujímavých pravidiel zo súboru všetkých možných pravidiel je možné využiť obmedzenia rôznych meradiel významu a prínosu. Najznámejšie sú:

- **Podpora (support)** – Vyjadruje pravdepodobnosť, ako často sa v súbore údajov objavuje sada položiek. Je definovaný ako podiel transakcií T v súbore údajov, ktoré obsahujú množinu položiek X .
- **Spôľahlivosť (confidence)** – Vyjadruje podiel tých inštancií, ktoré vyhovujú pravidlu $(X \Rightarrow Y)$ oproti tým, na ktoré sa dá aplikovať pravidlo X .

$$\text{conf}(X \Rightarrow Y) = \frac{\text{supp}(X \cup Y)}{\text{supp}(X)}$$

Na meranie účinnosti IDS bolo navrhnutých niekoľko metrík podľa Kumar [25]. Tieto metriky môžu byť rozdelené do troch tried a to, prahová (*threshold*), hodnotiaca (*ranking*) a pravdepodobnostná (*probability*) trieda.

Prahové metriky zahŕňajú mieru klasifikácie (*Classification rate* - CR), F-meranie (*F-measure* - FM) a náklady na príklad (*Cost per example* - CPE). Nie je dôležité, ako je blízka predikcia k prahovej hodnote, dôležité je ak je nad alebo pod prahovou hodnotou. Hodnoty prahovej triedy ležia v rozsahu 0 až 1.

Trieda hodnotenia zahŕňa FPR, detekčnú frekvenciu (*Detection rate* - DR), presnosť (*Precision* - PR), oblasť pod krivkou ROC (AUC) a schopnosť detekcie narušenia (*Intrusion detection capability* - CID). Tieto metriky merajú ako dobre sú inštalácie útoku usporiadané pred normálnymi inštaláciami a môžu byť interpretované ako súhrn výkonnosti modelu na všetkých možných prahoch.

Do triedy pravdepodobnosti patrí chyba strednej hodnoty (*Root mean square error* - RMSE). Hodnota RMSE leží v rozsahu 0 až 1. Trieda je minimalizovaná, keď sa predpovedaná hodnota pre každú triedu útoku zhoduje so skutočnou podmienenou pravdepodobnosťou, že táto trieda je normálna.

V prípade metód hodnotenia klastrovaním je vyhodnotenie oveľa náročnejšie. Jediný spôsob, ako realisticky vyhodnotiť klastrovanie je, že či sa výsledok zhľukovania v kontexte aplikácie ukáže ako užitočný. Klastrovanie možno vyhodnotiť z perspektívy dĺžky popisu pomocou princípu *Minimum Description Length* (MDL). Princíp MDL spočíva v tom, že najlepšia hypotéza pre daný súbor údajov je tá, ktorá vedie k najlepšej kompresii údajov. Technika klastrového učenia rozdeľuje tréningový súbor do k klastrov. Najlepšie klastrovanie podporí najefektívnejšie kódovanie.

2.5. Sieťové útoky

Podľa Liu a spol. [29] sieťový útok využíva diery v sieťovom systéme, v chybných protokoloch, v chybách hardvéru alebo softvéru a údaje sieťového systému pri neautorizovanom správaní. Sieťová komunikácia je v súčasnosti konfrontovaná so štyrmi druhmi bezpečnostných hrozieb: odpočúvanie informácií, prerušenie komunikácie, falšovanie správ a falšovania informácií. Ďalej sa tieto štyri typy útokov kategorizujú do dvoch kategórií a to, aktívne a pasívne útoky. Zachytávanie informácií je pasívny útok. Prerušenie komunikácie, manipulácia so správou, útok falšovania je aktívny útok. V súčasnosti predstavuje režim sieťového útoku viacero prostriedkov, voči čomu sa ľudia ťažko bránia. Tieto režimy by mohli byť rozdelené do štyroch kategórií: odmietnutie služby útoku, využitie typu útoku, zhromažďovanie informácií útoku, falošné informácie útoku. Potom sa môžeme zamerať na niekoľko základných útočných prostriedkov, ako je napríklad: IP Spoofing Attack, ARP Attack, UDP Flooding Attack, TCP SYN Flooding Attack, ICMP Flooding Attack atď.

Sheela a spol. [47] vo svojej práci uvádzajú, že IDS využíva rôzne techniky na detekciu vniknutí do počítačovej siete. Používa na detekciu útočníkov jednoduchú techniku alebo kombináciu techník. Tieto techniky zahŕňajú detekciu anomálií, detekciu zneužitia, monitorovanie cieľa a špionáž.

2.5.1. Detekcia anomálií

Podľa [47] táto technika uchováva normálne správanie počítačovej siete, ako sú informácie o sieťových paketoch, informácie o softvéri, systémové log udalosti, informácie o operačnom systéme, informácie o jadre operačného systému (kernel) atď. Ak sa deteguje rozdiel vo vyššie uvedených parametroch, tak sa zistí anomália a vygeneruje sa alarm. Detekcia anomálií je užitočná pri zisťovaní podvodov, vniknutí do siete a pri iných nezvyčajných činnostiach v systéme. Detekcia anomálie je označovaná aj ako detekcia založená na správaní sa. Identifikuje odchýlky systému od normálneho správania. Táto metóda má schopnosť odhaliť nové a neznáme útoky analýzou údajov o audite.

Žiaľ, táto metóda má vysokú mieru falošného poplachu. Niekedy môže byť legitímne správanie systému klasifikované ako anomálne a označené ako útok.

2.5.2. Detekcia zneužitia

Podľa [47] táto technika ukladá sekvenciu vzorov, útočné signály, vzory narušenia atď. do databázy. Uložené udalosti zo systému sa porovnávajú s uloženými informáciami v databáze zistených útokov. Ak sa zistí zhoda, systém vygeneruje alarm. Keďže táto metóda porovnáva podpisy, niekedy sa označuje ako detekcia založená na podpisoch. Tieto techniky automaticky aktualizujú

svoju databázu na rôznych vstupných údajoch tak, aby zahŕňali nové typy útokov. Techniky detekcie zneužívania majú vysoký stupeň presnosti pri detekcii známych útokov a ich variantov. Tieto techniky však nedokážu zistiť neznáme/nové útoky, pretože sú závislé od existujúcich podpisov.

2.5.3. Monitorovanie cieľa

Podľa [47] táto technika hľadá modifikáciu na špecifických súboroch. Monitorovanie cieľa nehľadá anomálie. Funguje to ako korekčná kontrola, ktorá obnovuje súbor potom, čo bol súbor modifikovaný útočníkom. Využíva *cryptographic hash computing* na obnovenie upraveného obsahu. Táto technika je ľahko implementovateľná, pretože neustále sledovanie prevádzky správcom nie je potrebný. Posielanie alarmu do siete alebo do systému sa vykonáva vtedy, keď existuje nesúlad údajov (check sum). Výpočet check sum môže byť vypočítaný v rôznych intervaloch.

2.5.4. Špionáž

Podľa [47] táto technika deteguje útočníkov, ktorí zostávajú v sieti po dlhú dobu. Vo všeobecnosti útočníci dlhodobo kontrolujú zraniteľnosť systému a otvárajú porty a čakajú na ďalšiu dlhú dobu útoku. Táto technika kontroluje všetky takéto metodické útoky zhromažďovaním širokej škály údajov o celom systéme. Technika vyžaduje veľké množstvo vzoriek odobratých z rôznych počítačov a sietí na objavenie takýchto útokov. Na tento účel kombinuje detekciu anomálií a detekciu zneužitia.

2.5.5. Typy sieťových útokov

Autori Ananthi a Vengatesa [4] vo svojej práci vysvetľujú ako funguje jeden z najčastejších počítačových útokov, Denial of Service (DoS). V prípade DoS na zaplavenie servera paketmi (TCP/UDP) sa používa jeden počítač a jedno internetové pripojenie. Distributed DoS (DDoS) je botnet útok a je jedným z typov záplavového útoku. Počas tohto útoku sa útočné uzly pokúšajú naraz napadnúť jeden uzol (zvyčajne server). Namiesto jedného počítača a jedného internetového pripojenia využíva útok DDoS mnoho počítačov a mnoho pripojení. Počítače za takýmto útokom sú často distribuované po celom svete. Hlavným rozdielom medzi DoS a DDoS je, že cieľový server bude preťažený stovkami alebo dokonca tisíckami požiadaviek v prípade útoku DDoS. V dôsledku toho dochádza k pretečeniu pamäte a odmietnutiu poskytovanej služby (nemožno ďalej poskytovať danú službu). DoS ďalej vysvetľujú vo svojej práci autori Hussain a Mishra [20]. DoS je typ útoku, kedy útočník zahlučuje pamäťové prostriedky a tým pádom zabráni, aby slúžili legítimným sieťovým požiadavkám. Takto napadnutý systém odopiera užívateľom prístup k počítaču alebo iným službám poskytované počítačom. DoS útok je iniciovaný tromi spôsobmi:

1. Zneužívanie legitímnych vlastností počítača.
2. Zacielenie implementačných chýb.
3. Využitie nesprávnej systémovej konfigurácie.

Útočník po úspešnom dokončení útoku ďalej poskytuje iné (svoje) služby, ktoré sú nedostupné pre autentické použitie a sú založené na rovnakých princípoch ako DoS útok, napríklad: *apache, smurf, neptune, ping of death, back, mail bomb, UDP storm* atď. DoS je jedným z útokov ktorý klasifikuje aj dátová množina NSL-KDD, ktorej sa venujeme v kapitole 2.7 Dátové množiny.

Ďalšie známe útoky podľa [20] sú:

- **Remote to Local (R2L)** – Týka sa neoprávneného prístupu od vzdialeného počítača. Útočník útočí na vzdialene umiestnený počítač odoslaním paketov cez internet. Útok využíva privilégiá, ktoré by mal mať lokálny používateľ na počítači. Príklady takýchto útokov sú: *xlock, xnsloop, phf, sendmail, dictionary* atď.
- **User to Root (U2R)** – Je spojený s neoprávneným prístupom lokálnych privilégií super používateľa (root). Pri týchto typoch útokov útočník začína v systéme s bežným používateľským kontom so snahou zneužiť zraniteľné miesta v systéme na získanie privilégií super užívateľov. Príklady: *perl, Xtream* atď.
- **Probe** – Útočník skenuje počítač alebo sieťové zariadenia na odhalenie zraniteľných alebo slabých miest, ktoré sa neskôr môžu zneužiť, aby sa narušil systém. Táto technika je primárne spojená s dolovaním v dátach ako: *satan, saint, portsweep, mscan, nmap* atď.
- **Scan** – Podľa Al-Jarrah a Arafat [2] skenovanie portov sa pokúša objaviť spustené služby na hostiteľskom počítači alebo sa pokúsi overiť dostupnosť určitej služby. Je dobre známe, že každá sieťová aplikácia bežiaca na počítači má jedinečné číslo portu, na ktoré počúva, ako napríklad port 80 pre prehliadanie webu. Zistením, ktoré služby sú spustené môže byť spustený určitý útok proti objavenej službe. Techniky skenovania portov sú rozdelené do troch typov na základe portov a hostiteľov:

1. **Jeden hostiteľ – rôzne porty:** Útočník prehľadáva rôzne porty na určitom hostiteľovi, čo je typické správanie skenovania portov. Poradie portov nie je dôležité, skenovanie môže byť sekvenčné alebo náhodné.
2. **Rôzni hostitelia – jeden port:** Útočník prehľadáva viacero hostiteľov naraz s rovnakým číslom portu. Tento útok je spustený proti sieti hostiteľov, ktorí hľadajú hostiteľov, ktorí prevádzkujú určitú službu ako DNS, SMTP alebo HTTP.

3. **Rôzny hostitelia – rozdielne porty:** Útočník prehľadáva viacero hostiteľov naraz a každý hostiteľ je skenovaný iným portom. Toto je pokročilá technika skenovania portov, ktorá sa snaží skryť svoju aktivitu iniciovaním náhodných skenov portov medzi náhodnými hostiteľmi. Tento útok je najkomplikovanejším skenovaním portov.


Najznámejšie útoky na skenovanie portov sú: TCP scanning, ACK scanning, UDP scanning, FIN scanning, NULL scan, X-mas a UDP/ICMP Error a ďalšie.

- **Eavesdropping** [47] – Útočník monitoruje komunikáciu iných ľudí neautorizovaným spôsobom. To môže byť napríklad odpočúvanie telefónnych hovorov, prezeranie e-mailov a správ a ďalších internetových služieb. Odposluch je ťažké zistiť, pretože nemá vplyv na normálnu prevádzku siete. Keďže je ťažké odhaliť tento typ útoku, tak je vo všeobecnosti najväčším problémom, ktorému väčšina správcov čelí v podniku. Použitím silných šifrovacích schém môžu byť dáta chránené pred týmto typom útoku.
- **Man-in-the-Middle** [47] – Pri tomto útoku útočník zachytáva konverzáciu medzi dvomi stranami a vydáva sa za nich, čím získa prístup k dôležitým informáciám. Obe strany sa domnievajú, že spolu priamo komunikujú, aj keď útočník sa nachádza v strede ich konverzácie. Tento typ útoku je najčastejšou hrozbou pre online bezpečnosť, pretože útočníkovi je umožnené zachytiť a upraviť citlivé informácie v transakciách v reálnom čase. Útočník môže tiež zneužiť chyby zabezpečenia v konfiguráciách zabezpečenia siete.

2.5.6. Odhalenie sieťových útokov


Sieťový útok odkazuje na zneužitie chýb a nedostatkov v bezpečnostných nastaveniach siete, chybných protokolov, chybu v hardvéri alebo softvéri, násilný útok na hardvér alebo softvér či na údaje pri neautorizovanom správaní sa v sieťovom prostredí. V súčasnosti predstavuje sieťový útok viacero prostriedkov, voči čomu sa ľudia len ťažko bránia. Preto je potrebné vyvinúť obranný mechanizmus na ochranu sieťovej premávky voči škodlivej činnosti, tak ako aj autori článku Li a spol. [27].

Li a spol. navrhli sieťový modul detekcie útokov. Modul je založený predovšetkým na filtrovaní paketov. Rozpoznáva typ sieťového útoku a má aj funkcionality monitorovania siete, či funkciu upozornenia, ktorá nemá vplyv na výkon základnej sieťovej komunikácie. Na nasledujúcom obrázku č. 8 môžete vidieť návrh platformy na odhalenie sieťových útokov.




Obrázok 8 – Návrh platformy na odhalenie sieťových útokov [27]

Modul najskôr prijíma pakety na detekciu útoku, ktoré sú následne filtrované vo filtračnom module (Filter module). Potom podľa charakteristík útoku siete, sa analyzujú pakety. Vývojové prostredie sa skladá z troch počítačov (útočník, obeť a detektor), ktoré sú prepojené HUB-om, ako je znázornené na obrázku č. 9. Na detektore beží modul detekcie útoku. Tento spôsob spojenia je v súlade so skutočnou aplikáciou detekčného stroja, ktorý nebráni počítačom odosielať a prijímať dátové pakety. Pod inštaláciou operačného systému Linux je zabezpečená podpora raw socketov na zachytenie všetkých ethernet rámcov.



Obrázok 9 – Prostredie odhalenia útoku [27]

Na obrázku č. 10 je znázornená konštrukcia modulu na detekciu sieťových útokov, ktorá slúži predovšetkým na zachytenie dátových paketov, ich filtrovanie, robenie dátovej štatistiky a na odhalenie útoku.



Obrázok 10 – Štruktúra modulu na detekciu sieťových útokov [27]

2.6. Strojové učenie

Strojové učenie môže byť klasifikované mnohými rôznymi spôsobmi, ale najčastejšie sa rozlišuje strojové učenie pod dohľadom a bez dohľadu. Strojové učenie pod dohľadom je potrebné naučiť na sade príkladov pre danú problematiku, pričom strojové učenie bez dohľadu dokáže sa sám naučiť vzory z poskytnutých údajov bez akéhokoľvek ľudského zásahu alebo poradenstva.

Bhattacharyya a Kalita [8] vysvetľujú, že strojové učenie s dohľadom sú metódy prediktívneho modelu pre normálne a anomálne triedy, kedy model porovnáva dátové inštancie s modelom pre určenie do ktorej triedy patrí. Na rozdiel strojové učenie bez dohľadu predpokladá, že normálne prípady sú oveľa častejšie ako anomálne prípady a anomálne prípady sú štatisticky odlišné od bežných prípadov. Avšak ak tieto predpoklady nie sú pravdivé, tak takéto metódy vyhodnocovania trpia vysokými falošnými poplachmi.

Strojové učenie s dohľadom:

- Rozhodovacie a regresné stromy
- Klasifikačné a regresné stromy (CART)
- Podporné vektorové stroje (SVM)

Strojové učenie bez dohľadu:

- Algoritmy hierarchického zhľukovania
- Algoritmy zhľukovania založené na hustote
- Modulárne algoritmy
- Softvérové algoritmy založené na soft computingu

V prípade strojového učenia bez dohľadu existuje mnoho ďalších typov, ktoré sme vyššie nezahrnuli napríklad: Skryté Markov modely, Algoritmus maximalizácie očakávaní, Soft computing, Rough sets, Evolučný algoritmus a ďalšie.

[8] NIDS systém vyžaduje ľudský zásah vo vytvorení, overení a nasadení pravidiel. Na riešenie tohto problému boli zavedené NIDS s anomáliami, ktoré používajú algoritmy strojového učenia. Problém falošných poplachov však stále postihuje väčšinu takýchto systémov. Preto vhodná kombinácia metód strojového učenia pre túto problémovú oblasť môže viesť k lepšiemu rozvoju NIDS.

Na využití umelej inteligencie (UI) – neurónových sietí v prostredí počítačových sietí, konkrétne pre IDS sa zhodnú aj autori článku [28], Li a Dong. Tvrdia, že UI má mnoho užitočných vlastností ako: paralelizmus, vysoký stupeň tolerancie voči chybám, seba-reguláciu, seba-poznávanie a silné nelineárne mapovanie a zovšeobecnenie pre komplexný systém.

2.6.1. Klasifikačné algoritmy

Na detekciu anomálií sa vo všeobecnosti používajú algoritmy strojového učenia. Tieto algoritmy vytvárajú model detekcie alebo predikčný model vo fáze učenia sa pomocou tréningového algoritmu na tréningových dátach. Tento predikčný model sa potom testuje na nových údajoch v testovacej fáze. Vstupné dáta potrebujú predspracovanie, aby boli zrozumiteľné pre algoritmy strojového učenia. Vstupné údaje predstavujú pozorovania alebo záznamy, a každý záznam je reprezentovaný atribútom.

Algoritmy, ktoré vyžadujú plne označené údaje, sa nazývajú dohliadané algoritmy učenia. Algoritmy, ktoré nepotrebujú označené údaje sa nazývajú algoritmy učenia bez dozoru. Tieto algoritmy nájdu skrytý vzor v údajoch, keďže dokážu nájsť vzťah medzi údajmi a ich triedou. Poslednou klasifikáciou algoritmov strojového učenia sú čiastočne dohliadané algoritmy, ktoré nepotrebujú všetky záznamy, aby boli označené.

Nasledujúci zoznam podľa Jain a Bhupendra [21] uvádza niektoré klasifikačné algoritmy na odhalenie sieťových útokov:

- **K-means** – Na vyriešenie hlavného problému klastrovania je algoritmus K-means najbežnejší a najjednoduchší algoritmus učenia sa bez dozoru. Rozdeľuje n pozorovaní do k klastrov, každé pozorovanie patrí do klastra s najbližším priemerom a slúži ako prototyp klastra. Výsledkom je rozdelenie dátového priestoru do Voronoiho buniek.
- **Bayesovské siete** – Používajú sa na vyjadrenie poznatkov o nejednoznačnej doméne súboru údajov. Pravdepodobnostné závislosti medzi zodpovedajúcimi náhodnými premennými sú reprezentované hranami tohto modelu. Uzly reprezentujú premenné a hrany kódujú

podmienené závislosti medzi premennými. Bayesovské siete sú riadené acyklické grafy (*Directed Acyclic Graphs* - DAG). Stav náhodnej premennej a tabuľka podmienenej pravdepodobnosti (*Conditional Probability Table* - CPT) sa nachádza v každom uzle.

- **J48** – Voľne dostupný klasifikátor algoritmu C4.5. C4.5 je program, ktorý vytvára rozhodovací strom založený na súbore označených vstupných údajov. Rozhodovacie stromy sa môžu použiť na klasifikáciu, a preto sa C4.5 často označuje ako štatistický klasifikátor. Podľa Mehmood a Rais [30], rozhodovací strom závisí od atribútov v tréningových dátach, pretože z nich pracuje na základe získaných informácií. Koreňový uzol (root) obsahuje funkciu, ktorá má najviac informácií. Algoritmus J48 je navrhnutý s tými funkciami, ktoré ľahko riešia medzery, ktoré sú prítomné v ID3.
- **ID3** – Dohliadaný algoritmus, ktorý využíva rozhodovací strom založený na matematických výpočtoch. Vykonáva zhora nadol greedy vyhľadávanie prostredníctvom danej tréningovej množiny na testovanie každého atribútu v každom uzle, na vytvorenie rozhodovacieho stromu.
- **NB Strom** – Vysoko škálovateľný hybridný prístup pre veľké databázy. Je vhodný pre prípady, keď je pre klasifikáciu mnoho relevantných atribútov. V takýchto prípadoch je databáza veľká a je žiaduca interpretovateľnosť klasifikátora, atribúty nie sú nevyhnutne nezávislé (t.j. atribúty nie sú podmienené nezávislé). NB strom výrazne zlepšuje výkonnosť svojich zložiek indukciou vysoko presných klasifikátorov.
- **Náhodný les** – Po anglicky Random Forest je jedným z algoritmov klasifikácie stromov. Hlavným cieľom tohto algoritmu je zvýšiť klasifikátory stromov na základe koncepcie lesa. Náhodné klasifikátory lesov majú akceptovanú mieru presnosti a môžu byť implementované na spracovanie hodnôt šumu súboru údajov. Počas klasifikácie nie je proces opätovnej modifikácie. Pri implementácii tohto algoritmu by sa mal počet stromov v lese odhadnúť, pretože každý jednotlivý strom v rámci lesa predpovedá očakávaný výstup. Potom sa použije technika hlasovania, ktorá sa používa na výber očakávaného výstupu. Náhodný les je pomalý v tréningu, je náchylný pretrénovaniu a taktiež je príliš jednoduchý pre komplexné problémy.
- **Rozhodovacie stromy** – Jednotkové stromové štruktúry, ktoré predstavujú rozhodovacie súbory. Tieto súbory generujú pravidlá, ktoré sa používajú na klasifikáciu údajov.
- **Support Vector Machine** – Nová generácia učiacich sa algoritmov. Používa sa na klasifikáciu a regresiu. SVM sú v popredí v oblasti strojového učenia vďaka dôsledným matematickým základom z optimalizácie a teórie štatistického učenia. Podľa [30] SVM oddeľuje triedy pomocou hyper plánu a používa údaje označené triedou v tréningovej fáze rovnako ako ostatné klasifikačné algoritmy učenia pod dohľadom. Aj keď SVM je binárny

klasifikátor, môže byť použitý aj na klasifikáciu viacerých tried. Na klasifikáciu viacnásobných tried sa používajú dve rôzne metódy, *one-vs-all* a *one-vs-one*.

- **Logistická regresia** – Podľa autora internetového článku Navlani [35], logistická regresia je štatistická metóda na predpovedanie binárnych tried. Výsledná alebo cieľová premenná má dichotomickú povahu, pričom dichotómia znamená, že existujú iba dve možné triedy. V našom prípade sa jedná o normálnu (0) alebo útočnú premávku (1).
- **Multi Layer Perceptone** – Mapuje množinu vstupných dát na vhodnú množinu výstupov. Je graf pozostávajúci z viacerých vrstiev, kde každá vrstva je plne pripojená k ďalšej. MLP využíva spätné šírenie (generalizácia), kontrolovanú výučbovú techniku pre tréning siete. Môže klasifikovať údaje, ktoré nie sú lineárne oddeliteľné.

Pri klasifikačných algoritmoch je dôležité brať do úvahy vhodný výber parametrov. Na nájdenie optimálnych hyperparametrov modelu sa používa *Grid-search*. Optimálny výber hyperparametrov zaručuje presnejšie predpovede modelu. Hyperparameter modelu je vlastnosť, ktorá je mimo modelu a ktorého hodnota sa nedá odhadnúť z údajov. Hodnota hyperparametru sa musí nastaviť pred začiatkom procesu učenia.

Podľa Williamsa a spol. [58] na výber vhodných parametrov sa používajú algoritmy na báze konzistencie (*Consistency-based Feature selection* - CON) a na báze korelácie (*Correlation-based Feature Selection* - CFS). Tieto algoritmy hodnotia rôzne kombinácie funkcií na identifikáciu optimálnej podmnožiny.

- **Na báze konzistencie** – Vyhodnocuje podmnožiny parametrov a vyberie optimálnu podmnožinu. Optimálna podmnožina je najmenšia podmnožina parametrov, ktoré môžu identifikovať inštancie triedy rovnako konzistentne ako kompletná množina.
- **Na báze korelácie** – Používa hodnotiacu heuristiku, ktorá skúma užitočnosť jednotlivých parametrov spolu s úrovňou vzájomnej korelácie medzi vlastnosťami. Vysoké skóre je priradené k podmnožinám obsahujúcim atribúty, ktoré sú vysoko korelované s triedou a majú nízku vzájomnú koreláciu.

Podmnožiny parametrov podľa [58], ktoré sa majú vyhodnotiť sa generujú použitím nasledovných techník vyhľadávania podmnožín:

- **Greedy search** – Pre danú rodičovskú množinu skúša všetky možné potomkové podmnožiny prostredníctvom pridania alebo odstránenia parametrov. Potomková podmnožina, ktorá ukazuje najvyššiu mieru úspechu potom nahrádza nadradenú rodičovskú


podmnožinu a proces sa opakuje. Proces sa ukončí, keď už nie je možné vykonať ďalšie zlepšenia.

- **Best First search** – Je podobná predchádzajúcemu algoritmu, ale na rozdiel od Greedy, Best First search vytvára nové podmnožiny založené na pridaní alebo odstránení parametrov aktuálnej podmnožiny. Má však schopnosť spätne sa pohybovať pozdĺž cesty výberu podmnožiny, aby sa preskúmali rôzne možnosti, keď aktuálna cesta už nevykazuje zlepšenie. Aby sa predišlo spätnému šíreniu, obmedzuje sa počet nevylepšených podmnožín.

2.6.2. Neurónová sieť

Haddadi a spol. [18] tvrdia, že neurónová sieť je inšpirovaná ľudským nervovým systémom a používa sa v rôznych oblastiach, ako je rozpoznávanie vzorov, optimalizácia, riadenie a pod. Dokáže riešiť komplexné nelineárne problémy a výsledky hodnotenia sú presné na základe veľkého počtu parametrov, ktoré zvyšujú predvídateľnosť.

Neurónová sieť sa skladá z niekoľkých procesných jednotiek (uzlov) a riadených väzieb medzi nimi. Tieto spojenia reprezentujú vzťah medzi vstupnými a výstupnými neurónmi. Podľa Sani a spol. [39] výsledok transformácie je určený charakteristikami uzlov a váhami určenými pre prepojeniami medzi nimi. Teda nastavením váh môže byť výstup regulovaný. Proces aktualizácie váh a prahov sa nazýva učenie. Na obrázku č. 11 môžete vidieť jednoduchý neurón, kde parametre x_1 a x_2 predstavujú vstup, w_1 a w_2 váhy, u - prah, s - súhrnný blok, F - aktivačnú funkciu a y - výstup. V prípade ANN je potrebné si uvedomiť, že predtým ako začneme proces tréningu je potrebné zadať nastavenie neurónovej siete. Je potrebné určiť počet neurónov, počet vrstiev neurónovej siete, algoritmus a prenosovú funkciu pre tréning.




Obrázok 11 – Neurón [39]

Neurónová sieť je klasifikovaná do dvoch tried/architektúr na základe spojení: Feed-forward a Recurrent siete.

- **Feed-forward** – Podľa [18] a [39] neuróny sú usporiadané tak, že vstupy do prvej vrstvy neurónov sú vstupmi do neurónovej siete. Výstup každého neurónu v prvej vrstve je vstupom do každého neurónu v druhej vrstve a tak sa to opakuje vo všetkých nasledujúcich vrstvách,

až kým nedôjdeme k výstupnej vrstve, ktorej výstupy sú jediným výstupom neurónovej siete. Úlohou tréningového procesu je nájsť správne váhy pre neurónové spojenia, ktoré v kombinácii so vstupmi dosiahnu požadovaný výstup. Tento proces sa uskutočňuje algoritmom spätného šírenia. Na obrázku č. 12 môžete vidieť takúto neurónovú sieť.



Obrázok 12 – Feed-forward neurónová sieť [18]


- **Recurrent** – Sieť svoje výstupy vracia späť do vlastných vstupov.

Podľa Haddadi a spol. [18] IDS založené na neurónových sieťach trpia nasledujúcimi problémami:

- **Pretrénovanie** – Ak je neurónová sieť pretrénovaná časťou údajov. V takom prípade je len veľmi málo chýb v tréningu, ale vysoký podiel chýb v teste, pretože neurónová sieť stráca schopnosť generalizácie.
- **Nedostatok pamäte** – Obrovské množstvo dát má za následok vysokú pamäťovú náročnosť. Neurónové siete trpia nízkou pamäťou vo fáze tréningu. Výber správnej tréningovej funkcie môže tento problém riešiť.
- **Réžia** – V zložitých neurónových sieťach je veľa výpočtov a to spôsobuje režijné náklady. Réžia rastie zložitou systémom.

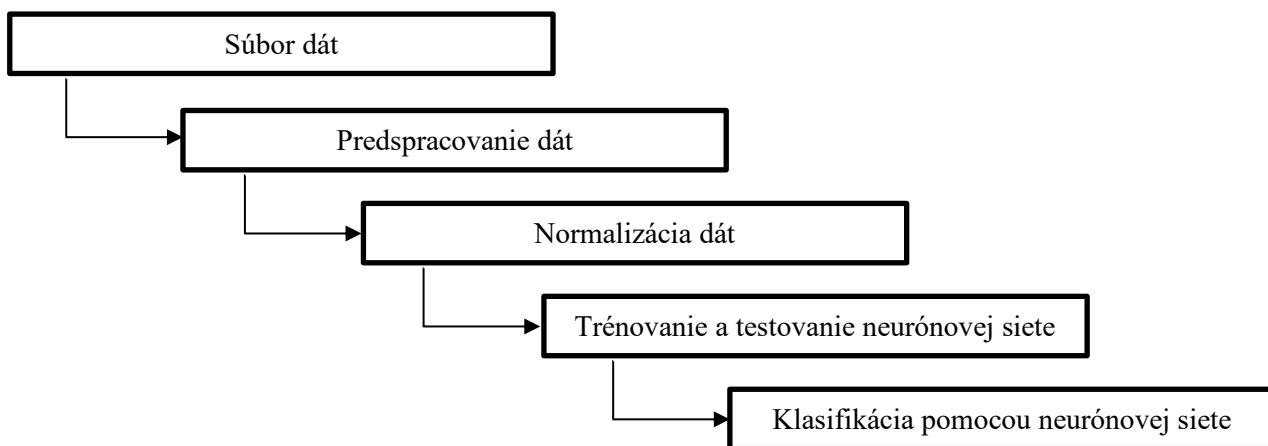
Typický model neurónovej siete pre IDS je znázornený na obrázku č. 13. V tomto modeli je predpoklad, že prichádzajúce pakety sú extrahované pomocou ľubovoľne dostupnej metódy. Pre tréningovú fázu, máme dátovú množinu pre útočnú a normálnu premávku. Je potrebné poznamenať, že dátové súbory a vzdelávací modul neurónovej siete sú pripojené k modelu neurónovej siete z dôvodu výberu vhodnej metódy na tréningovanie. Pre každý tréningový cyklus je výstup porovnaný s očakávaným výstupom na validačnom module. Tréningovanie prebieha nepretržite, kým model neurónovej siete nie je plne natrénovaný. V niektorých IDS tréningovanie sa vykonáva pravidelne alebo nepretržite.

Pre vhodný návrh neurónovej siete je potrebné brať do úvahy predchádzajúce tri problémy (pretrénovanie, nedostatok pamäte, režia), ktorými trpia neurónové siete.



Obrázok 13 – Model neurónovej siete pre IDS [39]

Na nasledujúcom obrázku č. 14 môžete vidieť proces spracovania dátovej množiny a klasifikácie sieťových útokov.



Obrázok 14 – Proces klasifikácie sieťových útokov [39]

2.7. Dátové množiny

Dátová množina je súbor údajov. Najčastejšie dátový súbor zodpovedá obsahu jednej databázovej tabuľky, kde každý stĺpec tabuľky predstavuje konkrétnu premennú a každý riadok zodpovedá prvku z príslušného súboru údajov.

2.7.1. NSL-KDD

Dátové množiny Kanadského inštitútu pre kybernetickú bezpečnosť [10] sú používané na celom svete univerzitami, súkromným priemyslom a nezávislými výskumníkmi.

Dátová množina NSL-KDD je vylepšenou verziou starej dátovej množiny KDD'99. Revathi a Malathi [37] tvrdia, že až 75-78% záznamov tvorilo duplicitu v starej verzii KDD. Vykonal sa štatistická analýza tohto súboru údajov a zistili sa problémy, ktoré výrazne ovplyvňujú výkonnosť IDS a vedú k zlému hodnoteniu prístupov detekcie anomálií. Na vyriešenie týchto problémov sa navrhol nový súbor údajov - NSL-KDD, ktorý sa skladá len z vybraných záznamov z kompletného súboru údajov KDD.

Podľa inštitútu pre kybernetickú bezpečnosť v Kanade [10], NSL-KDD nezahŕňa nadbytočné duplicitné záznamy a tak výkon klasifikátorov nie je ovplyvnená metódami, ktoré majú lepšiu mieru detekcie na častých záznamoch. Inštitút ďalej uvádza, že počet vybraných záznamov z každej skupiny obtiažnosti je nepriamo úmerný percentu záznamov v pôvodnom súbore údajov KDD. V dôsledku toho, miery klasifikácie metód strojového učenia sa líšia v širšom rozsahu, čo znamená dosahovanie presnejších hodnotení pre rôzne metódy strojového učenia. Ďalej, počet záznamov v trénovacej a testovacej sade údajov sú primerané, čo umožňuje vykonávanie experimentov na kompletnom súbore dát, bez potreby náhodného výberu menšej časti. Výsledky hodnotenia experimentov tak budú konzistentné a porovnateľné.

Podľa [37] NSL-KDD sa skladá z 21 rôznych útokov z 37 prítomných v súbore testovacích dát. Známe typy útokov sú prítomné v súbore údajov pre trénovanie, zatiaľ čo nové útoky sú v súbore dát pre testovanie, t.j. nie sú dostupné v trénovacom súbore údajov. Typy útokov sú zoskupené do štyroch kategórií: *DoS*, *Probe*, *U2R* a *R2L*. Tabuľka č. 2 uvádza známe typy útokov.

Tabuľka 2 – Útoky v testovacom súbore dát NSL-KDD [37]

Trieda útoku	Typ útoku
DoS	Back, Land, Neptune, Pod, Smurf, Teardrop, Mailbomb, Processtable, Udpstorm, Apache2, Worm
Probe	Satan, Ipsweep, Nmap, Portsweep, Mscan, Saint
U2R	Guess_password, Ftp_write, Imap, Phf, Multihop, Warezmaster, Xlock, Xsnoop, Snmpguess, Snmpgetattack, Httpunnel, Sendmail, Named
R2L	Buffer_overflow, Loadmodule, Rootkit, Perl, Sqlattack, Xterm, Ps

Dhanabal a Shantharajah [10] vo svojej práci detailne opisujú jednotlivé atribúty dátovej množiny NSL-KDD a taktiež opisuje experiment v automatizovanom nástroji WEKA na dolovanie v dátach. WEKA implementuje mnoho štandardných procesov dolovania v dát, ako je čistenie, predspracovanie, klastrovanie, klasifikácia, regresia, vizualizácia a výber funkcií dát. Je použitý na vykonávanie klasifikačných experimentov na 20 percentnom NSL-KDD dátovom súbore. Dátový súbor sa predspracuje a normalizuje na rozsahu 0 až 1. Normalizácia dát je dôležitá, pretože niektoré klasifikátory poskytujú lepšiu mieru presnosti na normalizovanom súbore dát. Dhanabal a Shantharajah vo svojej práci použili metódu výberu atribútov na základe korelácie. Dimenzia atribútov sa znížila z počtu 41 na 6. Následne sa vykonala klasifikácia pomocou algoritmov J48, SVM a Naïve Bayes. Výsledky sú zaznamenané v tabuľke č 3.

Tabuľka 3 – Tabuľka výsledkov experimentu v nástroji WEKA [10]

Klasifikačný algoritmus	Názov triedy útoku	Presnosť (%)
J48	Normal	99.8
	DoS	99.1
	Probe	98.9
	U2R	98.7
	R2L	97.7
SVM	Normal	98.8
	DoS	98.7
	Probe	91.4
	U2R	94.6
	R2L	92.5
Naïve Bayes	Normal	74.9
	DoS	75.2
	Probe	74.1
	U2R	72.3
	R2L	70.1

Podľa Thomasa a Pavithrana [53] aj napriek tomu, že súbor údajov NSL-KDD trpí niektorými problémami, je veľmi efektívny súbor údajov, ktorý možno použiť na výskumné účely. Dnes je ťažké získať reálne súbory údajov vzhľadom na povahu bezpečnostnej domény, a preto súbor údajov NSL-KDD sa považuje za jeden z najlepších pre výskum detekcie anomálií.

2.7.2. UNSW-NB15

Podľa oficiálnej stránky [56] UNSW-NB15 je neupravený dátový súbor sieťových paketov vytvorený nástrojom IXIA PerfectStorm v laboratóriu Cyber Range v Austrálskom centre pre kybernetickú bezpečnosť (*Cyber Range Lab of the Australian Centre for Cyber Security - ACCS*). Bol vytvorený na generovanie bežného hybridu skutočných moderných činností a syntetického súčasného správania pri útokoch.

Na zachytenie sieťovej prevádzky vo forme paketov sa používa nástroj *tcpdump*. Tento nástroj sa použil na zachytenie 100 GB surovej dátovej prevádzky. UNSW-NB15 súbor údajov má 9 typov útokov: *Fuzzers*, *Analysis*, *Backdoors*, *DoS*, *Exploits*, *Generic*, *Reconnaissance*, *Shellcode* a *Worms*. Dátový súbor pozostáva z 2 540 044 záznamov a 49 atribútov/vlastností s označením triedy.

Podľa Moustafa a Slay [33] nástroj IXIA obsahuje všetky informácie o nových útokoch, ktoré sa priebežne aktualizujú zo stránky CVE (*Common Vulnerabilities and Exposures*). CVE je stránka/slovník verejne známych zraniteľností a ohrození bezpečnosti informácií.

Moustafa a Slay [32] opisujú päť kategórií, do ktorých sú jednotlivé vlastnosti dátového súboru začlenené:

- **Vlastnosti toku** – Zahŕňa atribúty medzi hostiteľmi.
- **Základné** – Zahŕňa atribúty, ktoré predstavujú protokoly.
- **Obsahové** – Zahŕňa atribúty TCP/IP, obsahuje aj niektoré atribúty HTTP služieb.
- **Časové** – Obsahuje časové atribúty, napr. čas príchodu medzi paketmi, čas návratu protokolu TCP.
- **Ďalšie** – Túto kategóriu možno ďalej rozdeliť do dvoch skupín:
 - **Funkcie všeobecného účelu** – Každá vlastnosť má svoj vlastný účel, podľa ochrany služby protokolov.
 - **Funkcie pripojenia** – Sú vytvorené z toku 100 záznamov pripojenia na základe poradia poslednej časovej vlastnosti.

Moustafa a Slay [31] navrhli sieťovú forenznú schému, kde prvý krok zachytáva sieťové pakety cez sniffing a ukladá zachytené pakety do databázy, aby sa uľahčilo vyšetrovanie útokov. Druhý krok vyberá dôležité funkcie a odstraňuje cudzie a redundantné informácie, ktoré by mohli negatívne ovplyvniť odhalenie útokov. Dôležité funkcie/atribúty sa vyberajú využívajúc štatistiku - chí-kvadrát. Tretí krok skúma útoky a ich pôvod pomocou novej techniky correntropy-variation. Výsledky sú zaznamenané v nasledujúcej tabuľke č. 4 (výsledky sú uvedené v percentách).

Tabuľka 4 – Tabuľka výsledkov pre sieťovú forenznú schému [31]

Typ útoku	Veľkosť vzorky		
	100 000	200 000	300 000
Normal	92.12	93.16	93.29
Analysis	88.26	89.45	90.22
DoS	95.71	95.13	97.55
Exploits	76.47	77.82	77.19
Fuzzers	64.33	65.23	66.28
Generic	83.56	87.52	88.87
Reconnaissance	58.38	59.24	60.32
Backdoors	54.42	71.23	72.42
Shellcode	65.76	66.48	65.98
Worms	45.82	45.92	48.87

Navrhnutá technika sa porovnala s tromi najmodernejšími prístupmi, a to technikami: podporného vektorového stroja (*Filter-based Support Vector Machine* - FSVM), multivariačnou korelačnou analýzou (*Multivariate Correlation Analysis* - MCA) a umelou metódou techniky imunitného systému (*Artificial Immune System* - AIS). Na základe porovnaní, sieťová forenzná schéma je lepšia, pokiaľ ide o presnosť a frekvenciu falošného poplachu. Forenzná technika poskytuje najlepšie výsledky, pretože odhaduje hodnoty correntropie¹ pre normálne a testované vzorky a následne identifikuje vzorky, ktoré sú viac ako dve štandardné odchýlky od priemeru normálnych vzoriek ako útoky.

2.7.3. ISCX

Podľa Kanadského inštitútu pre kybernetickú bezpečnosť [10] sa v ISCX zavádza systematický prístup na generovanie požadovaných súborov údajov. Základný princíp je založený na koncepcii profilov, ktoré obsahujú podrobné popisy útokov a abstraktné distribučné modely pre aplikácie, protokoly alebo sieťové entity nižšej úrovne. Vytvorí sa profily pre agentov, ktorí generujú reálnu prevádzku pre protokoly HTTP, SMTP, SSH, IMAP, POP3 a FTP. Agenti boli potom naprogramovaní tak, aby ich činnosť čo najúčinnejšie napodobnila aktivitu užívateľa. Útokové

¹ Correntropia [59] - Štatistické meranie, ktoré odhaduje podobnosť medzi dvoma alebo viacerými náhodnými premennými integráciou funkcie hustoty pravdepodobnosti pozdĺž hlavnej diagonály vektorového priestoru.

scenáre boli navrhnuté a vykonané tak, aby vyjadrili skutočné prípady škodlivého správania. Aplikovali sa v reálnom čase na fyzických zariadeniach prostredníctvom ľudskej pomoci.

Dátová množina UNB ISCX IDS 2012 sa skladá z označených sieťových záznamov, vrátane úplného paketového zaťaženia vo formáte *pcap*. Záznamy sú označené dvadsiatimi atribútmi a podľa Soheily-Khah a spol. [48] má dátová množina viac ako dva miliónov záznamov z čoho 2% dát predstavujú útok. Skladá sa zo sieťovej aktivity zaznamenávanú počas siedmich dní. Tieto aktivity predstavovali normálnu sieťovú premávku a útočnú (infiltrácie siete z vnútra, HTTP DoS, DDoS pomocou IRC Botnet a Brute Force SSH) a má nasledujúce charakteristiky:

- **Realistická sieťová prevádzka** – V ideálnom prípade súbor údajov by nemal vykazovať žiadne nežiadúce sieťové vlastnosti. Toto zabezpečuje jasnejší obraz o skutočných účinkoch útokov na sieť.
- **Označenie súboru údajov** – Táto charakteristika má obrovský význam pri hodnotení rôznych detekčných mechanizmov. Vytváranie súboru údajov v kontrolovanom a deterministickom prostredí umožňuje rozlišovať anomálnu aktivitu od normálnej sieťovej prevádzky.
- **Zachytenie celkovej sieťovej interakcie** – Tieto informácie sú nevyhnutné pre hodnotenie a správnu interpretáciu výsledkov.
- **Úplné zachytenie** – Sieťové záznamy sú vytvorené v kontrolovanom prostredí *testbed*, čím sa úplne odstráni obava týkajúca sa súkromia súvisiace so zdieľaním sieťových stôp, t.j. sa zachová prirodzenosť výsledného súboru údajov.
- **Rôzne scenáre narušenia** – Prostredníctvom vykonávania útočných scenárov a uplatňovania abnormálneho správania sa vytvoril rôznorodý súbor útokov na základe nedávnych trendov v bezpečnostných hrozbách.

Autori [48] píšú, že mnoho článkov ukázalo, že pokiaľ ide o heterogénne mnohorozmerné údaje, klasifikátor Náhodný les patrí medzi najúčinnnejšie metódy. Preto navrhli klasifikačnú metódu postavenú na spomínanom klasifikátore. Výsledky predspracovania K-menas metódy sú použité ako vstupné údaje pre klasifikátor Náhodný les.

Autori navrhli, aby toky boli klasifikované podľa ich aplikačnej vrstvy (HTTPWeb, SSH, FTP, ICMP atď.). Vzhľadom na to, že bežné prevádzkové modely sú odlišné v závislosti na aplikáciu alebo službu, je oveľa efektívnejšie postaviť detektor narušenia pre každú z týchto vrstiev. Vo svojej práci porovnávajú navrhovaný algoritmus detekcie narušenia algoritmami ako sú: SVM, algoritmus vyhľadávania najbližšieho suseda (Nearest Neighbor Search – NNS), Naïve Bayes, Rozhodovacie stromy, Neurónová sieť a Náhodný les. Porovnávala sa presnosť, miera detekcie, a frekvencia

falošných poplachov. V tabuľke č. 5 môžete vidieť výsledky porovnania na základe presnosti (accuracy). Hodnoty sú uvedené v percentách.

Tabuľka 5 – Tabuľka presností klasifikačných algoritmov pre ISCX IDS 2012 [48]

	SVM	NNS	Naïve Bayes	Rozhodovací strom	Neurónová sieť	Náhodný les	K-means a Náhodný les
HTTPWeb	98.99	99.70	98.04	99.89	99.02	99.88	99.91
SSH	99.47	99.90	99.22	99.87	99.89	99.89	99.98
ICMP	99.83	99.95	99.90	99.99	99.93	99.99	100.00
FTP	99.62	99.95	99.54	99.97	99.94	99.97	99.97
DNS	99.98	99.99	96.18	99.98	99.98	99.99	99.99

Na základe predchádzajúcej tabuľky je zrejmé, že metóda navrhnutá autormi [48] má najlepšie výsledky presnosti, potom nasleduje Rozhodovací strom a algoritmus vyhľadávania najbližšieho suseda.

2.7.4. Predspracovanie dát

Podľa Bahdwaj [6] údaje v surovom stave sú vysoko citlivé na šum, chýbajúce hodnoty a nekonzistentné rozdelenie. Kvalita údajov vo vysokej miere ovplyvňuje výsledky klasifikačných metód. Spracovanie údajov je jedným z najkritickejších krokov v procese dolovania v dátach, ktoré sa zaoberá prípravou a transformáciou pôvodného súboru údajov. Metódy predspracovania údajov sú nasledovné:

- **Čistenie dát** –Metóda založená na doplnení chýbajúcich hodnôt, vyhladení šumu v údajoch, identifikácii a odstránení vybočujúcich hodnôt (outliers) a riešení nezrovnalostí.

V dátových množinách reálneho sveta sa stále nájdu chýbajúce hodnoty. Ich korekcia je kľúčová, pretože žiadny model nedokáže pracovať s chýbajúcimi dátami, ktoré sú často označované ako NULL či NaN. Odstránenie celých stĺpcov či riadkov z dátovej množiny môže viesť k strate cenných dát, a preto takáto metóda spracovania chýbajúcich hodnôt nie je vhodná. Samozrejme ak máme dátovú množinu vo veľkosti viac sto tisíc záznamov, tak odstránenie dvoch, troch záznamov nemá žiadny vplyv, ale v prípade ak pracujeme s malou dátovou množinou napríklad dvesto záznamov pričom dvadsať percent zo všetkých záznamov

sú chýbajúce hodnoty, tak v takom prípade odstránenie záznamov s chýbajúcimi hodnotami nepripadá do úvahy.

V prípade doplnenia chýbajúcich hodnôt sa používajú nasledovné metódy:

- Vynechanie n-tice, ak chýba označenie triedy.
- Manuálne doplnenie hodnôt.
- Doplnenie globálnej konštanty (napr. „neznáme“).
- Doplnenie priemeru všetkých hodnôt.
- Doplnenie priemeru určitej triedy.
- Doplnenie najpravdepodobnejšej hodnoty.
- Predikcia chýbajúcich hodnôt na základe existujúcich hodnôt v rámci daného atribútu.

V prípade odstránenia šumu v údajoch sa používajú nasledovné metódy:

- Lineárna, viacnásobná lineárna regresia.
- Vybočujúce hodnoty možno identifikovať pomocou kombinácie počítačovej a ľudskej kontroly.
- Vybočujúce hodnoty môžu byť detegované klastrovaním, kedy podobné hodnoty sú usporiadané do skupín.

- **Transformácia dát** – Táto činnosť transformuje údaje do vhodnej formy pre metódy dolovania v dátach. Transformácia dát zahŕňať nasledujúce metódy:

- Normalizácia, t.j. transformácia údajov do rozsahu -1.0 – 1.0 alebo 0.0 – 1.0.
- Odstránenie šumu.
- Agregácia údajov.
- Zovšeobecňovanie údajov.

- **Redukcia dát** – Proces redukcie objemu alebo rozmerov (počet atribútov) súboru dát. Práca s redukovaným súborom údajov je efektívnejšia. Nasledujúci zoznam vymenúva niektoré metódy redukcie dát:

- Aplikovanie agregáčnych operácií pre údaje v konštrukcii dátovej kocky.
- Odstránenie nepodstatných, nerelevantných alebo nadbytočných atribútov.
- Zmenšenie veľkosti súboru údajov kompresiou, napríklad wavelet transformácia.
- Nahradenie alebo odhad údajov menšími alternatívnymi údajmi, ako sú parametrické metódy alebo neparametrické metódy (klastrovanie, vzorkovanie alebo použitie histogramov).

- Generovanie diskretizácie a konceptovej hierarchie, kde surové hodnoty údajov pre atribúty sú nahradené rozsahmi alebo vyššími koncepčnými úrovňami.
- **Spracovanie kategorických atribútov** – Kategorické hodnoty nadobúdajú diskkrétne hodnoty ako napríklad farba. Kategorické hodnoty sa ďalej rozdeľujú do dvoch podtried:
 - **Ordinálne kategorické atribúty** – Ordinálne hodnoty sa dajú zoradiť, napríklad: veľký, stredný, malý.
 - **Nominálne kategorické atribúty** – Nominálne hodnoty sa nedajú zoradiť.

V prípade transformácie kategorických atribútov na numerické sa používajú nasledovné metódy:

- **Mapovanie** – Slovník určujúci mapovanie kategorických hodnôt na numerické.
- **Label encoding** – Transformácia kategorický textových údajov na numerické - zrozumiteľné číselné údaje pre model.
- **One-Hot Encoding** – Enkóder zoberie stĺpce, ktoré obsahujú kategorické hodnoty a na základe unikátnych hodnôt vytvorí ďalšie stĺpce pre numerickú reprezentáciu kategorických hodnôt. Novovytvorené stĺpce majú hodnoty 0 alebo 1 na základe toho, ktorý riadok má danú kategorickú hodnotu.
- **Obohacovanie dát** – Podľa Hintona [19] obohacovanie dát je definované ako zlúčenie údajov z tretích strán z externého autorizovaného zdroja s existujúcou databázou údajov s cieľom vylepšiť údaje. Hinton ďalej uvádza, že obohacovanie dát má jednu kľúčovú podmienku, a to aktuálnosť dát, ktorá vedie k procesu obohacovania dát 24/7.

2.8. Zhodnotenie analýzy

V tejto kapitole sme sa venovali analýze danej problematiky. Analýzu problémovej oblasti pokladáme za kľúčovú, pretože sme sa dopracovali k podstatným výsledkom, ktoré pokladáme za potrebné k ďalšej práci na danej úlohe.

Podrobnejšie sme sa venovali typom systémom na detekciu narušenia siete. Popísali sme jednotlivé typy IDS z hľadiska nasadenia. Podrobnejšie sa venovať anomálne založeným detekčným systémom sme pokladali za dôležité, pretože takéto systémy majú schopnosť detegovať doteraz neznáme typy útokov. Potreba venovať sa týmto typom IDS je dôležitá, pretože v počítačových sieťach sa objavujú nové zraniteľné miesta a útoky sú čoraz sofistikovanejšie. Opísali sme jednotlivé charakteristiky IDS, pretože si myslíme, že je potrebné vedieť limity týchto detekčných systémov, ak chceme prispieť do tejto problémovej oblasti výsledkom našej práce. V krátkosti sme sa venovali architektúre detekčných systémov. Opísali vybrané existujúce nástroje na detekciu útokov alebo narušenia a na záver tejto sekcie sme opísali jednotlivé spôsoby vyhodnocovania IDS. Táto kapitola je veľmi dôležitou súčasťou analýzy, pretože vďaka nej dokážeme pochopiť kvalitu použitého modelu alebo techniky, ktorá sa použila pri klasifikácii.

Ďalej sme sa venovali analýze sieťových útokov. Keďže IDS využíva rôzne techniky na detekciu vniknutí do počítačovej siete, sme pokladali analýzu tejto oblasti taktiež za kľúčovú. Popísali sme jednotlivé typy sieťových útokov, proti ktorým budeme konfrontovaný aj v našej ďalšej práci. Vďaka naštudovanej literatúry sme zahrnuli do kapitoly sieťové útoky aj všeobecný proces odhaľovania sieťových útokov vo forme obranného mechanizmu.

Ďalšia kľúčová oblasť v rámci tematiky, ktorú táto práca rieši je strojové učenie. Klasifikačné algoritmy budú tvoriť jadro tejto práce, a preto analýza existujúcich algoritmov a podrobnejší popis najpoužívanejšej metódy – neurónová sieť je veľmi dôležitá.

Na záver sme zanalyzovali tri najpoužívanejšie dátové množiny. Opísali sme základné charakteristiky vybraných dátových množín. V tejto kapitole sa nám podarilo na základe preštudovanej literatúry uviesť výsledky experimentov citovaných autorov pre budúce porovnanie s našou prácou. Myslíme si, že takáto forma analýzy je lepšia z hľadiska možnosti porovnania sa voči existujúcim riešeniam nad vybranými dátovými množinami ako samotná analýza dátových množín bez údajov z experimentov. Ďalej sa nám podarilo spísať kroky potrebné pre prípravu dát, pred tým než ich použijeme ako vstup pre metódy dolovania v dátach. Príprava dát je dôležitou súčasťou pri získavaní údajov, pretože údaje v reálnom svete sú zvyčajne neúplné, obsahujú šum a sú nekonzistentné.

3. Špecifikácia požiadaviek

V tejto kapitole sú špecifikované funkcionálne a nefunkcionálne vlastnosti navrhovaného riešenia.

3.1. Funkcionálne požiadavky

Naším cieľom je vytvoriť dva programové moduly. Prvý programový modul je určený na spracovanie rozsiahlej množiny dát. Druhý programový modul je určený na odhalenie anomálnej sieťovej premávky prostredníctvom inteligentných metód strojového učenia. Obe programové moduly budú vhodným spôsobom dokumentovať svoj priebeh procesov. Výstupom modulov budú grafické vizualizačné prvky na vhodnú reprezentáciu výsledkov a súbory, ktoré vzniknú. Funkcie programových modulov budú pokrývať nasledujúce oblasti:

- Výber rôznych metód strojového učenia.
 - Programový modul strojového učenia umožní používateľovi vybrať metódu strojového učenia a následne spustiť klasifikáciu nad vybranou množinou predspracovaných dát.
- Výber dátovej množiny na základe typu predspracovania, na ktorú sa má aplikovať zvolená metóda strojového učenia.
 - Programový modul strojového učenia umožní používateľovi vybrať, nad akou dátovou množinou chce aplikovať vybranú metódu strojového učenia. Používateľ bude mať na výber sadu predspracovaných dátových množín.
- Zobrazenie parametrov vybranej metódy strojového učenia.
 - Programový modul strojového učenia umožní používateľovi zobraziť parametre vybranej metódy strojového učenia. Taktiež umožní tieto parametre škálovať.
- Vytvorenie výstupu klasifikácie v textovej aj grafickej podobe.
 - Programový modul strojového učenia zobrazí výstup klasifikácie po aplikovaní vybranej metódy strojového učenia nad vybranou dátovou množinou dát vo forme tabuľky, grafu a percentuálnej úspešnosti.
- Porovnanie rôznych metód strojového učenia.
 - Programový modul umožní porovnať metódy strojového učenia. Výsledok porovnania bude v podobe tabuľky.

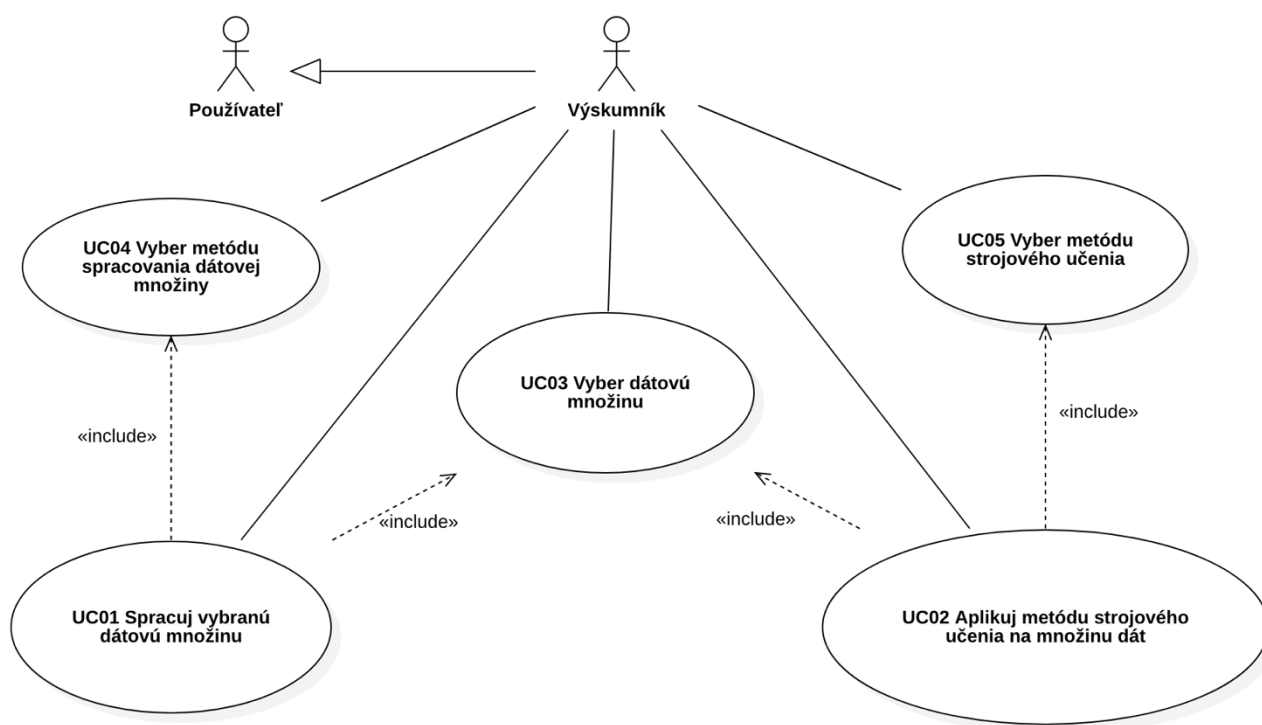
- Výber dátovej množiny na spracovanie.
 - Programový modul určený na spracovanie dátových množín umožní používateľovi vybrať nepredspracovanú dátovú množinu.
- Výber rôznych metód spracovania dátovej množiny.
 - Programový modul určený na spracovanie dátovej množiny umožní používateľovi vybrať metódu spracovania dátovej množiny a následne spustiť spracovanie nad vybranou množinou dát.
- Možnosť zobrazit' a uložiť proces spracovania dátovej množiny.
 - Programový modul určený na spracovanie dátovej množiny umožní uložiť proces spracovania dátovej množiny spolu s výstupmi jednotlivých krokov spracovania do dokumentu vo formáte HTML. Spracovanú dátovú množinu bude taktiež možné uložiť vo formáte CSV.
- Možnosť zobrazit' a uložiť proces programového modulu strojového učenia.
 - Programový modul strojového učenia umožní uložiť proces práce strojového učenia spolu s výstupmi jednotlivých krokov do dokumentu vo formáte HTML. Taktiež umožní uložiť model metódy strojového učenia vo formáte SAV pre opakované použitie.

3.2. Nefunkcionálne požiadavky

Navrhované riešenie bude implementované ako programový modul, a preto nebude mať používateľské rozhranie. Modul musí byť voľne prístupný pre verejnosť. Mal by využívať voľne dostupný úložný priestor pre ukladanie vzniknutých súborov. Taktiež musí byť zabezpečená vhodná dokumentácia. Spôsob ovládania modulu musí byť prehľadný a intuitívny pre používateľa a bez redundantných informácií. Ovládanie, nastavovanie parametrov a prístup k výstupom modulu nemôžu byť náročné, aby sa používateľ vedel rýchlo zorientovať a používať vytvorený programový modul.

3.3. Prípady použitia

Na obrázku č. 15 je zobrazený diagram prípadov použitia, ktorý vyplýva zo špecifikácie funkcionálnych vlastností programového modulu.



Obrázok 15 – Diagram prípadov použitia

Aktér:

- Výskumník – Osoba ktorá pracuje s programovým modulom.

3.3.1. Scenáre prípadov použitia

V tabuľkách č. 6 – 10 sa nachádza detailný opis jednotlivých prípadov použitia.

Tabuľka 6 – Scenár prípadu použitia spracuj vybranú dátovú množinu

Názov prípadu použitia	Spracuj vybranú dátovú množinu		
Identifikačné číslo	UC01		
Hlavný scenár	Umožňuje používateľovi spracovať vybranú dátovú množinu prostredníctvom výberu preddefinovanej metódy spracovania. Po dokončení spracovania dátovej množiny sa vygeneruje HTML dokument o priebehu spracovania dátovej množiny. Taktiež po dokončení spracovania dátovej množiny sa uloží spracovaná dátová množina vo formáte CSV.		
	Krok	Rola	Akcia
	1.	Používateľ	Vyberie dátovú množinu. Akcia je realizovaná prípadom použitia UC04 Vyber dátovú množinu.
	2.	Používateľ	Vyberie metódu spracovania dátovej množiny. Akcia je realizovaná prípadom použitia UC06 Vyber metódu spracovania dátovej množiny.
	3.	Používateľ	Spustí proces spracovania dátovej množiny.
	4.	Systém	Predspracuje dátovú množinu. Po dokončení sa vytvorí HTML dokument o priebehu spracovania dátovej množiny a CSV súbor spracovanej dátovej množiny a uloží sa na Google Drive úložisko.
	5.	Systém	Prípad použitia končí.

Tabuľka 7 – Scenár prípadu použitia aplikuj metódu strojového učenia na množinu dát

Názov prípadu použitia	Aplikuj metódu strojového učenia na množinu dát			
Identifikačné číslo	UC02			
Hlavný scenár	Umožňuje používateľovi aplikovať metódu/y strojového učenia na vybranú dátovú množinu. Po dokončení scenára sa vygeneruje HTML dokument o priebehu aplikovania strojového učenia, ktorý obsahuje aj výsledky hodnotení. Taktiež sa po dokončení scenára uloží model metódy strojového učenia vo formáte SAV. Používateľ v tomto scenári má možnosť porovnať vybrané metódy strojového učenia.			
	Krok	Rola		Akcia
	1.	Používateľ		Vyberie dátovú množinu. Akcia je realizovaná prípadom použitia UC04 Vyber dátovú množinu.
	2.	Používateľ		Vyberie metódu strojového učenia. Akcia je realizovaná prípadom použitia UC03 Vyber metódu strojového učenia.
	3.	Používateľ		Spustí sa proces odhalenia sieťových útokov pomocou inteligentných metód strojového učenia.
	4.	Systém		Vykonajú sa operácie strojového učenia nad vybranou množinou dát. Ak sa vybralo porovnanie metód strojového učenia z kroku č. 2, tak sa vykoná aj porovnanie. Po dokončení sa vytvorí HTML dokument o priebehu odhaľovania sieťových útokov a SAV súbor modelu metódy strojového učenia a uloží sa na Google Drive úložisko.
	5.	Systém		Prípad použitia končí.
Alternatívny scenár	Alternatívny scenár zabezpečuje prípad, kedy používateľ vyberie viac metód strojového učenia.			
	Od kroku	Do kroku	Rola	Akcia
	2a.	3.	Používateľ	Vybral viac ako jednu metódu strojového učenia.
			Systém	Zaeviduje potrebu porovnania metód. Po vykonaní porovnania sa vytvorí výstup v podobe tabuľky, ktorá zobrazí výsledok porovnania jednotlivých metód strojového učenia.

Tabuľka 8 – Scenár prípadu použitia vyber dátovú množinu

Názov prípadu použitia	Vyber dátovú množinu		
Identifikačné číslo	UC03		
Hlavný scenár	Umožňuje používateľovi vybrať dátovú množinu v rámci určeného typu dátovej množiny.		
	Krok	Rola	Akcia
	1.	Používateľ	Používateľ vyberie dátovú množinu zo zoznamu dátových množín.
	2.	Používateľ	Potvrdí výber.
	3.	Systém	Zaeviduje výber a prípad použitia končí.

Tabuľka 9 – Scenár prípadu použitia vyber metódu spracovania dátovej množiny

Názov prípadu použitia	Vyber metódu spracovania dátovej množiny		
Identifikačné číslo	UC04		
Hlavný scenár	Umožňuje používateľovi vybrať jednu z preddefinovaných metód spracovania vybranej dátovej množiny.		
	Krok	Rola	Akcia
	1.	Používateľ	Používateľ vyberie metódu spracovania vybranej dátovej množiny.
	2.	Používateľ	Potvrdí výber.
	3.	Systém	Zaeviduje výber a prípad použitia končí.

Tabuľka 10 – Scenár prípadu použitia vyber metódu strojového učenia

Názov prípadu použitia	Vyber metódu strojového učenia		
Identifikačné číslo	UC05		
Hlavný scenár	Umožňuje používateľovi vybrať metódu z množiny preddefinovaných metód strojového učenia, ktorá sa aplikuje na vybranú množinu dát s cieľom zistiť mieru úspešnosti odhalenia sieťových útokov.		
	Krok	Rola	Akcia
	1.	Používateľ	Používateľ vyberie metódu strojového učenia z množiny preddefinovaných metód.
	2.	Používateľ	Potvrdí výber.
	3.	Systém	Zaeviduje výber a prípad použitia končí.

4. Návrh riešenia

Na základe podrobnej analýzy anomálií, anomálne založených detekčných systémov a klasifikačných algoritmov, ktoré sa bežne používajú na detekciu anomálnej sieťovej premávky sme sa rozhodli vybrať práve tento smer, ktorým sa naša práca bude uberať.

V tejto kapitole navrhujeme dva programové moduly. Prvý programový modul bude slúžiť na predspracovanie dátovej množiny. Druhý programový modul bude implementovať rôzne metódy strojového učenia pre odhalenie útočnej/anomálnej sieťovej premávky nad predspracovanou dátovou množinou. Táto práca bude mať výskumný charakter z hľadiska hlbšej analýzy jednotlivých metód predspracovania dátovej množiny a metód strojového učenia, ktorým sa budeme podrobne venovať v jednotlivých kapitolách nižšie v tejto práci. Metódy strojového učenia implementujeme nad vybranou dátovou množinou s cieľom porovnať výsledky hodnotení a vyhodnotiť, ktorá metóda je pre aký typ problematiky sieťového narušenia najvhodnejšia. Zameriame sa predovšetkým na hľadanie anomálií v sieťovej premávke a na metódy, ktoré sú určené na ich odhaľovanie. Veľkým problémom a nedostatkom v tejto oblasti je vhodné nastavenie metód strojového učenia. Preto naša práca bude venovaná aj výskumu vhodných nastavení parametrov pre vybrané metódy. Ako bolo spomenuté aj v kapitole 2.6.2 Neurónová sieť, veľa závisí od nastavenia neurónovej siete, kde je potrebné určiť počet neurónov, počet vrstiev neurónovej siete, algoritmus a prenosovú funkciu pre tréning. Podobným spôsobom je potrebné určiť parametre aj pre ostatné metódy strojového učenia. Na základe rôznych nastavení a vstupov do metód dokážeme optimalizovať klasifikáciu a tým pádom pri vhodných nastaveniach dosahovať lepšie výsledky hodnotenia modelu.

Spomenuli sme vstupné dáta pre klasifikačnú metódu, ktoré sú taktiež kľúčové pre dosahovanie dobrých výsledkov. V tejto práci bude kľúčové vhodné predspracovanie vybranej dátovej množiny, a odhalenie závislostí medzi jeho atribútmi, ktoré majú značný vplyv na odhaľovanie útokov. Na základe konzultácii s vedúcim tejto práce budú vybrané metódy implementované na vybranej množine dát - UNSW-NB15, ktorej sme sa venovali v kapitole 2.7 Dátové množiny. Vybranej dátovej množine je potrebné dokonale porozumieť. Zanalyzujeme jednotlivé atribúty vybranej dátovej množiny a po absolvovaní dostatočnej analýzy dát a pochopení súvislostí medzi atribútmi predspracujeme a transformujeme dáta do formy vstupu pre metódy dolovania v dátach. Následne na základe analýzy spôsobu vyhodnocovania metód strojového učenia (viď. kapitolu 2.4 Spôsob vyhodnocovania IDS) vhodným spôsobom vyhodnotíme vybrané metódy a na základe výsledkov spíšeme výhody a nevýhody použitých metód. Výsledky použitých metód porovnáme a interpretujeme textovým aj grafickým spôsobom.

V tejto kapitole navrhнем aj vývojové prostredie vhodné na prácu s rozsiahlou množinou dát. Navrhнем také prostredie, ktoré podporuje dostatok výpočtového výkonu aj pre prácu s metódami strojového učenia.

Naším cieľom je, aby táto práca prispela svojim výsledkom v tejto problémovej oblasti tým, že spíšeme jednotnú analýzu vplyvov rôznych nastavení metód strojového učenia a rôznych spôsobov predspracovania vybranej dátovej množiny.

4.1. Vývojové prostredie

Rozhodli sme sa pre prostredie Google Colab, v ktorom sa budú programové moduly vyvíjať. Colaboratory je voľne dostupná cloudová služba, ktorá integruje prostredie Jupyter Notebook. Prostredníctvom prehliadača dokážeme spúšťať, ukladať a zdieľať svoje analýzy. Obrovskou výhodou tohto prostredia je dostupnosť k vysokým výpočtovým zdrojom. Google [55] uvádza, že tieto zdroje sú postavené na Tensor Processing Unit (TPU). Cloud TPU je stroj ASIC² navrhnutý na mieru, ktorý sprostredkuje produkty spoločnosti Google, ako sú prekladač, fotografie, vyhľadávanie, asistent a e-mail. Cloud TPU verzia 3 ponúka 420 TFLOPS³ a 128 GB pamäte s veľkou šírkou pásma (High Bandwidth Memory - HBM). Google Colab sa dá prepojiť aj s ďalšou službou od Google, a to s Google Drive úložným priestorom kam budeme ukladať samotné súbory programových modulov. Výstupy programových modulov sa budú ukladať vo formáte HTML, modely metód strojového učenia vo formáte SAV⁴ a v prípade dátových množín predspracované dátové množiny vo formáte CSV. Programový modul bude naprogramovaný programovacím jazykom Python vo verzii 3.

4.2. Programový modul predspracovania dátovej množiny

V prostredí Google Colab si založíme osobitný Jupyter Notebook, ktorý bude spracovávať rozsiahlu množinu dát. Bude obsahovať sekvenciu krokov potrebných na predprípravu dát, ktoré budú neskôr vstupom pre metódu strojového učenia vo forme tréningovej, validačnej a testovacej podmnožiny. Na úvod používateľ určí, ktorú dátovú množinu chce predspracovať a spôsob predspracovania. Navrhнем súbor metód predspracovania dátovej množiny na základe spomínaných metód predspracovania dátových množín, ktorým sme sa venovali v kapitole 2.7.4 Predspracovanie dát. Spôsoby predspracovania dátovej množiny sa budú líšiť iba v niektorých

² Application-Specific Integrated Circuit (ASIC) [5] - Mikročip určený na špeciálne použitie a nie na všeobecné použitie.

³ Floating-point Operations Per Second (FLOP) [14] – Jednotka výpočtového výkonu počítača, ktorá udáva počet operácií v pohyblivej rádovej čiarky za sekundu.

⁴ SAV [40] – Prípona súboru použitá pre uložený dátum Statistical Package for Social Sciences

krokoch. Pri výbere metódy predspracovania dátovej množiny sa určí, aký typ metódy sa má aplikovať pre daný krok predspracovania. Niektoré kroky predspracovania sa budú môcť vynechať. Toto neplatí pre kroky nevyhnutné pre predspracovanie dátovej množiny do akceptovateľnej podoby metódou strojového učenia. Tieto kroky sú nasledovné: načítanie, analýza a čistenie dát dátovej množiny. Metódy predspracovania dátovej množiny budú zahŕňať rôzne voľby ako: rôzne metódy doplnenia chýbajúcich hodnôt, spracovania kategorických atribútov, obohacovania dát, štandardizácie a vzorkovania. Výber metódy predspracovania dátovej množiny neimplementujeme v tejto fáze riešenia diplomového projektu.

V programovom module sa najskôr načíta vybraná dátová množina a následne sa spustí predspracovanie. Prvým krokom bude analýza dátovej množiny, kedy zistíme či dáta sú úplné, jednotné, či obsahujú chýbajúce hodnoty, redundantné informácie, nepotrebné atribúty, alebo vybočujúce hodnoty. Ďalej zistíme koreláciu jednotlivých atribútov dátovej množiny, ktorá je užitočná z hľadiska pochopenia vzťahov medzi atribútmi. V programovacom jazyku Python existuje mnoho metód na analýzu dát. My si vyberieme iba niektoré z nich. Na základe predošlej analýzy dokážeme vhodne aplikovať ďalšie metódy na predspracovanie dátovej množiny.

Ďalším krokom je čistenie dát. V tomto kroku musíme dbať na to aké dáta ideme meniť resp. dopĺňať, pretože akákoľvek zmena v množine môže mať neskôr veľký vplyv na výsledok vyhodnotenia metódy strojového učenia.

Vybočujúce hodnoty v prípade dátovej množiny tohto charakteru je riskantné odstraňovať, pretože práve v prípade extrémnych výkyvov v hodnotách jednotlivých atribútov dátovej množiny môže byť zaznamenaný útok resp. anomália. Samozrejme toto nie je pravidlo, taktiež sa môže stať, že pri vysokom výkyve, napríklad v počte prenesených byte-ov sa jednoducho iba posielala súbor s veľkou veľkosťou. Túto skutočnosť najjednoduchšie odhaľujú grafické metódy zobrazenia distribúcie hodnôt pre jednotlivé atribúty dátovej množiny počas analýzy dát.

V prípade korekcie chýbajúcich hodnôt v našom prípade máme viacero možností. Z hľadiska, že sa jedná o citlivé údaje v doméne sietí, aj malá zmena napríklad v počte prenesených byte-ov či dĺžke spojenia môže mať kontraproduktívny dopad. Pre čo najpresnejšie doplnenie chýbajúcich hodnôt sme sa preto rozhodli využiť regresiu t.j. strojové učenie určené na predpoveď hodnoty na základe ostatných známych hodnôt. Iným slovom povedané, regresia je určená na odhad hodnoty nejakej spojitej premennej. Táto metóda oproti metódam spomenutým v kapitole 2.7.4 Predspracovanie dát je najrelevantnejšia a najkomplexnejšia, ktorú potvrdzuje aj autor článku [24], Jimoh. Jimoh uvádza, že jedinou nevýhodou tohto prístupu je to, že ak neexistuje žiadna korelácia medzi atribútmi s chýbajúcimi údajmi a inými atribútmi v množine údajov, potom model pre predpovedanie chýbajúcich hodnôt bude skreslený. Na základe predošlej analýzy ale budeme vedieť predpovedať mieru skreslenia modelu. Skreslenie modelu následne dokážeme korigovať nájdením

optimálnych hyperparametrov modelu, ktorého výsledkom sú „presnejšie“ predpovede. V tomto prípade je potrebné si uvedomiť, že miera presnosti predpovede chýbajúcich hodnôt silno závisí od počtu existujúcich hodnôt, na ktorých sa dokáže model naučiť predikciu.

Ošetrovanie kategorických atribútov v dátovej množine je ďalšia diskutovaná oblasť procesu predspracovania množiny dát. Najskôr je potrebné si uvedomiť rozdiel medzi nominálnymi a ordinálnymi kategorickými atribútmi. Podľa autora Dhairya [12], najväčšiu chybu, ktorú väčšina ľudí robí, je to, že nie sú schopní rozlíšiť rozdiel medzi ordinálnymi a nominálnymi atribútmi. Podľa neho, ak použijeme funkciu mapovania alebo Label encoder s nominálnymi atribútmi, model si bude myslieť, že existuje určitý vzťah medzi nominálnymi atribútmi ako medzi kategorickými atribútmi. Takto získané výsledky nemusia byť najoptimálnejšie, ale na druhej strane takýmto štýlom vieme značne zredukovať dimenziu dátovej množiny. Myslíme si, že aj napriek tomu sa dá nájsť vhodný spôsob ako použiť mapovanie pre nominálne atribúty. Napríklad takým spôsobom, že zistíme aké nominálne atribúty sa vyskytujú pri útočnej sieťovej premávke a k nim priradíme mapovaním vyššie numerické hodnoty ako pre nominálne hodnoty pri normálnej neanomálnej sieťovej premávke. Tým pádom vznikne vzťah medzi nominálnymi atribútmi, ktorý model strojového učenia môže interpretovať tak, že tie nominálne atribúty, ktoré majú vyšší príznak majú väčšiu pravdepodobnosť výskytu pri útočnej sieťovej premávke.

V prípade úpravy hodnôt jednotlivých atribútov môže nastať situácia, kedy hodnoty jednotlivých atribútov sa vyvíjajú v takom smere, že vzniknú nové korelácie alebo dokonca vzniknú príliš vysoké korelácie. Tento fenomén sa nazýva multikolinearita. Podľa internetového článku [34] je multikolinearita stav veľmi vysokých vzájomných vzťahov alebo vzájomných súvislostí medzi nezávislými premennými. Ide teda o druh narušenia údajov. Ak sú v údajoch prítomné štatistické závery o údajoch tak nemusia byť spoľahlivé. Ďalej sa uvádza, že tento fenomén môže vzniknúť pri aplikovaní metódy One-Hot Encoding s čím súhlasí aj autor Dhairya. Multikolinearita môže vzniknúť aj vplyvom opakovania tej istej premennej rovnakého druhu či zahrnutím premennej, ktorá sa počíta z iných premenných. Multicollinearitu možno zistiť pomocou tolerancie a rozptylného inflačného faktoru (Variance Inflation Factor - VIF). Ak je hodnota tolerancie menšia ako 0,2 alebo 0,1 a súčasne hodnota VIF je 10 a vyššia, potom je multikolinearita problematická. Problémom odstraňovania multikolinearity sa zaoberá aj Frost [15] vo svojom článku.

Pokladáme za dôležité spomenúť aj proces obohacovania dát, ktorému sme sa venovali v kapitole 2.7.4 Predspracovanie dát. V našom prípade by sa jednalo o obohacovanie dát z hľadiska IP adries. Keďže dátová množina má zdrojovú a cieľovú adresu ako nominálnu hodnotu, tak dohľadanie krajiny IP adresy by nemal byť žiaden problém. Možný problém vidíme v špeciálnych IP adresách ako sú súkromné, multicast či localhost IP adresy. Tieto adresy sa dajú kategorizovať na základe rozsahu IP adresy. Po prekonvertovaní IP adresy na názov alebo kód krajiny alebo na jednu

z predchádzajúcich hodnôt, môžeme aplikovať mapovanie či One-Hot Encoding. Týmto spôsobom predspracovania IP adries dokážeme získať ďalší užitočný atribút, o ktorom môžeme s určitosťou povedať, že je relevantný pre metódu strojového učenia. Keďže určitú metódu dokážeme natrénovať na istej množine dát, tak tento model sa naučí klasifikovať známe IP adresy z danej množiny dát. V prípade nasadenia vybranej metódy strojového učenia do reálneho prostredia musíme IP adresy osobitne predspracovať v samostatnom module. Ako sme aj v analýze spomenuli, obohacovanie je proces, ktorý musí byť neustále aktuálny, a tak musíme myslieť na prípady resp. ošetriť také prípady, kedy sa IP adresa nedá predspracovať na základe existujúcej množiny dát tretej strany z dôvodu neúplnosti dát.

Ďalším možno štandardným krokom je štandardizácia, iným slovom normalizácia dátovej množiny. O tom, prečo je tento krok nevyhnutý píše autorka článku [21], Jaitley. Podľa autorky nie každá dátová množina vyžaduje normalizáciu hodnôt, tento proces je nevyhnutný iba vtedy, ak dátová množina má rôzne rozsahy hodnôt dát. Iným slovom, štandardizácia je systematický spôsob, ako zabezpečiť, aby bola dátová štruktúra vhodná na všeobecné vyhľadávanie bez určitých nežiaducich charakteristík. Po štandardizácii model strojového učenia lepšie dokáže „porozumieť“ dátam a dosiahnuť tak lepšie výsledky. Túto skutočnosť dokázala aj Jaitley vo svojom experimente. Tvrdí, že tento krok je potrebný pre dosahovanie lepších výsledkov.

Podľa Alencara [3] prevzorkovanie je všeobecne prijatá technika riešenia vysoko nevyvážených súborov dát. Vzorkovanie pozostáva z odstránenia vzoriek z väčšinovej triedy (under-sampling) a/alebo pridaním ďalších záznamov/vzoriek z menšinovej triedy (over-sampling). V prípade over-samplingu vznikajú ďalšie záznamy, aby sa vyrovnal počet vzoriek menšinovej triedy väčšinovej. Tým pádom nám vznikne viac záznamov a dátová množina sa zväčší čo môže mať dopad na čas učenia modelu strojového učenia, hlavne pri rádovo sto tisíc až milión záznamoch. Tento krok predspracovania dátovej množiny pokladáme za diskutabilný, pretože v reálnej prevádzke počítačovej siete nemáme rovnomerné zastúpenie normálnej a útočnej sieťovej premávky. Zvyčajne je množstvo normálnej, neútočnej sieťovej premávky viac ako desaťnásobne väčšie ako množstvo útočnej premávky. V našom prípade overíme oba prípady, t.j. klasifikáciu sieťovej premávky na prevzorkovanej množine dát a na množine dát bez vzorkovania.

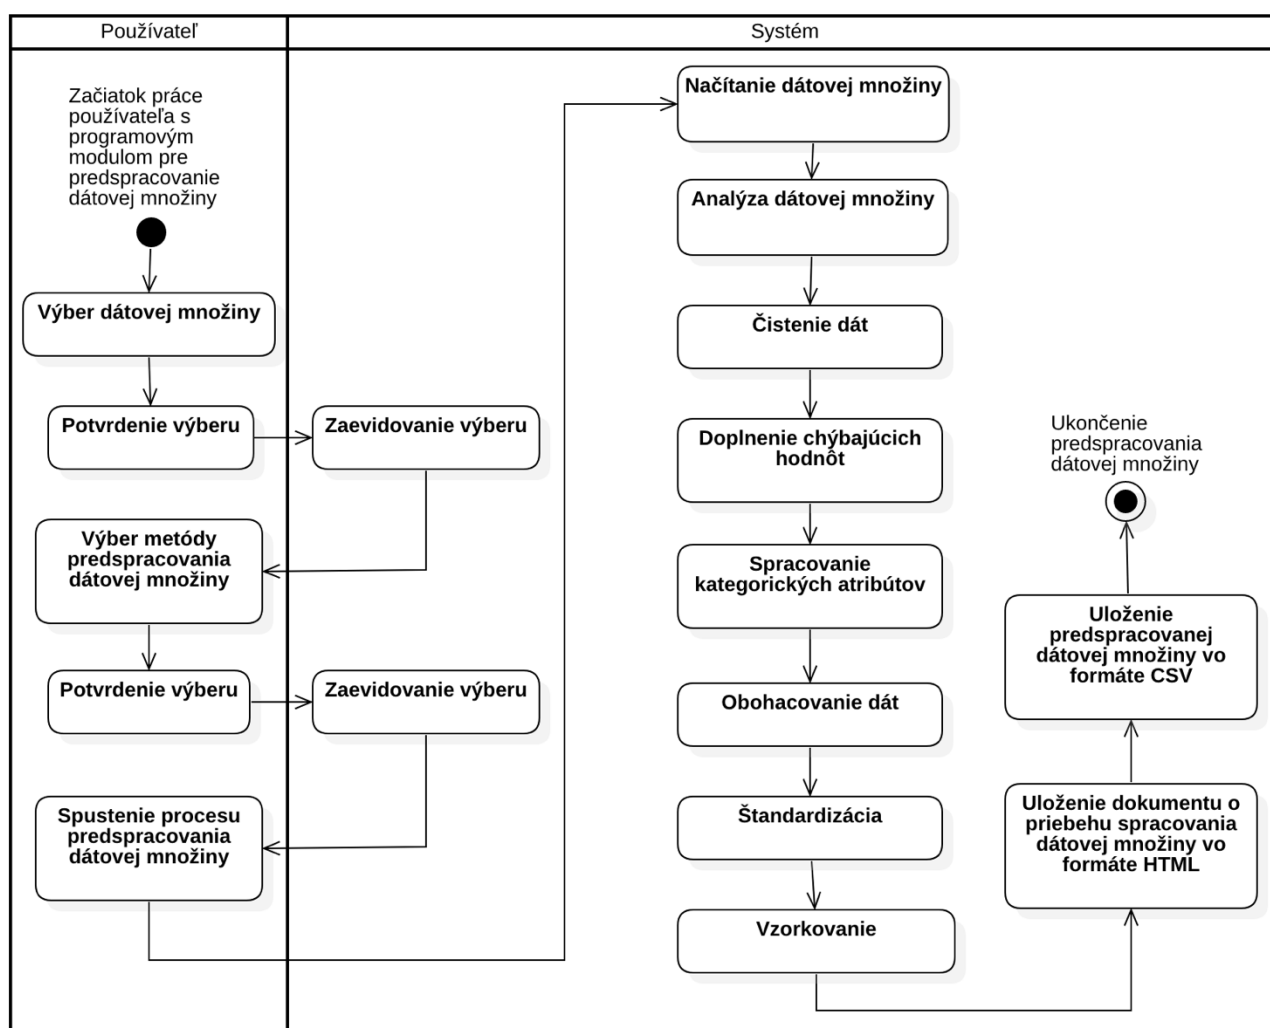
Na záver sa uloží správa o priebehu spracovania dátovej množiny vo formáte HTML. Predspracovaná dátová množina sa uloží vo formáte CSV. Výsledné dokumenty sa uložia na Google Drive úložisko.

4.3. Opis činností programového modulu predspracovania dátovej množiny

Diagram aktivít predspracovania dátovej množiny na obrázku č. 16 predstavuje proces spracovania vybranej dátovej množiny.

Používateľ inicializuje proces predspracovania výberom dátovej množiny a metódy predspracovania. Pri výbere metódy predspracovania sa určí, aký typ metódy sa má aplikovať pre daný krok predspracovania. Niektoré kroky predspracovania sa budú môcť vynechať. Toto neplatí pre kroky nevyhnutné pre predspracovanie dátovej množiny do akceptovateľnej podoby metódou strojového učenia ako bolo spomenuté aj v predchádzajúcej kapitole. Systém následne vykoná predspracovanie vybranej dátovej množiny sekvenciou krokov metód predspracovania.

Výsledkom je dokument vo formáte HTML, ktorý predstavuje správu o priebehu spracovania dátovej množiny. Predspracovaná dátová množina sa uloží vo formáte CSV. Výsledné dokumenty sa ukladajú na Google Drive úložisko.



Obrázok 16 – Diagram aktivít programového modulu predspracovania dátovej množiny

4.4. Programový modul strojového učenia

Po spracovaní dátovej množiny programovým modulom určeným na predspracovanie rozsiahlej dátovej množiny, ktorej sme sa venovali v kapitole 4.2 Programový modul predspracovania dátovej množiny môžeme postúpiť k metódam výpočtovej inteligencie strojového učenia.

V prostredí Google Colab si založíme osobitný Jupyter Notebook, pomocou ktorého nad množinou dát spustíme rôzne metódy strojového učenia. Tento osobitný programový modul je určený na vyhodnotenie úspešnosti predikcie odhalenia sieťových útokov. Bude obsahovať sekvenciu krokov potrebných na načítanie predspracovanej dátovej množiny. Taktiež bude podporovať zlúčenie viacerých dátových množín, ktoré sa spracovali rovnakou metódou predspracovania. Táto vlastnosť programového modulu je užitočná vtedy, keď chceme, aby model mohol použiť väčšie množstvo dát, na ktorých sa môže učiť.

V prípade ak je mierny rozdiel medzi dátovými množinami určenými na zlúčenie, treba tieto nezrovnalosti adekvátne vyriešiť. Takáto situácia môže nastať napríklad v prípade, ak sa v jednej dátovej množine nachádza nejaký nominálny atribút (stĺpec po predspracovaní One-Hot Encodingom), ktorý sa v druhej dátovej množine nenachádza. V takom prípade, používateľ musí rozhodnúť o ďalšom procese spracovania. Prvé riešenie spočíva v odstránení atribútu z dátovej množiny určenej na zlúčenie s ďalšou dátovou množinou, v ktorej sa daný atribút nenachádza. Túto metódu je vhodné aplikovať iba vtedy, keď daný atribút neovplyvní kvalitu dát. Tejto problematike sme sa venovali v kapitole 2.7.4 Predspracovanie dát, časť čistenie dát. Druhá metóda spočíva v tom, že sa daný atribút či atribúty sa doplnia do dátovej množiny, ktorá ich neobsahuje s neutrálnymi hodnotami.

Načítaná a spracovaná dátová množina sa potom pretransformuje na menšie časti: trénovacia podmnožina, validačná podmnožina a testovacia podmnožina dát. Autor Shah [45] vysvetľuje vo svojom článku rozdiely medzi jednotlivými podmnožinami:

- **Trénovacia podmnožina** – Vzorka údajov určená na učenie modelu.
- **Validačná podmnožina** – Vzorka údajov použitá na vykonanie nezáujatého vyhodnotenia modelu, ktorý bol naučený na vzorke trénovacích dát. Táto vzorka je určená predovšetkým na vyladenie hyperparametrov modelu, pričom *hyperparameter* je parameter, ktorého hodnota je nastavená pred začiatkom procesu učenia modelu.
- **Testovacia podmnožina** – Vzorka údajov použitá na objektívne vyhodnotenie konečného modelu, ktorý bol naučený na vzorke trénovacích dát.

Pred tým než sa spustí učenie modelu, používateľ bude môcť vybrať metódu strojového učenia. Výberom metódy sa určí, aké metódy/modely strojového učenia sa majú použiť, či sa majú

zlúčiť načítané dátové množiny, v akom pomere sa majú transformovať dátové množiny a akou metódou sa majú optimalizovať hyperparametre. Používateľ ďalej bude mať možnosť rozhodnúť sa, či chce učenie spustiť nad celou množinou dát so všetkými atribútmi alebo len nad určitou množinou atribútov, ktoré sa vyberú aplikovaním metódy na výber najlepších atribútov. Keďže chceme myslieť na dobu tréovania metódy strojového učenia, tak redukcia dimenzie predspracovanej dátovej množiny môže túto dobu výrazne ovplyvniť. S týmto záverom súhlasí aj autor Shaikh [46]. Podľa Shaikha výber najlepších atribútov má aj ďalšie výhody ako: zníženie pravdepodobnosti preučenia (overfitting), zvýšenie presnosti z dôvodu odstránenia nepodstatných atribútov, pretože nerelevantné alebo čiastočne relevantné atribúty môžu mať negatívny vplyv na výkonnosť modelu. Naivný prístup vedie k vyčítaniu dôležitých atribútov z korelačnej tabuľky, ale my aplikujeme vybranú metódu strojového učenia na ich výber.

V tejto fáze riešenia diplomového projektu sme neimplementovali možnosť výberu medzi viacerými metódami strojového učenia. Implementovali sme iba niektoré vybrané metódy.

Pred samotným učením modelu/ov strojového učenia je potrebné vybrať model/y ktoré sa majú natréovať a následne sa má vykonať vyhodnotenie miery úspešnosti modelu. V prípade ak používateľ zvolil viac ako jednu metódu, tak sa zvolené metódy strojového učenia porovnávajú a výsledok porovnania sa zapíše do tabuľky porovnaní. Týmto spôsobom získame sumár porovnaní metód strojového učenia, na základe ktorého môžeme ľahko odvodiť, ktorá metóda je najlepšia pre daný problém. Spôsobom vyhodnocovania sme sa venovali v kapitole 2.4 Spôsob vyhodnocovania IDS. Porovnanie metód strojového učenia sa neimplementoval v tejto fáze riešenia diplomového projektu.

Po nastavení predošlých nastavení môže prebehnúť proces tréovania metód strojového učenia. Pred každým tréovaním modelu strojového učenia navrhujeme optimalizáciu hyperparametrov. Je dôležité poznamenať rozdiel medzi parametrami modelu a hyperparametrami. Podľa Prabhu [36] parametre modelu sú vlastnosti údajov, ktoré sa model naučil sám počas tréovania. Tieto hodnoty môžu byť váhy jednotlivých spojení, odchýlky či rozhodovacie body v prípade rozhodovacích stromov. Hyperparametre zase riadia proces tréovania a nastavujú sa pred spustením samotného tréovania modelu. Každý model strojového učenia má vlastný súbor takýchto hyperparametrov a neexistuje jednotný, všeobecný návod na ich správne nastavenie. Existujú však metódy, ktorými dokážeme hyperparametre optimalizovať. Naším cieľom je aplikovať optimalizáciu hyperparametrov, jednou z existujúcich metód a kombináciou viacerých metód.

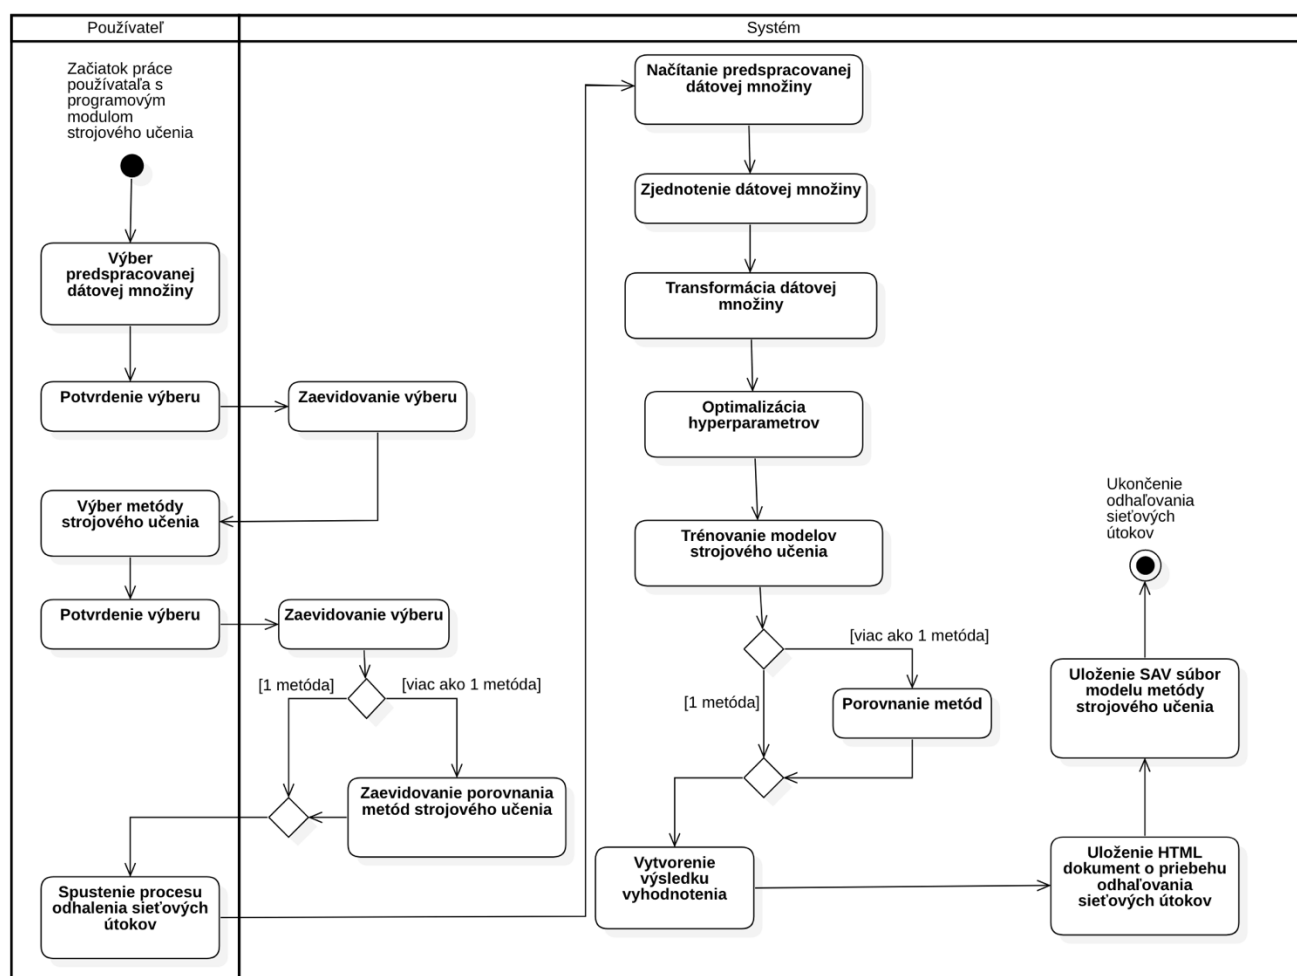
Výsledky metód strojového učenia interpretujeme vo forme percentuálnych úspešností, kontingenčných tabuliek a grafov.

4.5. Opis činností programového modulu strojového učenia

Diagram aktivít odhaľovania sieťových útokov pomocou metód strojového učenia na obrázku č. 17 predstavuje proces aplikácie metód strojového učenia na množinu predspracovaných dát, ktorá je výstupom programového modulu predspracovania dátovej množiny.

Používateľ inicializuje proces výberom predspracovanej dátovej množiny a metód/y strojového učenia. Pri výbere metódy strojového učenia sa zisťuje, či používateľ vybral jednu alebo viac metód. V prípade viacerých metód strojového učenia sa vykoná ich porovnanie po natrénovaní modelu strojového učenia. Výstupom je sumár porovnaní metód strojového učenia, na základe ktorého môžeme ľahko odvodiť, ktorá metóda je najlepšia. Ďalej sa vykoná súbor krokov, ktoré sú potrebné na predprípravu predspracovanej dátovej množiny pre model. Pred samotným tréновaním modelu je dôležité si všimnúť aktivitu optimalizácie hyperparametrov. Tento krok je kľúčový pre dosahovanie lepších výsledkov v odhaľovaní anomálnej sieťovej premávky.

Výsledkom je dokument vo formáte HTML, ktorý predstavuje správu o priebehu odhaľovania sieťových útokov. Model metódy strojového učenia sa uloží vo formáte SAV. Výsledné dokumenty sa ukladajú na Google Drive úložisko.



Obrázok 17 – Diagram aktivít programového modulu strojového učenia

5. Implementácia

Programové moduly, ktorým sme sa venovali v kapitole 4. Návrh riešenia sa nám podarilo plne implementovať na základe návrhu riešenia. Výsledná architektúra programových modulov vo fáze prototypu je zhodná s architektúrou, ktorú sme navrhli v kapitolách číslo 4.2 až 4.5.

5.1. Nastavenie vývojového prostredia

Podľa návrhu vývojového prostredia, ktorému sme sa venovali v kapitole 4.1 Vývojové prostredie sme spojzdnili vývojové prostredie v prostredí Google Colab. K tomu, aby sme mali prístup k súborom ako: dátové množiny, predspracované dátové množiny, Jupyter Notebook, knižnice a ďalšie súbory potrebné pre beh programových modulov sa musíme prihlásiť do úložného priestoru Google Drive cez náš Google účet pomocou aplikácie Google Drive File Stream. Toto prihlásenie zabezpečuje knižnica *google.colab.drive*. K autentifikácii je potrebné skopírovať do prihlasovacieho poľa unikátny kľúč, ktorý sa vygeneruje po pridelení súhlasu prístupu aplikácie Google Drive File Stream k súborom používateľa. Proces autentifikácie je spoločný pre oba programové moduly.

Ďalšou spoločnou črtou oboch programových modulov je nastavenie runtime typu na Python 3 a hardvérového urýchľovača na TPU. Nastavenie behu prostredia na vysokovýkonných zariadeniach od spoločnosti Google prebehne spustením kódu [55] určeným na správne rozpoznanie TPU zariadení. Tento kód pridáme do notebooku do novej bunky. Kód by mal vrátiť zoznam osem TPU zariadení dostupných v našom prostredí Colab.

Tím pádom máme pripravené vysoko výkonné výpočtové prostredie od spoločnosti Google, ktoré budeme využívať hlavne v prípade trénovania neurónových sietí, pretože TPU podporuje trénovanie iba vrstvových modelov ako je neurónová sieť.

5.2. Prototyp programového modulu predspracovania dátovej množiny

Pre prácu s vybranou dátovou množinou NSW-NB15 [56] ju najskôr potrebujeme stiahnuť do nášho Google Drive úložného priestoru, pretože programový modul je vybudovaný tak, aby pristupoval k zdrojom z Google Drive úložného priestoru. Ďalej je potrebné stiahnuť databázu GeoLite2Country [17], ktorá je bezplatná geolokačná databáza IP adries. GeoLite2 databázy v porovnaní s databázami GeoIP2 spoločnosti MaxMind sú menej presné. Databázu IP adries budeme potrebovať pri procese obohacovania dátovej množiny.

Programový modul je rozdelený do buniek, kde v každej bunke je časť kódu zodpovedajúca za vykonanie daného kroku predspracovania vybranej dátovej množiny.

Jednotlivé kroky programového modulu predspracovania dátovej množiny nájdete na diagrame aktivít na obrázku č. 16. Proces spracovania dátovej množiny opisujú kapitoly nižšie.

5.2.1. Načítanie dátovej množiny

Dátová množina vo formáte CSV sa načíta do dátovej štruktúry *DataFrame*. Zvyčajne dátové množiny neobsahujú hlavičku, ktorá predstavuje názvy jednotlivých atribútov/stĺpcov, a preto je potrebné zvlášť načítať atribúty a nastaviť ich ako hlavičku dátovej množiny.

5.2.2. Analýza dátovej množiny

V procese analýzy dátovej množiny najskôr zistíme základné informácie o dátovej množine, ako počet záznamov a počet atribútov. Metódou *describe* zobrazíme popisné štatistiky dátovej množiny, ktoré sumarizujú centrálnu tendenciu, rozptyl a tvar distribúcie. Táto metóda neberie do úvahy nominálne atribúty a hodnoty s hodnotou NaN. Z popisu dokážeme vyčítať počet záznamov, aritmetický priemer, smerodajnú odchýlku, minimálnu, maximálnu hodnotu a kvartáli, pričom päťdesiat percentný kvartál predstavuje medián. Tento popis je užitočný z hľadiska zistenia vybočujúcich hodnôt. V tejto fáze predspracovania analyzujeme dátovú množinu aj grafickým spôsobom, tzn. grafmi zobrazíme distribúciu hodnôt jednotlivých atribútov. Tento spôsob je taktiež vhodný na analýzu vybočujúcich hodnôt, kedy z grafu dokážeme vyčítať prah, od ktorej hodnoty vybočujú v porovnaní s rozložením väčšiny dát. Graf normálnej a útočnej sieťovej premávky nám dá prehľad o pomere počtov záznamov, ktorý zohľadníme neskôr pri otázke vzorkovania. Ďalšia metóda na analýzu dát je korelačná matica, ktorá farebne aj číselne určí mieru korelácie atribútov. Každá bunka v tabuľke zobrazuje koreláciu medzi dvomi atribútmi. Korelačná matica sa používa hlavne na zhrnutie údajov ako vstup do pokročilejšej analýzy. Na to, aby sme v ďalšom kroku vedeli vhodne aplikovať metódy na čistenie dát musíme najskôr zobrazit' počty unikátnych hodnôt pre jednotlivé atribúty. Tento spôsob odhalí to, aké hodnoty jednotlivé atribúty nadobúdajú a v akom počte. Tento prístup sa zväčša aplikuje na nominálne atribúty.

5.2.3. Čistenie dát

Z posledného kroku analýzy dátovej množiny dokážeme vyčítať hodnoty, ktoré v danom rozsahu nadobudnutých hodnôt nedávajú zmysel alebo sú jednoducho nekategorizované. V prípade ak týchto hodnôt je málo, tak ich môžeme odstrániť. Samozrejme musíme brať do úvahy prístup spomenutý v kapitole 2.7.4 Predspracovanie dát, časť čistenie dát. Počas fázy čistenia dát sme došli

k záveru, že v dátovej množine sa nachádzajú nekategorizované nominálne hodnoty, ktoré sme buď zmazali alebo premenovali. Ďalej sme zistili, že hodnoty zdrojových a cieľových portov nadobúdajú hexadecimálny tvar. Tieto hodnoty sme prekonvertovali na decimálny tvar. V súvislosti s číslami portov sme zistili, že niektoré hodnoty presahujú rozsah dynamických portov, ktorej maximálna hodnota je 65 535. Dĺžka času spojenia ukazovala vybočujúce hodnoty s dĺžkou času nad 8000ms oproti strednej hodnote, ktorá je 60ms. Týchto záznamov bolo iba zopár a na základe dôkladnej analýzy sme ich mohli zmazať. Ostatné atribúty tiež obsahovali vybočujúce hodnoty, ale po analýze typov spojení a toho či ide o normálnu alebo útočnú premávku sme došli k záveru, že vo vybočujúcich hodnotách určitých atribútov je vysoké zastúpenie anomálnej sieťovej premávky, a tak sme tieto záznamy nemohli zmazať, pretože by sa znížilo už aj tak nízke zastúpenie anomálnej premávky na ešte nižší počet.

5.2.4. Doplnenie chýbajúcich hodnôt

Ako sme aj v časti Analýza dátovej množiny spomenuli, tak popisné štatistiky nezohľadňujú chýbajúce hodnoty, a preto ich zobrazenie riešime cez metódu *isna*. Táto metóda nám vráti zoznam atribútov s chýbajúcimi dátami. Prvým atribútom je *attack_cat*, ktorý je nominálneho typu a určuje typ útoku. V našom prípade tento atribút môžeme zmazať, pretože našim cieľom nie je predikcia viacerých tried, ale iba binárna predikcia tzn. či je dané sieťové spojenie normálne alebo útočné. Ďalším prístupom k spracovaniu tohto atribútu je jeho ponechanie, pretože od typu útoku môže závisieť ďalšia akcia v prípade zistenia anomálnej premávky. Ďalšie atribúty s chýbajúcimi hodnotami sú numerické.

Pre doplnenie numerických chýbajúcich hodnôt sme sa rozhodli pre regresiu. Využívame metódu *RandomForestRegressor*, pretože používa priemerovanie na zlepšenie predikčnej presnosti a má kontrolu nad pretrénovaním. Predtým, než by sme spustili tréning regresného náhodného stromu sme optimalizovali hyperparametre pomocou dvoch metód: *RandomizedSearch* a *GridSearch*. Podľa Senapatia [44] náhodné vyhľadávanie (Random Search) je technika, pri ktorej sa na nájdenie najlepšieho riešenia postaveného modelu používajú náhodné kombinácie zvolených hyperparametrov. Ďalej uvádza, že šanca na nájdenie optimálneho hyperparametra je v náhodnom vyhľadávaní pomerne vyššia z dôvodu náhodného vyhľadávacieho vzoru. Maticové vyhľadávanie oproti náhodnému vyhľadávaní hyperparametrov vyskúša každú kombináciu predvoleného zoznamu hodnôt hyperparametrov a vyhodnotí model pre každú kombináciu. Po vyhodnotení všetkých kombinácií hyperparametrov sa za najlepší model považuje ten, ktorý dosiahol najvyššiu presnosť. Naše riešenie spočíva v kombinácii týchto dvoch metód.

Najprv sme zadefinovali množinu hyperparametrov s hodnotami, ktoré môže každý hyperparamter nadobudnúť podľa dokumentácie danej regresnej metódy. Najskôr sme spustili

Náhodné vyhľadávanie a na základe výsledku náhodného vyhľadávania sme dokázali určiť dolnú hranicu hodnôt hyperparametrov. Vytvorili sme druhú množinu hyperparametrov s hodnotami vyššími alebo rovnými aké sme dostali náhodným vyhľadávaním a spustili sme optimalizáciu hyperparametrov maticovým vyhľadávaním. Výslednú množinu hyperparametrov sme použili ako parameter v modeli regresného náhodného lesa. Pre každý model predikcie chýbajúcich hodnôt určitého atribútu sme optimalizovali hyperparametre zvlášť.

Pseudo kód na rozdelenie dátovej množiny je nasledovný:

```
Rozdeľ údaje do dvoch množín, s chýbajúcimi hodnotami a bez
chýbajúcich hodnôt bez atribútu, ktorý chceme predpovedať.
Množinu s chýbajúcimi hodnotami označ X_test. Množinu bez
chýbajúcich hodnôt označ X_train. Množina y_train predstavuje
známe hodnoty predpovedaného atribútu. Natrénuj model na
množine X_train a y_train a predpovedaj hodnoty pre X_test.
Zlúč pôvodné hodnoty s hodnotami množiny X_test.
```

Na základe predchádzajúceho pseudo kódu sme postupne predpovedali chýbajúce hodnoty pre všetky atribúty zvlášť. Takýmto spôsobom sme zabezpečili závislosť hodnôt, pretože model pri predikcii chýbajúcich hodnôt druhého atribútu bral do úvahy predpovedané hodnoty prvého atribútu atď.

5.2.5. Spracovanie kategorických atribútov

Kategorické atribúty sme sa rozhodli spracovať dvomi spôsobmi. Prvý spôsob je priradenie statických numerických hodnôt jednotlivým kategorickým hodnotám. Tento spôsob sa nazýva mapovanie, kedy sa vytvorí slovník s presným mapovaním kategorických hodnôt na numerické. Taký slovník má nasledovnú podobu: {'ftp': 1, 'smtp': 2, 'dns': 3, ...}.

Druhým spôsobom predspracovania kategorických atribútov je metódou One-Hot Encoding. Pomocou metódy *pd.get_dummies(nazovKategorickehoAtributu)* sme pretransformovali nominálne atribúty na numerické. Týmto metódam sme sa podrobnejšie venovali v kapitole 2.7.4 Predspracovanie dát. Spracovaniu nominálneho atribútu zdrojovej a cieľovej IP adresy sa venujeme v nasledujúcej kapitole.

5.2.6. Obohacovanie dát

Nominálny atribút zdrojovej a cieľovej IP adresy sme pretransformovali na ďalší nominálny atribút, ktorý predstavuje krajinu IP adresy pomocou vyššie spomínanej databázy GeoLite2.

Pomocou knižnice *geoip2.database* sme zavolali metódu na získanie označenia krajiny (ISO kód), ku ktorej daná IP adresa patrí. V prípade IP adries ktoré sa nenachádzajú v databáze sme ošetrili tak, že sme podľa rozsahu IP adries priradili jeden z príznakov: "Private", "Localhost", "Multicast". Následne sa aplikuje proces spracovania kategorických atribútov z kapitoly vyššie. Tento proces je časovo náročný v prípade transformácie IP adries v rozsahu viac sto tisíc.

Dátovú množinu sme obohatili aj o dva ďalšie atribúty, ktoré opisujú typ portu. Na základe rozsahu čísla jednotlivých portov vieme určiť, či sa jedná o dobre známy (well-know) port, registrovaný alebo súkromný. Následne sa aplikuje proces spracovania kategorických atribútov z kapitoly vyššie.

5.2.7. Štandardizácia

Pre proces štandardizácie sme použili metódu *StandardScaler*, ktorý normalizuje vlastnosti odstránením strednej hodnoty a škáluje hodnoty podľa rozptylu jednotiek. Dôvod, prečo je tento proces nevyhnutný pre metódy strojového učenia je podrobne vysvetlený v kapitole 4.2 Programový modul predspracovania dátovej množiny.

5.2.8. Vzorkovanie

Proces štandardizácie je realizovaný dvomi metódami: *SMOTE* a *ADASYN*. Tieto metódy sú prepojené rúrou (pipeline). Rúra slúži na to, aby sa výstup jednej metódy použil ako vstup pre druhú metódu. Podľa Lemaitre a spol. [26] štandardná metóda *RandomOverSampler* v porovnaní s metódami *SMOTE* a *ADASYN* vzorkuje duplikovaním niektorých pôvodných vzoriek menšinovej triedy. *SMOTE* a *ADASYN* generujú nové vzorky interpoláciou. Vzorky použité na interpoláciu/generovanie nových syntetických vzoriek sa však líšia. *ADASYN* sa zameriava na vytváranie vzoriek vedľa originálnych vzoriek, ktoré sú nesprávne klasifikované pomocou klasifikátora K-Nearest Neighbors (KNN). Zatiaľ čo *SMOTE* nerozlišuje rozdiel medzi vzorkami, ktoré sa majú klasifikovať pomocou pravidla najbližších susedov.

5.2.9. Uloženie súborov

Uloženie dokumentu vo formáte HTML o priebehu správy predspracovania vybranej dátovej množiny sa realizuje cez príkaz *jupyter* volaním metódy *nbconverter*, ktorý prekonvertuje notebook do HTML formátu a uloží do príslušného adresára v adresnom priestore Google Drive.

Predspracovaná dátová množina sa prekonvertuje do formátu CSV pomocou knižnice *google.colab.files* zavolaním metódy *to_csv*. Následne sa vygeneruje CSV súbor a uloží sa do príslušného adresára v adresnom priestore Google Drive.

5.3. Prototyp programového modulu strojového učenia

Programový modul je rozdelený do buniek, kde v každej bunke je časť kódu zodpovedajúca za vykonanie daného kroku predspracovania vybranej predspracovanej dátovej množiny pre metódu strojového učenia. Kroky predspracovania predspracovanej dátovej množiny pre metódy strojového učenia sú zjednotenie a transformácia dátovej množiny. Týmto krokom sa venujeme nižšie v podkapitolách tejto kapitoly.

Jednotlivé kroky programového modulu strojového učenia nájdete na diagrame aktivít na obrázku č. 17. Proces programového modulu strojového učenia opisujú kapitoly nižšie.

5.3.1. Načítanie, zjednotenie a transformácia predspracovanej dátovej množiny

Predspracovaná dátová množina vo formáte CSV sa načíta do dátovej štruktúry *Set* (sada), pričom jednotlivé položky sady predstavujú samotnú predspracovanú dátovú množinu, ktorá je uložená v dátovej štruktúre *DataFrame*. Prístup k dátovej množine je nasledovný: `datasets['nazovDátovejMnoziny']`. Predspracované dátové množiny sa ukladajú spolu s hlavičkami, a preto nie je potrebné ich osobitne načítať a nastaviť ako hlavičku predspracovanej dátovej množiny.

V prípade, ak používateľ načítal viac ako jednu dátovú množinu s rovnakou metódou predspracovania, tak sa tieto dátové množiny môžu zlúčiť, voľba je na používateľovi. Problémom zlúčenia dátových množín sme sa venovali v kapitole 4.4 Programový modul strojového učenia. Je dôležité poznamenať, že v prípade zlúčenia rozsiahlych predspracovaných dátových množín môže dôjsť k vyčerpaniu pamäte RAM v prostredí Google Colab. Vyčerpanie pamäte zvyčajne môže nastať pri procese výberu hyperparametrov alebo počas trénovania modelu strojového učenia. Počas testovania prototypu sa nám nie raz stalo, že RAM pamäť veľkosti 35GB nebola postačujúca.

Predspracovaná dátová množina sa pretransformuje na menšie množiny dát podľa návrhu. Štandardne sa využíva metóda *train_test_split* knižnice *model_selection*. V tejto metóde sa určí veľkosť validačnej vzorky dát vo forme percent. Návratová hodnota metódy je trénovacia a validačná vzorka dát. K tomu, aby sme dostali aj testovaciu vzorku dát potrebujeme metódu dvakrát aplikovať. Vzorky sú rozdelené v pomere trénovacia vzorka: 60%, validačná vzorka: 20%, testovacia vzorka: 20%.

Tým pádom je predspracovaná dátová množina pripravená na použitie metódou strojového učenia.

5.3.2. Trénovanie a vyhodnotenie modelu strojového učenia

Rozhodli sme sa vybrať nasledovné inteligentné metódy strojového učenia: logistická regresia, SGD klasifikátor, rozhodovací strom a náhodný les. Okrem SGD klasifikátora sú všetky vyššie spomenuté metódy strojového učenia opísané v kapitole 2.6.1 Klasifikačné algoritmy. SGD klasifikátor [52] je tiež lineárny klasifikátor, ale je kombináciou SVM a logistickej regresie s výcvikom SGD. Tento model implementuje regularizované lineárne modely so stochastickým gradientom učenia (Stochastic Gradient Descent - SGD). Gradient straty sa odhaduje pre každú vzorku v čase a model sa aktualizuje podľa postupu so znižujúcou sa mierou učenia.

Používateľ má možnosť určiť či chce model strojového učenia trénovať na dátovej množine so sadou vybraných atribútov. Pre logistickú regresiu sme použili metódu *RFE* [49], ktorá vytvára rebríček hodnotení jednotlivých atribútov s rekurzívnym odstránením. Pre parameter *estimator* (dozorca) sme použili model lineárnej regresie. Metóda vracia zoznam atribútov s príslušným hodnotením. Vyberú sa atribúty, ktorých p hodnota je menšia ako 0.05. Pre SGD klasifikátor sme použili metódu *Nystroem* [51], ktorá konštruje približnú mapu atribútov pre ľubovoľné jadro s použitím podmnožiny údajov ako základ. Pre metódy rozhodovací strom a náhodný les sme ako metódu na výber najlepších atribútov použili metódu *SelectFromModel* [50], ktorý je meta-transformátor pre výber najlepších atribútov na základe dôležitých váh. Metódy *RFE* a *SelectFromModel* sú súčasťou knižnice *feature_selection*. Metóda *Nystroem* sa nachádza v knižnici *kernel_approximation*.

Pseudo kód výberu najlepších atribútov je nasledovný:

Ak je príznak výberu najlepších atribútov pravdivý a predspracovaná dátová množina nebola predspracovaná One-Hot Encodingom, tak optimalizuj hyperparametre modelu so všetkými atribútmi predspracovanej dátovej množiny. Po optimalizovaní hyperparametrov vyber najlepšie atribúty z modelu a znovu optimalizuj hyperparametre pre model s najlepšími atribútmi. Výsledný model s optimalizovanými hyperparametrami použi na trénovanie. V prípade ak predspracovaná dátová množina bola predspracovaná metódou One-Hot Encoding, vyber najlepšie atribúty zo základného modelu (bez parametrov) a potom optimalizuj hyperparametre pre model s najlepšími atribútmi. Výsledný model s optimalizovanými hyperparametrami použi na trénovanie.

Pre výber optimálnych hyperparametrov sme použili kombináciu *RandomizedSearch* a *GridSearch*, ktoré sme podrobnejšie popísali v kapitole 5.2.3 Čistenie dát. Pre model SGD klasifikátor je použitá metóda *bestFit* z knižnice *parfit* od Carpentera [9], ktorá je určená na paralelizáciu učenia modelu a flexibilné vyhodnocovanie modelov strojového učenia.

Po výbere najlepších atribútov predspracovanej dátovej množiny je potrebné pretransformovať trénovaciu, validačnú a testovaciu vzorku dát na základe najlepších atribútov.

Dôležité je poznamenať výnimku v pseudo kóde, kedy sa pri výbere najlepších atribútov predspracovanej dátovej množiny nerobí dvojnásobný výber hyperparametrov ak predspracovaná dátová množina bola predspracovaná metódou One-Hot Encoding. Toto je z dôvodu prečerpania pamäte RAM, ktorý sme spomenuli v kapitole č. 5.3.1. Tu vzniká problém nedostatku pamäte z dôvodu veľkého objemu dát po spracovaní kategorických atribútov metódou One-Hot Encoding.

Na vyhodnotenie úspešnosti modelu používame nasledovné metriky:

- Správnosť, presnosť, F1-skóre, podporu
- Štandardnú desať-násobnú krížovú validáciu
- Stratifikovanú desať-násobnú K-fold krížovú validáciu
- Confusion matrix
- ROC (AUC) krivku

5.3.3. Uloženie súborov

Uloženie dokumentu vo formáte HTML o priebehu správy klasifikácie sieťových útokov sa realizuje cez príkaz *jupyter* volaním metódy *nbconverter*, ktorý prekonvertuje notebook do HTML formátu a uloží do príslušného adresára v adresnom priestore Google Drive.

Model strojového učenia sa uloží vo formáte SAV do príslušného adresára v adresnom priestore Google Drive. Metóda na uloženie modelu strojového učenia je *dump* knižnice *joblib*.

6. Overenie riešenia

Overenie správnosti riešenia programových modulov budeme realizovať na základe jednotlivých bodov funkcionálnych vlastností z kapitoly 3.1 Funkcionálne požiadavky.

- Výber rôznych metód strojového učenia.
 - Programový modul strojového učenia umožňuje používateľovi vybrať metódy strojového učenia a následne spustiť klasifikáciu nad vybranou množinou predspracovaných dát.
- Výber dátovej množiny na základe typu predspracovania, na ktorú sa má aplikovať zvolená metóda strojového učenia.
 - Programový modul strojového učenia umožňuje používateľovi vybrať, nad akou dátovou množinou chce aplikovať vybranú metódu strojového učenia. Používateľ má na výber sadu predspracovaných dátových množín.
- Zobrazenie parametrov vybranej metódy strojového učenia.
 - Programový modul strojového učenia zobrazuje parametre vybranej metódy strojového učenia. Taktiež umožňuje tieto parametre škálovať.
- Vytvorenie výstupu klasifikácie v textovej aj grafickej podobe.
 - Programový modul strojového učenia zobrazuje výstup klasifikácie po aplikovaní vybranej metódy strojového učenia nad vybranou dátovou množinou dát vo forme tabuľky, grafu a percentuálnej úspešnosti.
- Porovnanie rôznych metód strojového učenia.
 - Túto funkčnú vlastnosť sme neimplementovali v tejto fáze riešenia diplomového projektu.
- Výber dátovej množiny na spracovanie.
 - Programový modul určený na spracovanie dátových množín umožňuje používateľovi vybrať nepredspracovanú dátovú množinu.
- Výber rôznych metód spracovania dátovej množiny.
 - Programový modul určený na spracovanie dátovej množiny umožňuje používateľovi vybrať rôzne metódy spracovania dátovej množiny a následne spustiť spracovanie nad vybranou množinou dát.

- Možnosť zobrazit' a uložit' proces spracovania dátovej množiny.
 - Programový modul určený na spracovanie dátovej množiny ukladá proces spracovania dátovej množiny spolu s výstupmi jednotlivých krokov spracovania do dokumentu vo formáte HTML. Spracovanú dátovú množinu taktiež ukladá vo formáte CSV. HTML dokument a CSV súbor sa ukladá do Google Drive úložného priestoru používateľa.
- Možnosť zobrazit' a uložit' proces programového modulu strojového učenia.
 - Programový modul strojového učenia ukladá proces práce strojového učenia spolu s výstupmi jednotlivých krokov do dokumentu vo formáte HTML. Taktiež ukladá model metódy strojového učenia vo formáte SAV. HTML dokument a SAV súbor sa ukladá do Google Drive úložného priestoru používateľa.

6.1. Experimentálne overenie riešenia

Na základe predspracovaných dátových množín sme aplikovali vybrané metódy strojového učenia (viď. kapitolu 5.3.2 Trénovanie a vyhodnotenie modelu strojového učenia). Programový modul strojového učenia vyhodnotil vybrané metódy strojového učenia podľa tabuliek č. 11 a 12. Hodnoty sú uvedené pre správnosť a F1-skóre v percentách pre validačnú vzorku dát.

Tabuľka 11 – Výsledky experimentálnych testov - správnosť

Dátová množina	Logistická regresia	SGD klasifikátor	Rozhodovací strom	Náhodný les
dataset_4_MAP_TOPF_F	98.43	98.02	99.27	99.47
dataset_4_MAP_TOPF_T	98.40	79.82	98.80	99.05
dataset_4_MAP_RESAMP_TOPF_F	98.93	98.67	99.35	99.69
dataset_4_MAP_RESAMP_TOPF_T	98.88	53.66	98.91	99.23
dataset_4_OHE_TOPF_T	-	86.88	99.50	99.43
dataset_4_OHE_RESAMP_TOPF_T	-	55.79	98.92	99.46

Tabuľka 12 – Výsledky experimentálnych testov - F1-skóre

Dátová množina	Logistická regresia	SGD klasifikátor	Rozhodovací strom	Náhodný les
dataset_4_MAP_TOPF_F	96	95	98	99
dataset_4_MAP_TOPF_T	96	0	97	98
dataset_4_MAP_RESAMP_TOPF_F	99	99	99	100
dataset_4_MAP_RESAMP_TOPF_T	99	65	99	99
dataset_4_OHE_TOPF_T	-	66	99	99
dataset_4_OHE_RESAMP_TOPF_T	-	66	99	99

Vysvetlenie tabuľky:

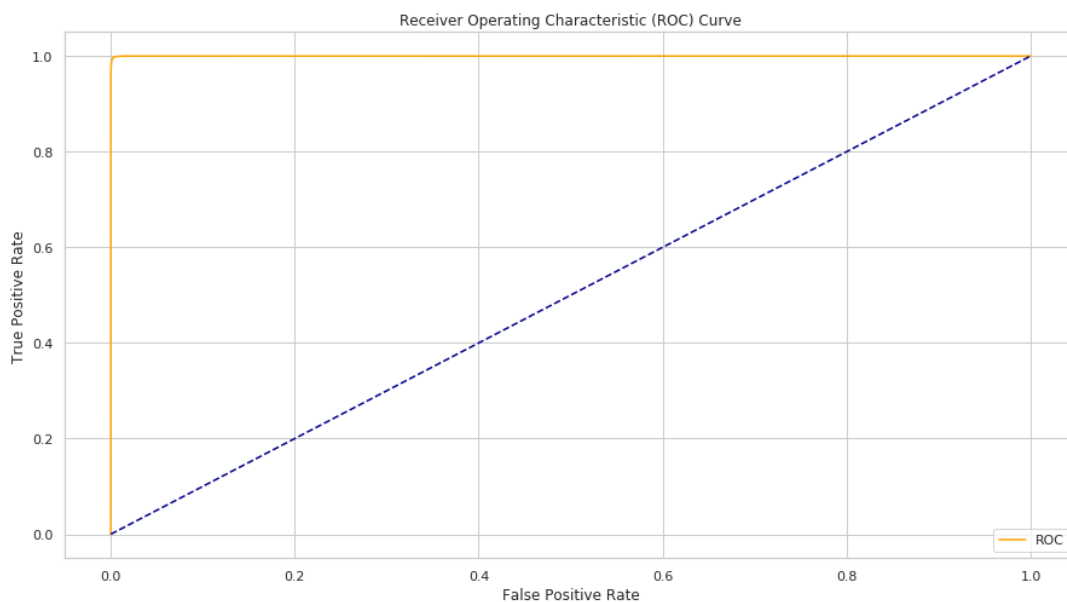
- Označenie MAP v názve dátovej množiny predstavuje mapovanie a OHE predstavuje One-Hot Encoding kategorických atribútov. Dátové množiny s označením MAP majú počet atribútov 50 a dátové množiny s označením OHE majú 218 atribútov.
- Označenie RESAMP v názve dátovej množiny predstavuje, že dátová množina je prevzorkovaná. Prevzorkované dátové množiny majú počet záznamov 702296 oproti dátovej množine bez vzorkovania s počtom záznamov 440042.
- Označenie TOPF_T/F v názve dátovej množiny predstavuje výber najlepších atribútov. V prípade T (pravda) sa vybrali najlepšie atribúty a v prípade F (nepravda) sa nevybrali.
- Hodnoty označené červenou farbou majú veľký výkyv správnosti modelu voči F1-skóre.
- Prázdne hodnoty boli spôsobené vznikom fenoménu multikolinearita.

Na základe experimentálnych testov môžeme dôjsť k záveru, že najspoľahlivejšou metódou strojového učenia je náhodný les, pretože v každom experimentálnom teste dosahoval veľmi podobné, stále a vysoké hodnoty správnosti a F1-skóre. Rozhodovací strom oproti náhodnému lesu dosahoval o niečo menej presné hodnoty správnosti klasifikácie a F1-skóre. Treťou najsprávnejšou metódou klasifikácie je lineárna regresia. V prípade predspracovanej kategorických atribútov metódou One-Hot Encoding sme sa stretli s fenoménom multikolinearita, ktorú opisujem v kapitole č. 4.2. Preto, pre túto metódu sme nedokázali určiť hodnoty správnosti a F1-skóre aj napriek aplikovaniu metódy postupného odoberania vybraných atribútov. Najhoršie výsledky dosahoval SGD klasifikátor. Výsledky tejto metódy strojového učenia majú veľké výkyvy v hodnotách správnosti modelu voči F1-skóre a tým pádom môžeme dôjsť k záveru, že model nie je spoľahlivý.

Ďalej sme zistili, že výber najlepších atribútov má za následok mierny pokles správnosti vyhodnotenia modelu. Ďalším zistením je fakt, že medzi rôznymi metódami predspracovania dátovej


množiny nie je veľký rozdiel vo výsledkoch. Strojové učenie, ktoré sa učilo na dátovej množine predspracovanou metódou prevzorkovania dosahoval lepšie výsledky.

Na nasledujúcom obrázku č. 18 je ROC krivka pre najlepší model náhodného lesa so správnosťou 99.69%, F1-skóre 100% a AUC hodnotou 99.99%.



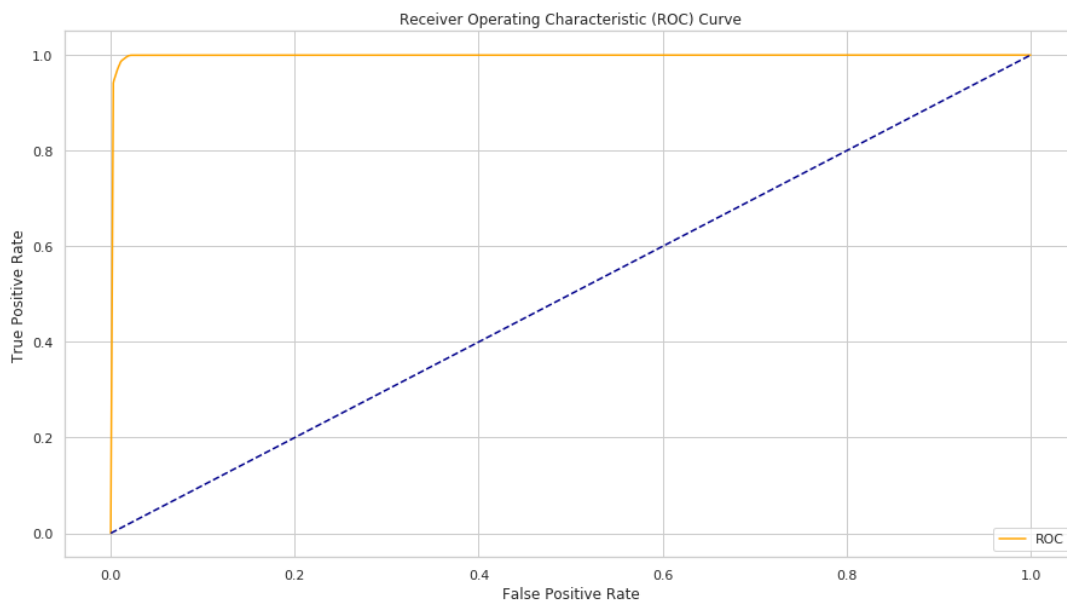
Obrázok 18 – ROC krivka najlepšieho modelu náhodného lesa

Na nasledujúcom obrázku č. 19 môžete vidieť ROC krivku SGD klasifikátora s úspešnosťou 79.82% a s F1-skóre 0%. V porovnaní s náhodným lesom môžeme dôjsť k záveru, že model SGD klasifikátora v tomto prípade nedokázal rozpoznať normálnu sieťovú premávku od anomálnej.




Obrázok 19 – ROC krivka SGD klasifikátora

Nasledujúce obrázky porovnávajú mieru zakrivenia ROC krivky (oblasť pod krivkou) rozhodovacieho stromu a náhodného lesa. Obrázok č. 20 zobrazuje ROC krivku rozhodovacieho stromu s AUC hodnotou 99.81%. Obrázok č. 21 znázorňuje ROC krivku náhodného lesa s AUC hodnotou 99.97%. Hodnota AUC určuje, na koľko percent je schopný model rozlíšiť rozdiel medzi dvomi triedami.



Obrázok 20 – ROC krivka rozhodovacieho stromu



Obrázok 21 – ROC krivka náhodného lesa

7. Zhodnotenie

V druhej časti tejto práce sme sa venovali návrhu vlastného riešenia. Navrhli sme dva programové moduly. Prvý programový modul je určený na spracovanie rozsiahlych dátových množín a druhý programový modul je určený na aplikovanie metód strojového učenia na vybranej predspracovanej dátovej množine. Taktiež sme navrhli vhodné prostredie, v ktorom sme navrhnuté programové moduly neskôr implementovali. Na výber vhodného prostredia sme kládli veľký dôraz z dôvodu práce s rozsiahlymi množinami dát a z dôvodu práce s metódami strojového učenia, ktoré vyžadujú vysoký výpočtový výkon. Určili sme funkcionálne a nefunkcionálne požiadavky, ktoré majú programové moduly spĺňať. Na základe návrhu riešenia a funkcionálnych požiadaviek sme úspešne implementovali prototypy programových modulov. Postup implementácie jednotlivých častí programových modulov sme taktiež podrobne opísali. Podarilo sa nám stiahnuť rozsiahlu množinu dát NUSW-NB15, nad ktorou sme aplikovali rôzne metódy predspracovania dátovej množiny. Podarilo sa nám predspracovať dátové množiny rôznymi spôsobmi. Nad predspracovanými dátovými množinami sme aplikovali metódy strojového učenia, konkrétne: logistická regresia, lineárny klasifikátor (SVM, logistická regresia) s výcvikom SGD, náhodný les a rozhodovací strom.

V poslednej časti tejto práce sme overili navrhnuté riešenie. Vykonali sme experimentálne testy a na základe výsledkov vyhodnotení úspešností klasifikácii vybraných metód strojového učenia vybrali najlepšiu metódu strojového učenia. Dosiahli sme vysoké miery presností odhalenia sieťových útokov. Najlepšou metódou na základe výsledkov experimentálnych testov je náhodný les, pretože v každom experimentálnom teste dosiahol veľmi podobné, stále a vysoké hodnoty správnosti. Na základe experimentálnych testov sme došli aj k záveru, že niektoré metódy strojového učenia nie sú vhodné pre určité typy predspracovania dátovej množiny. Najhoršie výsledky dosiahol SGD klasifikátor, pretože hodnoty správností voči hodnotám F1-skóre boli veľmi kolísavé a tým pádom môžeme túto metódu pokladať sa nespoľahlivú v doméne odhaľovania sieťových útokov. Výsledky experimentálnych testov sme interpretovali vo forme tabuliek a grafov.

Bibliografia

- [1] AHMED, Martuza, Rima PAL, Md. Mojammel HOSSAIN, Md. Abu Naser BIKAS a Md. Khalad HASAN. NIDS: A Network Based Approach to Intrusion Detection and Prevention. In: 2009 International Association of Computer Science and Information Technology - Spring Conference [online]. IEEE, 2009, 2009, s. 141-144 [cit. 2019-05-12]. DOI: 10.1109/IACSIT-SC.2009.96. ISBN 978-0-7695-3653-8. Dostupné z: <http://ieeexplore.ieee.org/document/5169326/>
- [2] AL-JARRAH, Omar a Ahmad ARAFAT. Network Intrusion Detection System using attack behavior classification. In: 2014 5th International Conference on Information and Communication Systems (ICICS) [online]. IEEE, 2014, 2014, s. 1-6 [cit. 2019-05-12]. DOI: 10.1109/IACS.2014.6841978. ISBN 978-1-4799-3023-4. Dostupné z: <http://ieeexplore.ieee.org/document/6841978/>
- [3] ALENCAR, Rafael. Resampling strategies for imbalanced datasets. Kaggle [online]. 2017 [cit. 2019-12-04]. Dostupné z: <https://www.kaggle.com/rafjaa/resampling-strategies-for-imbalanced-datasets>
- [4] ANANTHI, J. Vijitha a S. VENGATESAN. Detection of various attacks in wireless adhoc networks and its performance analysis. In: 2017 International Conference on Inventive Computing and Informatics (ICICI) [online]. IEEE, 2017, 2017, s. 754-757 [cit. 2019-05-12]. DOI: 10.1109/ICICI.2017.8365237. ISBN 978-1-5386-4031-9. Dostupné z: <https://ieeexplore.ieee.org/document/8365237/>
- [5] ASIC (application-specific integrated circuit) [online]. [cit. 2019-12-04]. Dostupné z: <https://whatis.techtarget.com/definition/ASIC-application-specific-integrated-circuit>
- [6] BHARDWAJ, Anshu. Data Preprocessing Techniques for Data Mining. Data Mining Techniques and Tools for Knowledge Discovery in Agricultural Datasets [online]. New Delhi: Division of Computer Applications Indian Agricultural Statistics Research Institute (ICAR), s. 139-144 [cit. 2019-05-22]. Dostupné z: http://iasri.res.in/ebook/win_school_aa/notes/Data_Preprocessing.pdf

- [7] BHARDWAJ, Anshu. Evaluation Measures for Data Mining Tasks. Data Mining Techniques and Tools for Knowledge Discovery in Agricultural Datasets [online]. New Delhi: Division of Computer Applications Indian Agricultural Statistics Research Institute (ICAR), s. 145-152 [cit. 2019-05-19]. Dostupné z: http://iasri.res.in/ebook/win_school_aa/notes/Evaluation_Measures.pdf
- [8] BHATTACHARYYA, Dhruva Kumar a Jugal Kumar KALITA. Network Anomaly Detection [online]. Chapman and Hall/CRC, 2013 [cit. 2019-05-12]. DOI: 10.1201/b15088. ISBN 9780429166877.
- [9] CARPENTER, Jason. Parfit — quick and powerful hyper-parameter optimization with visualizations. Medium: ML Review [online]. 2017, 26.11.2017 [cit. 2019-12-07]. Dostupné z: <https://medium.com/mlreview/parfit-hyper-parameter-optimization-77253e7e175e>
- [10] Canadian Institute for Cybersecurity [online]. Fredericton [cit. 2019-05-13]. Dostupné z: <https://www.unb.ca/cic/datasets/index.html>
- [11] Cloud TPU [online]. [cit. 2019-12-04]. Dostupné z: <https://cloud.google.com/tpu/>
- [12] DHAIRYA, Kumar. Introduction to Data Preprocessing in Machine Learning. Towards Data Science [online]. 2018, 25.12.2018 [cit. 2019-12-03]. Dostupné z: <https://towardsdatascience.com/introduction-to-data-preprocessing-in-machine-learning-a9fa83a5dc9d>
- [13] DHANABAL, L. a S. P. SHANTHARAJAH. A Study On NSL-KDD Dataset For Intrusion Detection System Based On Classification Algorithms. International Journal of Advanced Research in Computer and Communication Engineering [online]. 2015, 6(4), 446-452 [cit. 2019-05-13]. DOI: 10.17148/IJARCCE.2015.4696. ISSN 2278-1021. Dostupné z: <https://pdfs.semanticscholar.org/1b34/80021c4ab0f632efa99e01a9b073903c5554.pdf>
- [14] FLOPS (floating-point operations per second) [online]. [cit. 2019-12-04]. Dostupné z: <https://whatis.techtarget.com/definition/FLOPS-floating-point-operations-per-second>
- [15] FROST, Jim. Multicollinearity in Regression Analysis: Problems, Detection, and Solutions. Statistics By Jim - Making statistics intuitive [online]. [cit. 2019-12-04]. Dostupné z: <https://statisticsbyjim.com/regression/multicollinearity-in-regression-analysis/>

[16] GARG, Akash a Prachi MAHESHWARI. A hybrid intrusion detection system: A review. In: 2016 10th International Conference on Intelligent Systems and Control (ISCO) [online]. IEEE, 2016, 2016, s. 1-5 [cit. 2019-05-12]. DOI: 10.1109/ISCO.2016.7726909. ISBN 978-1-4673-7807-9. Dostupné z: <http://ieeexplore.ieee.org/document/7726909/>

[17] GeoLite2 Free Downloadable Databases [online]. [cit. 2019-12-06]. Dostupné z: <https://dev.maxmind.com/geoip/geoip2/geolite2/>

[18] HADDADI, Fariba, Sara KHANCHI, Mehran SHETABI a Vali DERHAMI. Intrusion Detection and Attack Classification Using Feed-Forward Neural Network. In: 2010 Second International Conference on Computer and Network Technology [online]. IEEE, 2010, 2010, s. 262-266 [cit. 2019-05-12]. DOI: 10.1109/ICCNT.2010.28. ISBN 978-1-4244-6961-1. Dostupné z: <http://ieeexplore.ieee.org/document/5474495/>

[19] HINTON, Todd. Introduction to Data Preprocessing in Machine Learning. Redpoint Global [online]. 2018, 10.7.2018 [cit. 2019-12-03]. Dostupné z: <https://www.redpointglobal.com/blog/what-is-data-enrichment/?fbclid=IwAR3lOtF1cBM08sGB8yzgj3evwzK00Nj8Af03oMttUmbpv9pd4Fh2J0tiZHA>

[20] HUSSAIN, Jamal a Aishwarya MISHRA. Performance Analysis of Some Neural Network Algorithms using NSL-KDD Dataset. International Journal of Computer Trends and Technology [online]. 2017, 50(1), 43-49 [cit. 2019-05-12]. DOI: 10.14445/22312803/IJCTT-V50P107. ISSN 22312803. Dostupné z: <http://www.ijcttjournal.org/archives/ijctt-v50p107>

[21] JAIN, Anurag; BHUPENDRA, L. Classifier selection models for intrusion detection system (IDS). Informatics Engineering, an International Journal (IEIJ), 2016, 4.1: 1-11.

[22] JAITLEY, Urvashi. Why Data Normalization is necessary for Machine Learning models. Medium [online]. 2018, 8.10.2018 [cit. 2019-12-04]. Dostupné z: <https://medium.com/@urvashilluniya/why-data-normalization-is-necessary-for-machine-learning-models-681b65a05029>

[23] JAJISH, Thomas. Intrusion Detection Systems (IDS), Network Intrusion Detection System (NIDS), Host Intrusion Detection System (HIDS), Signatures, Alerts, Logs, False Alarms. Sensor. Free Networking tutorials, System Administration Tutorials and Security Tutorials - omniseu.com [online]. [cit. 2019-05-12]. Dostupné z: <http://www.omniseu.com/security/infrastructure-and-email-security/intrusion-detection-systems-ids.php>

[24] JIMOH, Hafeez. The tale of missing values in Python. Towards Data Science [online]. 2018, 6.1.2018 [cit. 2019-12-04]. Dostupné z: <https://towardsdatascience.com/the-tale-of-missing-values-in-python-c96beb0e8a9d>

[25] KUMAR, Gulshan. Evaluation Metrics for Intrusion Detection Systems - A Study. International Journal of Computer Science and Mobile Applications [online]. 2014, (11), 11-17 [cit. 2019-05-12]. ISSN 2321-8363. Dostupné z: https://www.researchgate.net/publication/311108073_Evaluation_Metrics_for_Intrusion_Detection_Systems-A_Study

[26] LEMAITRE, G., F. NOGUEIRA, D. OLIVEIRA a C. ARIDAS. Over-sampling. Imbalanced-learn [online]. 2017 [cit. 2019-12-06]. Dostupné z: https://imbalanced-learn.readthedocs.io/en/stable/over_sampling.html

[27] LI PENG, YUEMING LU, JIEFU GAN a HANG CHENG. Design and implementation of network attacks detection module. In: Third International Conference on Cyberspace Technology (CCT 2015) [online]. Institution of Engineering and Technology, 2015, 2015, 5.-5. [cit. 2019-05-12]. DOI: 10.1049/cp.2015.0861. ISBN 978-1-78561-089-9. Dostupné z: <https://digital-library.theiet.org/content/conferences/10.1049/cp.2015.0861>

[28] LI, Jing a Chunbo DONG. Research on Network Security Situation Prediction-Oriented Adaptive Learning Neuron. In: 2010 Second International Conference on Networks Security, Wireless Communications and Trusted Computing [online]. IEEE, 2010, 2010, s. 483-485 [cit. 2019-05-12]. DOI: 10.1109/NSWCTC.2010.247. ISBN 978-1-4244-6597-2. Dostupné z: <http://ieeexplore.ieee.org/document/5480921/>

[29] LIU, Gao, Zheng YAN a Witold PEDRYCZ. Data collection for attack detection and security measurement in Mobile Ad Hoc Networks: A survey. *Journal of Network and Computer Applications* [online]. 2018, 105, 105-122 [cit. 2019-05-12]. DOI: 10.1016/j.jnca.2018.01.004. ISSN 10848045. Dostupné z: <https://linkinghub.elsevier.com/retrieve/pii/S1084804518300043>

[30] MEHMOOD, Tahir a Helmi B Md RAIS. Machine learning algorithms in context of intrusion detection. In: 2016 3rd International Conference on Computer and Information Sciences (ICCOINS) [online]. IEEE, 2016, 2016, s. 369-373 [cit. 2019-05-13]. DOI: 10.1109/ICCOINS.2016.7783243. ISBN 978-1-5090-2549-7. Dostupné z: <http://ieeexplore.ieee.org/document/7783243/>

[31] MOUSTAFA N., SLAY J. (2018) A Network Forensic Scheme Using Correntropy-Variation for Attack Detection. In: Peterson G., Sheno S. (eds) *Advances in Digital Forensics XIV. DigitalForensics 2018. IFIP Advances in Information and Communication Technology*, vol 532. Springer, Cham

[32] MOUSTAFA, Nour a Jill SLAY. The evaluation of Network Anomaly Detection Systems: Statistical analysis of the UNSW-NB15 data set and the comparison with the KDD99 data set. *Information Security Journal: A Global Perspective* [online]. 2016, 25(1-3), 18-31 [cit. 2019-05-19]. DOI: 10.1080/19393555.2015.1125974. ISSN 1939-3555. Dostupné z: <http://www.tandfonline.com/doi/full/10.1080/19393555.2015.1125974>

[33] MOUSTAFA, Nour a Jill SLAY. UNSW-NB15: a comprehensive data set for network intrusion detection systems (UNSW-NB15 network data set). In: 2015 Military Communications and Information Systems Conference (MilCIS) [online]. IEEE, 2015, 2015, s. 1-6 [cit. 2019-05-13]. DOI: 10.1109/MilCIS.2015.7348942. ISBN 978-1-4673-7007-3. Dostupné z: <http://ieeexplore.ieee.org/document/7348942/>

[34] Multicollinearity [online]. [cit. 2019-12-04]. Dostupné z: <https://www.statisticssolutions.com/multicollinearity/>

[35] NAVLANI, Avinash. Understanding Logistic Regression in Python. DataCamp [online]. 2018, 7.9.2018 [cit. 2019-12-03]. Dostupné z: <https://www.datacamp.com/community/tutorials/understanding-logistic-regression-python>

[36] PRABHU. Understanding Hyperparameters and its Optimisation techniques. Towards Data Science [online]. 2018, 3.7.2018 [cit. 2019-12-05]. Dostupné z: <https://towardsdatascience.com/understanding-hyperparameters-and-its-optimisation-techniques-f0debba07568>

[37] REVATHI, S. a A. MALATHI. A Detailed Analysis on NSL-KDD Dataset Using Various Machine Learning Techniques for Intrusion Detection. International Journal Of Engineering Research & Technology [online]. IJERT, 2013, 12(2), 1848-1853 [cit. 2019-05-13]. ISSN 2278-0181. Dostupné z: <https://www.ijert.org/research/a-detailed-analysis-on-nsi-kdd-dataset-using-various-machine-learning-techniques-for-intrusion-detection-IJERTV2IS120804.pdf>

[38] SAMRIN, Rafath a D VASUMATHI. Review on anomaly based network intrusion detection system. In: 2017 International Conference on Electrical, Electronics, Communication, Computer, and Optimization Techniques (ICEECOT) [online]. IEEE, 2017, 2017, s. 141-147 [cit. 2019-05-12]. DOI: 10.1109/ICEECOT.2017.8284655. ISBN 978-1-5386-1205-7. Dostupné z: <http://ieeexplore.ieee.org/document/8284655/>

[39] SANI, Yusuf, Ahmed MOHAMEDOU, Khalid ALI, Anahita FARJAMFAR, Mohamed AZMAN a Solahuddin SHAMSUDDIN. An overview of neural networks use in anomaly Intrusion Detection Systems. In: 2009 IEEE Student Conference on Research and Development (SCORED) [online]. IEEE, 2009, 2009, s. 89-92 [cit. 2019-05-12]. DOI: 10.1109/SCORED.2009.5443289. ISBN 978-1-4244-5186-9. Dostupné z: <http://ieeexplore.ieee.org/document/5443289/>

[40] SAV File Format [online]. [cit. 2019-12-04]. Dostupné z: <https://whatis.techtarget.com/fileformat/SAV-Saved-date-file-for-SPSS-Statistical-Package-for-the-Social-Sciences>

[41] SAXENA, Aumreesh Ku., Sitesh SINHA a Piyush SHUKLA. General study of intrusion detection system and survey of agent based intrusion detection system. In: 2017 International Conference on Computing, Communication and Automation (ICCCA) [online]. IEEE, 2017, 2017, s. 471-421 [cit. 2019-05-12]. DOI: 10.1109/CCAA.2017.8229866. ISBN 978-1-5090-6471-7. Dostupné z: <http://ieeexplore.ieee.org/document/8229866/>

- [42] SCHAELOCKE, Lambert, Thomas SLABACH, Branden MOORE a Curt FREELAND. Characterizing the Performance of Network Intrusion Detection Sensors. VIGNA, Giovanni, Christopher KRUEGEL a Erland JONSSON, ed. Recent Advances in Intrusion Detection [online]. Berlin, Heidelberg: Springer Berlin Heidelberg, 2003, 2003, s. 155-172 [cit. 2019-05-12]. Lecture Notes in Computer Science. DOI: 10.1007/978-3-540-45248-5_9. ISBN 978-3-540-40878-9. Dostupné z: http://link.springer.com/10.1007/978-3-540-45248-5_9
- [43] SCHOONJANS, Frank. ROC curve analysis. MedCalc [online]. Belgium [cit. 2019-05-06]. Dostupné z: <https://www.medcalc.org/manual/roc-curves.php>
- [44] SENAPATI, Deepak. Grid Search vs Random Search. Medium [online]. 2018, 29.8.2018 [cit. 2019-12-06]. Dostupné z: <https://medium.com/@senapati.dipak97/grid-search-vs-random-search-d34c92946318>
- [45] SHAH, Tarang. About Train, Validation and Test Sets in Machine Learning. Towards Data Science [online]. 2017, 6.12.2017 [cit. 2019-12-05]. Dostupné z: <https://towardsdatascience.com/train-validation-and-test-sets-72cb40cba9e7>
- [46] SHAIKH, Raheel. Feature Selection Techniques in Machine Learning with Python. Towards Data Science [online]. 2018, 28.10.2018 [cit. 2019-12-04]. Dostupné z: <https://towardsdatascience.com/feature-selection-techniques-in-machine-learning-with-python-f24e7da3f36e>
- [47] SHEELA EVANGELIN PRASAD, S. N., M. V. SRINATH a Murtaza SAADIQUE BASHA. Intrusion Detection Systems, Tools and Techniques – An Overview. Indian Journal of Science and Technology [online]. 2015, 8(35) [cit. 2019-05-12]. DOI: 10.17485/ijst/2015/v8i35/80108. ISSN 0974-5645. Dostupné z: <http://www.indjst.org/index.php/indjst/article/view/80108>
- [48] SOHEILY-KHAH, Saeid, Pierre-Francois MARTEAU a Nicolas BECHET. Intrusion Detection in Network Systems Through Hybrid Supervised and Unsupervised Machine Learning Process: A Case Study on the ISCX Dataset. In: 2018 1st International Conference on Data Intelligence and Security (ICDIS) [online]. IEEE, 2018, 2018, s. 219-226 [cit. 2019-05-19]. DOI: 10.1109/ICDIS.2018.00043. ISBN 978-1-5386-5762-1. Dostupné z: <https://ieeexplore.ieee.org/document/8367767/>

- [49] Sklearn.feature_selection.RFE [online]. [cit. 2019-12-07]. Dostupné z: https://scikit-learn.org/stable/modules/generated/sklearn.feature_selection.RFE.html
- [50] Sklearn.feature_selection.SelectFromModel [online]. [cit. 2019-12-07]. Dostupné z: https://scikit-learn.org/stable/modules/generated/sklearn.feature_selection.SelectFromModel.html
- [51] Sklearn.kernel_approximation.Nystroem [online]. [cit. 2019-12-07]. Dostupné z: https://scikit-learn.org/stable/modules/generated/sklearn.kernel_approximation.Nystroem.html
- [52] Sklearn.linear_model.SGDClassifier [online]. [cit. 2019-12-07]. Dostupné z: https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.SGDClassifier.html
- [53] THOMAS, Rajesh a Deepa PAVITHRAN. A Survey of Intrusion Detection Models based on NSL-KDD Data Set. In: 2018 Fifth HCT Information Technology Trends (ITT) [online]. IEEE, 2018, 2018, s. 286-291 [cit. 2019-05-13]. DOI: 10.1109/CTIT.2018.8649498. ISBN 978-1-5386-7147-4. Dostupné z: <https://ieeexplore.ieee.org/document/8649498/>
- [54] TIWARI, Mohit, Raj KUMAR, Akash BHARTI a Jai KISHAN. Intrusion Detection Systems. International Journal of Computer Science and Mobile Applications [online]. 2017, (5), 38-44 [cit. 2019-05-12]. ISSN 2320-8163. Dostupné z: https://www.researchgate.net/publication/316599266_INTRUSION_DETECTION_SYSTEM
- [55] TPUs in Colab [online]. [cit. 2019-12-06]. Dostupné z: https://colab.research.google.com/notebooks/tpu.ipynb#scrollTo=a_rjVo-RAoYd
- [56] The UNSW-NB15 Dataset Description [online]. 2018 [cit. 2019-05-14]. Dostupné z: <https://www.unsw.adfa.edu.au/unsw-canberra-cyber/cybersecurity/ADFA-NB15-Datasets/>
- [57] WARZYŃSKI, Arkadiusz; KOŁACZEK, Grzegorz. Intrusion detection systems vulnerability on adversarial examples. In: 2018 Innovations in Intelligent Systems and Applications (INISTA). IEEE, 2018. p. 1-4.

[58] WILLIAMS, Nigel, Sebastian ZANDER a Grenville ARMITAGE. A preliminary performance comparison of five machine learning algorithms for practical IP traffic flow classification. ACM SIGCOMM Computer Communication Review [online]. 2006, 36(5) [cit. 2019-05-22]. DOI: 10.1145/1163593.1163596. ISSN 01464833. Dostupné z: <http://portal.acm.org/citation.cfm?doid=1163593.1163596>

[59] What is Correntropy [online]. [cit. 2019-12-03]. Dostupné z: <https://www.igi-global.com/dictionary/information-theoretic-learning/6003>

[60] XIA WEI-WEI a WANG HAI-FENG. Prediction model of network security situation based on regression analysis. In: 2010 IEEE International Conference on Wireless Communications, Networking and Information Security [online]. IEEE, 2010, 2010, s. 616-619 [cit. 2018-11-10]. DOI: 10.1109/WCINS.2010.5541853. ISBN 978-1-4244-5850-9. Dostupné z: <http://ieeexplore.ieee.org/document/5541853/>

[61] ZAMAN, Marzia a Chung-Horng LUNG. Evaluation of machine learning techniques for network intrusion detection. In: NOMS 2018 - 2018 IEEE/IFIP Network Operations and Management Symposium [online]. IEEE, 2018, 2018, s. 1-5 [cit. 2019-05-21]. DOI: 10.1109/NOMS.2018.8406212. ISBN 978-1-5386-3416-5. Dostupné z: <https://ieeexplore.ieee.org/document/8406212/>

Príloha A: Plán práce

Tabuľka A.13 uvádza plán práce v rámci prvej etapy riešenia diplomovej práce.

Tabuľka A.13 – Plán práce k DP I

DP I	
Týždeň	Cieľ
1-2	Analýza existujúcich riešení IDS (štruktúra, metódy, algoritmy).
3-5	Analýza metód spracovania veľkej množiny dát z prostredia počítačových sietí.
6-8	Analýza a zaúčanie sa do strojového učenia.
9-10	Odkúšanie získaných znalostí na vzorových príkladoch. Experimentovanie.
11-12	Úprava a dokončenie dokumentácie.

Jednotlivé body vyššie uvedeného plánu boli mierne náročné na vypracovanie. Podarilo sa nám zanalyzovať rôzne aspekty vybranej problémovej oblasti.

Zanalyzovali sme IDS systémy, ich architektúru, existujúce riešenia zaoberajúce sa odhalením sieťových útokov a spôsob vyhodnocovania úspešnosti IDS. Taktiež sa nám podarilo dostatočne zanalyzovať sieťové útoky, dátové množiny a strojové učenie. V prvej etape diplomovej práce sme taktiež stihli aplikovať získané znalosti o strojovom učení na dátovej množine NSL-KDD.

Navrhli sme vlastné riešenie na základe preštudovania danej problematiky. Stanovenie podmienok na prvú etapu sa nám podarilo splniť a dokument sa tiež úspešne upravil do finálnej podoby na základe podmienok vedúceho práce.

Tabuľka A.14 uvádza plán práce v rámci druhej etapy riešenia diplomovej práce.

Tabuľka A.14 – Plán práce k DP II

DP II	
Týždeň	Cieľ
1-2	Zbieranie dát z prostredia počítačových sietí a ich predpríprava.
3-4	Návrh vlastného riešenia.
5-8	Implementácia zadania.
9-10	Analýza výsledkov vlastného riešenia. Odhalenie nedostatkov. Zapracovanie zmien do implementácie.
11-12	Úprava a dokončenie dokumentácie. Príprava na obhajobu DP II.

Jednotlivé body vyššie uvedeného plánu práce k DP II boli mierne náročné na vypracovanie. Počas práce na druhej etape sme sa stretli s viacerými problémami, ktoré boli časovo náročné na vyriešenie.

Podarilo sa nám stiahnuť rozsiahlu množinu dát NUSW-NB15, nad ktorou sme aplikovali rôzne metódy predspracovania dátovej množiny. Podarilo sa nám predspracovať dátové množiny rôznymi spôsobmi. Nad predspracovanými dátovými množinami sme aplikovali metódy strojového učenia, konkrétne logistická regresia, lineárny klasifikátor (SVM, logistická regresia) s výcvikom SGD, náhodný les a rozhodovací strom. Dosiahli sme vysoké miery presností odhalenia siet'ových útokov. Počas vývoja prototypu sme čelili rôznym nedostatkom, ktoré sa ale podarilo vyriešiť a zapracovať.

Počas práce na druhej etape sme pracovali aj na zdokonalení návrhu vlastného riešenia, ktorý podrobne opisujeme vyššie v tomto dokumente.

Stanovenie podmienok na druhú etapu sa nám podarilo splniť a dokument sa tiež úspešne upravil do finálnej podoby na základe podmienok vedúceho práce.

Tabuľka A.15 uvádza plán práce v rámci tretej etapy riešenia diplomovej práce.

Tabuľka A.15 – Plán práce k DP III

DP III	
Týždeň	Cieľ
1-4	Korekcia chýb návrhu na základe pripomienok od vedúceho projektu. Implementácia ďalších častí návrhu z druhej etapy. Implementácia ďalších metód strojového učenia, hlavne neurónovej siete.
5-6	Testovanie a zhodnotenie výsledkov implementovaného nástroja.
7-8	Finálne úpravy v projekte. Kontrola a odhaľovanie chýb.
9-10	Dokončenie dokumentácie.
11-12	Príprava na obhajobu DP III.

Príloha B: Technická dokumentácia

Príloha C: Obsah elektronického média

Adresáre:

- DiplomovaPraca/ – Elektronická verzia diplomovej práce vo formáte .docx a .pdf.
- Notebooks/ – Projektový adresár programových modulov pre predspracovanie dátovej množiny a strojové učenie. Adresár obsahuje súbory vo formáte .ipynb.
- Notebooks/lib/ – Adresár vlastných knižníc. Adresár obsahuje súbory vo formáte .py.

Súbory:

- ObsahElektronickehoMedia.txt – Textový súbor s obsahom adresárov a súborov elektronického média.